

Relatório Final

**PROGRAMA P&D – GERADORA DE ENERGIA
DO MARANHÃO S/A - GERA MARANHÃO**

**PROJETO DE P&D
PD-6492-0215/2015**

TÍTULO: ANÁLISE DA CONDIÇÃO MECÂNICA E TERMODINÂMICA DE MOTORES DE COMBUSTÃO INTERNA A PISTÃO ATRAVÉS DA RECONSTRUÇÃO DA PRESSÃO DOS CILINDROS POR MODELO NÃO LINEAR DE VIBRAÇÃO MECÂNICA, VELOCIDADE ANGULAR E ULTRASSOM



Dezembro de 2017

Sumário

1 ENTIDADES E EQUIPES EXECUTORAS	4
2 RESUMO EXECUTIVO	5
2.1 Objetivos do Projeto	5
2.2 Palavras Chave	6
2.3 Estudo de Anterioridade	6
2.4 Estado da Arte	7
2.5 Contribuição ao Estado da Arte	8
2.6 Originalidade do Produto ou Técnica	9
2.7 Abrangência da Aplicação	10
2.8 Testes de Funcionalidade	10
2.9 Contribuições e Impactos Econômicos	11
2.10 Contribuições e Impactos Tecnológicos	12
2.11 Contribuições Científicas	12
2.12 Contribuições e Impactos Socioambientais	14
2.13 Etapas e Cronograma de Execução	14
2.14 Recursos Empregados e Justificativas	15
2.15 Estudo de Viabilidade Econômica	16
3 DETALHAMENTO TÉCNICO DO PROJETO	18
3.1 Introdução	18
3.1.1 Falhas em Motores de Combustão Interna	18
3.1.2 Sinais para Monitoramento	20
3.1.3 Metodologia Proposta	22
3.2 Simulação dos Sinais	23
3.2.1 Sinal de Velocidade angular	28
3.2.2 Correlação artificial entre os sinais	29
3.2.3 Modelos Clássicos de Regressão	31
3.2.4 Simulação de resultados	32
3.3 Sistema de Aquisição	35
3.3.1 Sensores	35
3.3.2 Tratamento do sinal analógico	36
3.3.3 DAQ	36
3.4 Ensaios no Laboratório	37
3.4.1 Base do motor	38
3.4.2 Motor monocilíndrico MWM	38

3.4.3	Motor Yanmar	39
3.4.4	Motor Sulzer	42
3.4.5	Ensaio Elétrico do Gerador	43
3.4.6	Teste do Motor Sulzer	45
3.4.7	Ensaio do Motor Sulzer com Variação de Carga	48
3.4.8	Ensaio para Aquisição dos Sinais	54
3.5	Tratamento dos Sinais e Modelos Clássicos	55
3.5.1	<i>Slicing</i> dos sinais	55
3.5.2	Preparo do Sinal de Pressão	56
3.5.3	Preparo do Sinal de Aceleração	57
3.5.4	Treinando os Modelos	60
3.5.5	Medida de Desempenho	62
3.5.6	Resultados	63
3.6	Ensaios na Bancada	65
3.6.1	Configuração e Montagem da Bancada	65
3.6.2	Sinal de aceleração e rotação	66
3.6.3	Adaptação da Bancada para medir Pressão	67
3.6.4	Régressão do Sinal de Pressão	70
3.6.5	Simulação de Falhas na Bancada	75
3.6.6	Diagnóstico de Falhas na Bancada	80
3.7	Ensaios em Campo - Gera Amazonas	84
3.7.1	Adaptação do Sensor de Pressão	84
3.7.2	Levantamento da Geometria dos Motores	86
3.7.3	Posicionamento do Tacômetro	86
3.7.4	Medições	88
3.7.5	Validação dos sinais medidos	91
3.7.6	Tratamento dos sinais e Modelos Clássicos	93
3.7.7	Resultados	95
3.8	Ensaios em Campo - Gera Maranhão	97
3.8.1	Levantamento da Geometria dos Motores	98
3.8.2	Posicionamento do Tacômetro	99
3.8.3	Medições	100
3.8.4	Tratamento dos sinais e Modelos Clássicos	105
3.8.5	Resultados	108
3.9	Redes Neurais Convolucionais	110
3.9.1	Estrutura da CNN	111
3.9.2	Convolução	111
3.9.3	Pooling	112
3.9.4	Régressão	112
3.9.5	Treinamento	112
3.9.6	Resultados	113
4	CONCLUSÃO	117
REFERÊNCIAS BIBLIOGRÁFICAS		122
A Artigo: CITENEL		123

B Artigo: CONEM	124
C Artigo: ENCIT	125
D Artigo: IJCNN	126
E Artigo: CSBC	127
F Artigo: Revista	128
G Patente	129
H Qualificação Doutorado	130

Capítulo 1

ENTIDADES E EQUIPES EXECUTORAS

- **Título do Projeto:** Análise da condição mecânica e termodinâmica de motores de combustão a pistão através da reconstrução da pressão por modelo não linear de vibração mecânica, velocidade angular e ultrassom.
- **Duração do Projeto:** 18 meses - aditivo de 12 meses
- **Segmento:** Geração
- **Fase de Inovação:** PA - Pesquisa Aplicada
- **Tipo de Produto:** SM - Sistema
- **Tema:** GT - Geração Termelétrica
- **Subtemas:** GT0X - Outro - Sugestão: Análises em motores alternativos de combustão interna para manutenção preditiva
- **Descrição do Produto:** Sistema de monitoramento de motores de combustão interna através de vibração mecânica
- **Código do Projeto:** PD-6492-0215/2015
- **Data de Início do Projeto:** Julho 2015
- **Entidade Proponente:** Geradora de Energia do Norte S/A
- **Entidades Executoras:** IX ESTUDOS E PROJETOS LTDA. - EPP
SEMEQ - SERVIÇOS DE MONITORAMENTO DE EQUIPAMENTOS LTDA
- **Coordenador:** Afonso Henriques Moreira Santos, iX Estudos e Projetos Ltda.
- **Gerente:** Marcelo Luiz de Carvalho Ribeiro, Gera Maranhão S/A
- **Valor Total do Projeto:** R\$2.025.883,46

Capítulo 2

RESUMO EXECUTIVO

2.1 Objetivos do Projeto

O projeto tem por objetivo implementar uma técnica de monitoramento da condição em motores de combustão interna, utilizando-se de sinais indiretos como vibração e rotação. Para implementação e validação desta técnica foi desenvolvido um sistema de aquisição das grandezas de entrada no modelo. O monitoramento contínuo de motores de combustão interna, usados em plantas de geração de energia, não só previne paradas inesperadas e consequentemente interrompimentos na geração elétrica, como também permite a detecção de anomalias no processo de combustão, que impactam diretamente no consumo de combustível e na emissão de poluentes do motor.

A medição direta por meio de transdutores de pressão possui várias desvantagens: custo do sensor é elevado e sua vida útil bastante reduzida, devido às condições extremas a que é submetido no interior da câmara de combustão. Além disso, depósitos no sensor ao longo do tempo diminuem a precisão dos sinais medidos pelos transdutores, impactando em sua eficiência no processo de monitoramento.

O uso de medições indiretas, como a vibração do bloco do motor, o sinal de velocidade angular ou o sinal de ultrassom, tem sido usado na literatura para o monitoramento de máquinas alternativas. Mas na prática, os equipamentos comumente utilizados, ou necessitam do transdutor de pressão, ou são necessárias condições específicas de operação, de filtros e tratamentos de pré ou pós-processamento dos sinais medidos.

Neste projeto, uma metodologia que envolve técnicas no estado da arte de inteligência artificial e aprendizado de máquinas são utilizadas para realizar a reconstrução do sinal de pressão. Sinais indiretos como vibração e rotação são usados como entrada para o modelo, que extrai automaticamente as características mais relevantes desses sinais para o processo. O sinal de pressão é então reconstruído, independente de condição de operação do motor. Esse sinal reconstruído pode então ser utilizado para a análise da condição e do funcionamento do motor, a um custo muito menor que qualquer sistema que se utilize de medições diretas de pressão, com vida útil prolongada do sistema, devido às medições indiretas utilizadas.

2.2 Palavras Chave

Monitoramento; Motor de Combustão Interna; Grupo Gerador; Vibração; Pressão;

2.3 Estudo de Anterioridade

Alguns projetos de P&D submetidos a ANEEL têm relação com este projeto. A seguir, é feita uma breve análise de anterioridade sobre cada um dos projetos propostos.

- O projeto [19] desenvolveu um software para avaliação da eficiência da combustão de termoelétricas, utilizando somente dados históricos de geração bruta de energia elétrica e combustível consumido. Não faz o monitoramento dos equipamentos, somente uma análise a posteriori.
- O projeto [34], define um sistema de monitoramento e diagnóstico capaz de auxiliar no gerenciamento das atividades de manutenção de centrais termelétricas. Neste trabalho, a condição de referência é estabelecida nas condições ISO com base em testes realizados na planta em operação, além de informações técnicas adicionais. Com isso, qualquer desvio nos parâmetros operacionais são identificados. No entanto, o sistema proposto, depende dos parâmetros já possíveis de monitoramento, o que não se aplica a pressão interna do cilindro.
- O projeto [37] define um sistema de monitoramento e diagnóstico utilizando-se somente de sinais acústicos para o monitoramento de motores de combustão interna. O sinal de emissão acústica é um dos sinais utilizados no estado da arte de monitoramento de máquinas alternativas, como pode ser visto na seção 2.4.
- O projeto [30] fez o desenvolvimento de um sistema preditivo para diagnóstico termomecânico de falhas em motores de combustão interna através da análise da assinatura elétrica dos sinais de tensão e corrente do gerador.
- O projeto [33] busca desenvolver uma ferramenta em forma de Skid móvel de monitoramento e diagnóstico das condições operacionais das unidades diesel geradoras. Assim como o projeto [34], o sistema proposto depende dos parâmetros já possíveis de monitoramento, o que não se aplica a pressão interna do cilindro.
- O projeto [32] visa nacionalizar uma plataforma de monitoramento de grupo geradores, através de uma arquitetura de software que possibilitaria o monitoramento remoto, de parâmetros de motores de combustão interna. Assim como os projetos [34] e [33], o monitoramento de parâmetros de pressão interna ao cilindro sofre das desvantagens da medição direta por meio de transdutores de pressão citadas anteriormente.

2.4 Estado da Arte

Medições indiretas têm grande potencial para o diagnóstico de motores e algumas metodologias foram apresentadas na literatura. Elas usam técnicas e sensores não intrusivos, como acelerômetros, sensores de ultrassom e tacômetros ao invés de transdutores de pressão. Estes sensores são montados externamente ao bloco do motor e detectam os eventos de combustão transmitidos às superfícies externas, como: abertura e fechamento de válvulas, injeção e queima do combustível e abrasões mecânicas.

A seguir, são apresentados os trabalhos publicados em periódicos nacionais e internacionais, além da análise de anterioridade de cada um deles. Os trabalhos estão agrupados por tipo de medição indireta utilizada para monitorar motor de combustão interna.

Emissão Acústica

Um método que usa o sinal de emissão acústica foi apresentado em [20]. O sinal de pressão interna ao cilindro é reconstruído em dois motores Diesel pequenos: um dois tempos e outro quatro tempos. Os resultados da reconstrução foram satisfatórios, tanto no domínio do tempo quanto no domínio da frequência (um modelo cepstrum foi utilizado). Porém, o trabalho conclui que o sinal de emissão acústica não apresenta uma resposta direta ao processo de combustão, uma vez que a extração da reconstrução para diferentes condições de carga e rotação não pode ser feita eficientemente somente usando esta fonte de sinal. Outro trabalho que usa sinais acústicos para a reconstrução da pressão interna dos cilindros é apresentado em [10], porém sinais de vibração foram utilizados em conjunto à emissão acústica para o diagnóstico da condição de motores de combustão interna.

Velocidade Angular

A variação da velocidade angular do virabrequim é também um sinal de medição indireta bastante importante para o monitoramento do processo de combustão. Em [11], uma Rede Neural Recorrente (*Recurrent Neural Network – RNN*) é proposta para a reconstrução do sinal de pressão. No entanto, é mostrado neste trabalho que uma única RNN não é capaz de reconstruir a pressão para todo o domínio de operação do motor, com relação a carga e rotação. O trabalho apresentado em [39], adapta um modelo não-linear para a velocidade angular, com o objetivo de detectar alguns parâmetros do processo de combustão, como o valor máximo de pressão e a posição relativa deste valor ao eixo. Em [36], a identificação de parâmetros de combustão também é realizada através do sinal de velocidade angular, porém uma Rede Neural MLP (*Multi-Layer Perceptron*) é utilizada. A técnica apresenta resultados promissores, porém não realiza a reconstrução do sinal de pressão como um todo.

Vibração no domínio do tempo

As técnicas mais tradicionais de monitoramento usam o sinal de vibração medido através de acelerômetros piezoelétricos montados no bloco do motor. Alguns trabalhos desenvolveram métodos que usam o sinal no domínio do tempo, como o trabalho apresentado em [14]. Este trabalho estima alguns parâmetros de combustão (pico máximo de pressão e sua posição relativa). Em [18], a estimativa dos parâmetros de combustão é feita utilizando-se apenas de um único acelerômetro em um motor a diesel multicilíndrico. Já em [40], o sinal de pressão interno do cilindro é reconstruído usando o sinal de aceleração no domínio do tempo, através de uma Função de Transferência de Vibração (*Vibration Transfer Function* – VTF). Todos esses trabalhos citados, mostram que o sinal de vibração contém informação sobre o processo de combustão. No entanto, todos necessitam de alguma forma de pré ou pós-processamento para extrair os componentes relacionados a combustão ou para melhorar a relação de sinal-ruído da vibração medida.

Vibração no domínio da frequência

Outro método para realizar a reconstrução do sinal de pressão é através da utilização de Função de Resposta em Frequência (*Frequency Response Function* – FRF). Em [24], conclui-se que uma FRF pura não gera uma aproximação precisa para o sinal de pressão interna do cilindro, porém a combinação da FRF proposta com um algoritmo de Otimização por Enxame de Partículas (*Particle Swarm Optimization* – PSO) trouxe resultados mais próximos ao sinal de pressão esperado.

Redes Neurais

Redes Neurais baseadas em Funções de Base Radial (*Radial Basis Function* – RBF) também são usadas com sucesso na literatura para a reconstrução do sinal de pressão e para a estimativa de parâmetros de combustão. Alguns trabalhos como [13, 12, 26, 25], tiram vantagem dos modelos não lineares propostos por redes neurais RBF. Apesar da alta precisão obtida, na maioria dos casos são necessários grandes conjuntos de treino, em diferentes condições de rotação e carga, para que as redes sejam treinadas e consigam realizar bem o processo de reconstrução para as mais diversas condições de operação. Esses grandes volumes de dados também devem ser filtrados e pré ou pós-processados, para otimizar a resposta de aprendizado das redes utilizadas.

2.5 Contribuição ao Estado da Arte

Os equipamentos de monitoramento de motores de combustão interna utilizados no mercado necessitam do transdutor de pressão para a análise do processo de combustão, impossibilitando a tomada continua de medições dos equipamentos e seu monitoramento constante. Este trabalho visa demonstrar na prática as aplicações de medições indiretas de sinais como a vibração e da rotação do equipamento para reconstruir esse sinal de pressão utilizado para o monitoramento do processo de combustão.

Além disso, este trabalho aplica técnicas de *Deep Learning*, mais precisamente a aplicação de Redes Neurais Convolucionais (*Convolutional Neural Networks – CNN*) para a reconstrução da pressão interna dos cilindros usando diretamente o sinal de vibração no domínio do tempo.

Redes Neurais Convolucionais têm recebido atenção crescente em trabalhos recentes, como uma ferramenta robusta e eficiente para a extração de características de sinais utilizados para o monitoramento de condição de equipamentos. Em [17], falhas em redutores são classificadas usando uma CNN que aprende a partir de um conjunto de 256 características pré-determinadas do sinal de vibração. Em [23], é realizada a detecção de falhas em equipamentos rotativos através do sinal de vibração, porém, convertidos no domínio da frequência. Em [22], uma CNN é treinada diretamente com sinais de vibração no domínio do tempo para a detecção de falhas em motores elétricos. Todos esses trabalhos apresentam resultados que superam estratégias clássicas de extração de requisitos.

Os resultados obtidos da literatura mostram que os métodos baseados em vibração são eficientes para a reconstrução do sinal de pressão interna dos cilindros. Já trabalhos mais recentes, mostram que características representativas podem ser extraídas automaticamente de dados brutos de vibração. Isso evita a extração e seleção manual de atributos, que possui forte dependência de conhecimento prévio ou de condições específicas de funcionamento dos motores, como rotação e carga. A contribuição deste trabalho é a utilização de Redes Neurais Convolucionais para a reconstrução do sinal de pressão, utilizando-se dos sinais brutos de vibração, independente das condições de operação do motor de combustão a ser monitorado.

2.6 Originalidade do Produto ou Técnica

Tem crescido o número de aplicações e de pesquisas envolvendo ferramentas de aprendizado profundo de máquinas, com resultados que superam abordagens clássicas para uma grande gama de problemas na literatura. A aplicação dessas técnicas no problema de reconstrução do sinal de pressão interna do cilindro para motores de combustão se mostra original na literatura, com vantagens em relação às principais metodologias empregadas até então, como pode ser visto nos resultados da seção 3.9. Esta abordagem não só simplifica o processo de reconstrução do sinal de pressão, como também o torna mais robusto e menos suscetível a variações das condições operacionais.

Portanto, a originalidade da técnica empregada consiste na aplicação de ferramentas de inteligência artificial para a reconstrução do sinal de pressão. Mais precisamente, na utilização de algoritmos de *Deep Learning* diretamente nos sinais brutos de vibração extraídos diretamente do acelerômetro, deixando a cargo da ferramenta o aprendizado a extração das melhores características expressas no sinal, relativas ao processo de combustão.

O modelo de *Deep Learning* utilizado é o algoritmo de Rede Neural Convolucional (CNN), apresentado em maiores detalhes na seção 3.9. Os filtros e parâmetros/pesos da rede são inicializados com valores aleatórios. A rede recebe um sinal de vibração como entrada, aplica os filtros e pesos aleatórios e gera um sinal de pressão, que por consequência, será aleatório a princípio. O erro de aproximação do sinal ge-

rado com relação ao sinal esperado de pressão, é usado para o reajuste dos pesos e parâmetros da CNN. Com uma boa amostragem de sinais de vibração e pressão apresentados, após algumas rodadas de aprendizado, a rede será capaz de generalizar a reconstrução do sinal de pressão para novos sinais de vibração.

A técnica proposta, de reconstrução do sinal de pressão, usando sinais indiretos de vibração e rotação, viabiliza o monitoramento contínuo do motor. Isso pois os sensores utilizados são economicamente mais viáveis que o transdutor de pressão. Além disso, o fato dos acelerômetros e tacômetros serem instalados externamente no bloco do motor, faz com que tenham vida útil extremamente maior que o sensor de pressão. O monitoramento contínuo traz uma série de contribuições, relatadas nas seções 2.9 e 2.12.

Como um produto secundário do projeto, foi desenvolvido um sistema de aquisição, capaz de medir simultaneamente os sinais de vibração, rotação e pressão. Os sinais utilizados nos ensaios em laboratório e em campo foram aquisitados através deste equipamento, capaz de medir um cilindro por vez, sincronizando as medições com a rotação do motor, medida através do tacômetro e da marcação de referência feita no volante de inércia. O equipamento portátil desenvolvido no projeto é apresentado com maiores detalhes na seção 3.3.

2.7 Abrangência da Aplicação

A metodologia desenvolvida, que realiza a reconstrução do sinal de pressão interna do cilindro usando sinais indiretos de vibração e rotação, pode ser aplicada a diversos tipos de motores de combustão interna.

Neste projeto, a técnica foi desenvolvida para o monitoramento dos 38 motores Wärtsilä W20V32 instalados na Usina Gera Maranhão. São motores de 20 cilindros cada, com capacidade de geração individual de 8,73MW. A planta como um todo possui capacidade total de geração de 331,74MW.

No entanto, metodologia pode ser aplicada, sem perda de generalidade, a outros motores. Na seção 3.7 é demonstrada a reconstrução do sinal de pressão nos motores instalados na usina Gera Amazonas. Nesta usina, estão instalados 5 motores Wärtsilä W18V46 de 18 cilindros, com potência de 17,076MW cada. A planta no geral possui uma capacidade de 85,4MW.

Além dos motores de grande porte testados, motores menores, como o grupo gerador instalado no laboratório hidrodinâmico da Universidade Federal de Itajubá (Unifei) e a bancada de teste de simulação de falhas também mostraram que a metodologia tem aplicação para diversos tipos de motores de combustão.

2.8 Testes de Funcionalidade

A aplicação da metodologia proposta neste projeto, é demonstrada através de três etapas de testes de funcionalidade, descritas a seguir.

A primeira etapa será a aplicação do processo de reconstrução do sinal de pressão usando sinais de vibração e rotação para um motor de pequeno porte (bi-cilíndrico),

de cerca de 40cv apenas. Este motor é de um grupo gerador instalado no laboratório de hidromecânica da Universidade Federal de Itajubá.

Neste primeiro teste de funcionalidade, poderemos explorar a possibilidade de rodar alternadamente o motor com apenas um cilindro em funcionamento, ou com os dois cilindros em funcionamento. Além disso, é possível controlar para este motor, a carga aplicada, fazendo com que o gerador alimente uma das bombas de vazão do laboratório. De acordo com a vazão, podemos alterar a carga submetida ao gerador.

Na segunda etapa, a funcionalidade da proposta é testada em uma bancada de simulação de falhas, que simula o funcionamento mecânico de um motor a combustão. Esta etapa é importante para o estudo da influência de outras fontes de vibração independentes do processo de combustão no funcionamento do modelo de reconstrução do sinal de pressão proposto.

Posteriormente, os ensaios em campo são executados para a comprovação do funcionamento e aferição da eficácia dos modelos propostos de reconstrução. Nestas etapas, é simulado o funcionamento na prática da metodologia proposta e testada nas etapas anteriores em laboratório.

Por fim, com os dados medidos em campo e os resultados obtidos através dos modelos clássicos, foi possível desenvolver e testar novos algoritmos para realizar a reconstrução do sinal de pressão, como o de rede neural convolucional. Comparando os resultados com os modelos clássicos, pode-se observar e dimensionar as contribuições da metodologia proposta, no que diz respeito a eficiência do processo de reconstrução, assim como sua robustez para diversas condições de operação do motor.

2.9 Contribuições e Impactos Econômicos

Um bom transdutor de pressão, tem um custo médio de 2000 euros, enquanto um acelerômetro de boa qualidade não chega a custar 100 dólares. Além da diferença de custo entre os sensores, a principal desvantagem de um sistema de monitoramento que utilize de medições diretas de pressão é a limitada vida útil do transdutor, uma vez que este deve ter acesso a câmara de combustão, ou seja, sujeito a altíssimas temperaturas.

A baixa durabilidade desse tipo de sensor, impede o monitoramento contínuo de motores de combustão de grande porte. O que impacta severamente na capacidade de se detectar anomalias em seu funcionamento.

O monitoramento contínuo, ajudaria a prevenir paradas inesperadas no funcionamento de um determinado grupo gerador, o que, em casos extremos, evitaria grandes avarias e altos custos de manutenção. Além de evitar paradas inesperadas, o monitoramento permite a detecção adiantada de falhas, ainda em processo inicial, e o acompanhamento da evolução dessa falha, pode sugerir o melhor momento de uma intervenção, diminuindo custos de manutenção através de paradas planejadas do equipamento.

As medidas citadas teriam um grande impacto econômico no custo de manutenção dos motores. No entanto, além do custo de manutenção, a identificação de falhas relacionadas ao processo de combustão também possuem influência direta com a eficiência do motor, no que diz respeito ao seu consumo de combustível e emissão

de poluentes. Através do monitoramento da curva de pressão, é possível identificar a temporização dos eventos de abertura e fechamento de válvulas, de injeção de combustível e de vazamentos devido a desgastes internos no cilindro. Todos esses parâmetros, poderiam ser monitorados continuamente, e qualquer desvio do funcionamento esperado, poderia ser identificado, otimizando o consumo de combustível do motor.

2.10 Contribuições e Impactos Tecnológicos

A principal contribuição tecnológica atrelada ao projeto é a viabilização do monitoramento contínuo do processo de combustão de motores de combustão interna. A metodologia proposta não necessita do transdutor de pressão diretamente instalado nos pontos de inspeção do motor, mas sim de acelerômetros e tacômetros que podem ser fixados externamente ao bloco do motor.

Os equipamentos de mercado utilizados para medição de motor de combustão interna possuem um transdutor de pressão combinado com o sinal do acelerômetro e do tacômetro. Cada cilindro deve ser medido separadamente, com o sinal de rotação sincronizando as medições. A metodologia proposta, permitiria a instalação de um acelerômetro por cilindro, mais um tacômetro e essa instrumentação seria suficiente para o monitoramento contínuo.

Com a evolução da tecnologia, hoje já podemos considerar que vivemos na quarta revolução industrial, de internet das coisas. Nesse sentido, a metodologia desenvolvida para este projeto vai de encontro essa nova tendência mundial de tecnologia. O trabalho apresentado possibilita em um sistema futuro, o desenvolvimento de sensores de vibração sem fio, sincronizados com um sensor de rotação, realizando medições em todos os cilindros e transmitindo as informações do processo de combustão continuamente para um dispositivo concentrador. Este dispositivo, na presença de uma conexão com a rede poderia informar em uma cadênciaria determinada, cada um dos parâmetros importantes para o controle do processo de combustão, como temporizações de válvulas; valor e posição relativa ao eixo de cada pico de pressão em cada cilindro; entre outros.

2.11 Contribuições Científicas

A principal contribuição científica, além das vantagens práticas da metodologia desenvolvida, descrita nas seções anteriores, é a aplicação de técnicas de Inteligência Artificial, mais especificamente de *Deep Learning*. Têm sido crescente a utilização de algoritmos dessa área principalmente para problemas de visão computacional, processamento de linguagem natural, previsão de séries temporais. Nessas áreas, algoritmos como Convolutional Neural Networks (CNN), utilizado neste projeto, tem tido bastante destaque se comparado a metodologias clássicas de aprendizado de máquinas, principalmente no tratamento de imagens, e sinais com alta dimensionalidade.

Dada a interdisciplinaridade inerente ao projeto, os resultados obtidos estão sendo submetidos a congressos e revistas tanto com foco em mecânica quanto em

computação. A pesquisa realizada no projeto se mostra potencialmente inovadora em ambas as áreas e por isso, estão sendo submetidos artigos nos seguintes congressos:

- IX Congresso de Inovação Tecnológica em Energia Elétrica (CITENEL), 2 a 4 de agosto de 2017, João Pessoa, PB, Brasil. Título: “Reconstrução da pressão dos cilindros em motores de combustão interna por modelos não lineares de vibração mecânica”, (o artigo submetido pode ser visto no apêndice A). A submissão foi realizada em janeiro de 2017, antes dos ensaios em campo. Sem os resultados obtidos na prática, somente com o desenvolvimento teórico, o artigo acabou não sendo aceito.
- X Congresso Nacional de Engenharia Mecânica (CONEM), 20 - 24 de maio de 2018, Salvador, BA, Brasil – Título: “Reconstrução da pressão interna do cilindro em motores de combustão usando vibração e redes neurais convolucionais”, (o resumo estendido submetido pode ser visto no apêndice B).
- 17th Brazilian Congress of Thermal Sciences and Engineering (ENCIT), 25 - 28 de novembro de 2018, Águas de Lindóia, SP, Brasil – Título: “Reconstrução da pressão interna do cilindro em motores de combustão via medições indiretas como vibração e rotação”, (o artigo submetido pode ser visto no apêndice C).
- 2018 International Joint Conference on Neural Networks (IJNN), 8 – 13 de Julho de 2018, Rio de Janeiro, RJ, Brasil – Título: “In-cylinder pressure reconstruction using vibration measurements and deep Convolutional Neural Networks”, (o artigo submetido pode ser visto no apêndice D).
- XXXVIII Congresso da Sociedade Brasileira de Computação, 22 – 26 julho de 2018, Natal, RN, Brasil. Título: “Reconstrução da pressão interna do cilindro em motores de combustão via Redes Neurais Convolucionais”, (o artigo submetido pode ser visto no apêndice E).

Além da submissão dos artigos para os congressos citados, também está sendo submetido um artigo para uma revista internacional, com grande fator de impacto no meio acadêmico:

- Mechanical Systems and Signal Processing, ISSN 0888-3270 – Título: In-cylinder pressure reconstruction using vibration measurements and deep Convolutional Neural Networks”, (o artigo submetido pode ser visto no apêndice F).

O trabalho também será inserido em um capítulo da tese de doutorado cujo título é: “Deep Learning: Redes Neurais Convolucionais aplicadas ao diagnóstico de falhas mecânicas”, do aluno Amaury B. André, sob a orientação do prof. dr. Jacques Wainer, no Instituto de Computação da Unicamp. A qualificação está marcada para o início de março de 2018.

Também foi dada entrada no pedido de patente para o processo de monitoramento desenvolvido neste projeto. No apêndice G é possível ver o texto da patente, juntamente com o fluxograma do processo requerido.

2.12 Contribuições e Impactos Socioambientais

O monitoramento contínuo do processo de combustão em grupo geradores tem por finalidade mitigar riscos de quebras nos equipamentos. Uma quebra em um equipamento deste porte poderia significar um grande risco à segurança da população local. Além da segurança, a parada da geração de energia traz diversos impactos socioambientais, prejudicando o dia a dia da população abastecida pela energia gerada no parque da usina.

O consumo e a emissão de poluentes também é afetado diretamente pelo processo de combustão do grupo gerador. O monitoramento dos parâmetros deste processo, como temporizações de abertura e fechamento de válvulas, de injeção de combustível, de vazamentos devido a desgastes, entre outros, permite a detecção de anomalias possibilitando uma redução do consumo de óleo combustível. Uma diminuição do consumo, que é algo em torno de 42 toneladas por dia de operação do motor, já é por si só de grande impacto ambiental. Porém, além desse impacto direto, há um outro fator importante a se considerar. O óleo combustível é abastecido na usina Gera Maranhão através de cerca de 40 caminhões-tanque por dia, trafegando do porto no litoral do Maranhão, até a usina, num trajeto de aproximadamente 135 quilômetros. Ao melhorar a eficiência do motor, diminui-se também o tráfego de caminhões na rodovia, consumindo menos combustível, emitindo menos poluentes, além de diminuir o movimento e o risco de acidentes na rodovia.

2.13 Etapas e Cronograma de Execução

Na figura 2.1 a seguir, é possível ver as etapas realizadas e o cronograma de execução.

Figura 2.1: Cronograma de execução das atividades.

Como pode-se notar do cronograma, houve um hiato no projeto entre janeiro e julho de 2017. Nesse período, deveriam estar ocorrendo as medições de motores de grande porte na usina Gera Maranhão. No entanto, a usina não entrou em operação por todo esse período, tendo retomado seu funcionamento somente para o segundo semestre de 2017. Por isso o atraso nas etapas faltantes.

2.14 Recursos Empregados e Justificativas

Tabela 2.1: Equipamentos e custos

Equipamentos	Custo (R\$)
Sistema de aquisição de dados – 32 canais	10.897,46
Sistema de acondicionamento de Sinal Analógico	
Sensor de Pressão (alta)	14.693,00
Sensores de Pressão (baixa)	15.231,29
MG-2010 Basic Machinery Fault Simulator Magnum System	357.540,40
Ad-on reciprocating engine block packing for MFS Magnum	176.122,05
Analisador de performance de maquinas alternativas (Windrock - Modelo 6320/PA)	354.000,00
Total	928.484,20

Os principais recursos foram empregados no desenvolvimento do sistema de aquisição e na compra dos transdutores necessários, na reforma do motor Sulzer do laboratório hidromecânica na Universidade Federal de Itajubá, na compra da bancada de simulação de falhas mecânicas e na compra de um equipamento de monitoramento de motores de combustão típico do mercado.

O sistema de aquisição e os transdutores são essenciais para a medição dos sinais utilizados para o desenvolvimento da pesquisa de reconstrução do sinal de pressão através de sinais de vibração e rotação do motor. Para a validação desses sinais aquisitados através do sistema desenvolvido, o equipamento de monitoramento de motores de combustão típico do mercado se faz necessário. Com ele foi possível validar as curvas de pressão medidas nos equipamentos de grande porte, garantindo que os sinais estavam condizentes e que os resultados obtidos teriam aplicação prática no mercado.

A reforma do motor Sulzer é de suma importância para pesquisa, uma vez que possibilita o desenvolvimento do modelo de reconstrução em um ambiente mais controlado. Por ser um motor de dois cilindros, porém com a possibilidade de operar com apenas um cilindro por vez, o motor Sulzer do laboratório hidromecânica da Universidade Federal de Itajubá permite estudar os fenômenos de combustão isoladamente em cada cilindro, além da influência de um cilindro sobre o outro. A possibilidade de variar a carga no motor, através da alimentação de uma das bombas do laboratório, também facilitam o desenvolvimento dos modelos, antes da fase das medições em campo, em motores de grande porte.

A bancada de simulação de falhas, tem papel inverso ao motor Sulzer do laboratório de Itajubá. No motor o objetivo é isolar o processo de combustão para iden-

tificar como se relacionam os sinais de pressão e vibração. Na bancada de simulação de falhas, o objetivo é o contrário. Ao invés de isolar o processo de combustão, adicionar o máximo de elementos mecânicos com e sem falhas para identificar o quanto essas vibrações influenciariam no modelo de reconstrução da pressão proposto.

Os ensaios no motor Sulzer de Itajubá, aliado aos ensaios da bancada de simulação de falhas, tornaram robusto o modelo de reconstrução do sinal de pressão. A comparação dos sinais com um equipamento típico de mercado validam os sinais utilizados como entrada no modelo. Devido aos recursos empregados nessas etapas, pode-se considerar os resultados válidos, robustos e aplicáveis na prática do monitoramento de motores de combustão.

2.15 Estudo de Viabilidade Econômica

A viabilidade econômica do projeto pode ser analisada sob várias perspectivas. A primeira delas é com relação ao custo de instrumentação para o monitoramento dos grupo geradores. Considerando um valor médio de 2000 dólares para o transdutor de pressão, dado que cada motor possui 20 cilindros e são ao todo 38 motores no parque de geração da usina Gera Maranhão, o custo total de instrumentação ultrapassaria 1,5 milhão de dólares. Considerando os resultados apresentados neste projeto, possibilitando a substituição deste sensor por acelerômetros de vibração, que custam até 200 dólares no máximo, o custo de instrumentação cairia para algo em torno 150 mil dólares. Essa redução de custo já é mais que o suficiente para proporcionar o retorno sobre o investimento no projeto de pesquisa e desenvolvimento descrito nesse relatório, cujo custo total é de 1,2 milhão de reais, algo em torno de 360 mil dólares.

Além do custo de instrumentação, a vida útil do sistema de monitoramento usando sensores de vibração é bem maior. Isso possibilitaria o retorno do investimento antes da degradação do sistema, o que não seria possível acontecer utilizando transdutores de pressão.

O retorno do investimento do sistema de monitoramento também se dá por caminhos distintos. O primeiro seria na detecção de qualquer falha mecânica. Uma vez possível o monitoramento contínuo do motor, qualquer desvio de funcionamento que ocasionaria uma falha inesperada e consequentemente uma parada não programada do equipamento pode ser evitada. Uma quebra impactaria em grandes gastos de manutenção e em possível parada no fornecimento de energia.

Além de evitar paradas não programadas, o monitoramento contínuo do processo de combustão poderia identificar mais eficientemente desvios de temporização de abertura e fechamento de válvulas, de injecção de combustível e de vazamentos devido a desgastes em anéis, o que impacta diretamente no consumo de combustível. Para fazer uma estimativa, assumindo que o consumo fosse reduzido em um centésimo e para um único motor da usina Gera Maranhão, podemos fazer a seguinte conta:

Dado que o consumo diário da planta é de cerca de 1600 toneladas de óleo combustível, para 38 motores, cada motor consome em média 42 toneladas por dia. A densidade específica do óleo combustível utilizado (OCB1) é de $0,98\text{g}/\text{cm}^3$

¹. Portanto o consumo de um motor é de cerca de 43 mil litros por dia. Um centésimo disso, equivaleria a 430 litros por dia. Dado o custo de 1,8 dólares por galão (de 3,8 litros) ², a economia seria em torno de 203 dólares por dia. Com um centésimo de aumento da eficiência, para um único motor, o retorno do investimento de instrumentação se daria após 1 ano e 10 meses.

¹<http://www.abq.org.br/cbq/2015/trabalhos/4/8288-21602.html> – Acessado em dez/2017

²<http://www.indexmundi.com/pt/pre%E7os-de-mercado/?mercadoria=%c3%b3leo-combust%c3%advel&meses=60> – Acessado em dez/2017

Capítulo 3

DETALHAMENTO TÉCNICO DO PROJETO

3.1 Introdução

O diagnóstico de motores de combustão interna passa fundamentalmente pela análise das curvas de pressão interna dos cilindros. No entanto, outros sinais são possíveis de serem monitorados. Através destes sinais podemos identificar grande parte dos desvios de funcionamento em motores deste tipo. Nas seções que seguem, iremos apresentar as principais falhas detectáveis em motores de combustão interna e como essas falhas afetam seu funcionamento, além de uma descrição dos sinais possíveis de monitoramento.

3.1.1 Falhas em Motores de Combustão Interna

Um motor de combustão interna pode ser dividido em vários subsistemas [28], sendo os principais: sistema de injeção de combustível; pistões e anéis de segmento; sistemas de admissão e exaustão de gases; sistema de lubrificação; mancais (bronzinas); bloco, cabeçote, cilindro e buchas.

Na tabela 3.1 são apresentadas as probabilidades de falhas colhidas na literatura para motores de combustão interna a Diesel:

Para um bom diagnóstico de falhas em motores de combustão interna, é necessário conhecer sobre o processo e os mecanismos de falhas do motor. As falhas mais comuns que podem ocorrer devido a degradação ou mal funcionamento dos subsistemas de um motor são:

Perda de potência

Potência é um parâmetro fundamental no bom funcionamento de um motor. As suas causas podem estar ligadas diretamente ao processo de combustão nos pistões, seja por temporização incorreta, problema no sistema de injeção entre outros.

Componente	Ocorrência (%)
Mancais (bronzina)	24,4
Pistões - Anéis	19,4
Bloco, Cabeçote, Cilindro, Buchas	16,7
Eixo de manivelas	6,1
Válvulas	5,6
Tuchos, varetas, balancins	4,4
Sistema de Lubrificação	2,2
Eixo de Came	2,2
Carcaça	1,7
Acoplamentos	1,7
Outros	15,6
Total	100,0

Tabela 3.1: Distribuição estatística de falhas em cada um dos principais componentes de motores de combustão

Alteração de emissões

Exaustão de gases tem chamado cada vez mais a atenção no que tange motores de combustão, devido a atenção cada vez maior com relação aos impactos ambientais produzidos. A grande presença de fumaça na exaustão de gases se deve a um mal funcionamento ou a um desajuste no sistema de combustão.

Falha de lubrificação

Os principais problemas de lubrificação em motores é decorrente da pressão incorreta no sistema de lubrificação, ou da própria degradação do óleo. Degradação do óleo pode ocorrer por contaminação, ou por acúmulo de partícula decorrente do desgaste de materiais do motor, alterando assim a viscosidade e a capacidade de lubrificação de suas partes móveis.

Ruído e vibração

Outra gama de falhas perceptíveis em motores é a presença de ruídos ou vibrações excessivas. As causas podem ser oriundas de problemas mecânicos, do processo de combustão ou do processo de admissão e exaustão de gases.

Desgaste

Desgaste pode ocorrer por corrosão ou abrasão de partes mecânicas. Podem ocorrer nos mais diversos elementos mecânicos móveis dentro do motor, porém o desgaste mais impactante na disponibilidade do motor, acontece nos anéis de segmento do pistão.

Sobrecarga Térmica

Muitas das falhas citadas pode ocasionar um aumento da temperatura dos cilindros, ocasionando corrosão em componentes internos, aparecimento de trincas, rompimento do filme de óleo lubrificante, e emissão excessiva de gases.

Vazamentos

Os vazamentos podem ocorrer no sistema de injeção de combustível, alterando assim o processo de combustão; no sistema de lubrificação, ocasionando as falhas vinculadas a este sistema; e no sistema de admissão e exaustão de gases.

Outras falhas

Outras falhas que podem acontecer em motores de combustão interna são: problemas nos filtros; contaminação do combustível; aeração; formação de borras; entre outras.

3.1.2 Sinais para Monitoramento

As grandezas que podem ser aferidas, assim como os sinais que podem ser aquisitados e usados como base dos sistemas de monitoramento de motores de combustão propostos na literatura e utilizados na indústria, são apresentados nesta seção. Na tabela 3.2, podemos observar os subsistemas, suas falhas mais características e os sinais de monitoramento mais usados.

Subsistema	Falhas	Sinais Medidos
Injeção	temporização incorreta pressão incorreta injeção vazamento obstrução ou erosão de válvulas	pressão injeção vibração
Pistão, cilindro, anéis	falha na ignição passagem de gases (blow-by) batidas arrancamento falha nos anéis perda de potência	velocidade angular pressão cilindro pressão óleo pressão injeção temperatura vibração
Lubrificação	pressão incorreta óleo temperatura alta do óleo contaminação do óleo degradação do óleo	pressão óleo temperatura viscosidade acidez contagem de partículas vibração
Admissão e Exaustão	bloqueio do filtro vazamento emissão excessiva	fumaça vibração

Tabela 3.2: Sinais e falhas detectadas por subsistema de motores de combustão interna

Os sinais de pressão de injeção, pressão de óleo, temperatura e fumaça, são grandezas medidas diretamente e estão intrinsecamente ligadas a falhas no motor. Já a tomada das grandezas de viscosidade, acidez e contagem de partículas em óleo lubrificante são realizadas através da coleta de amostra e análise laboratorial do óleo lubrificante. Entretanto, os sinais de pressão interna do cilindro, vibração e velocidade angular, são sinais que demandam tratamento e interpretação sofisticados, por isso atraem tanta atenção da literatura especializada. Nas seções que se seguem, é feita uma revisão da literatura, apresentando o estado da arte na manipulação e interpretação desses sinais, e estão direta e indiretamente relacionados com todos os subsistemas, como pode ser visto na tabela 3.2.

Pressão interna dos cilindros

A pressão interna no cilindro provê uma quantidade grande de informação a cerca do processo de combustão. Está diretamente relacionado com o processo de transferência de calor, formação de poluentes, consumo de combustível, vibração e carga mecânica. É o principal sinal de controle para motores, além do mais significativo para o monitoramento da condição desses equipamentos. Alguns exemplos de trabalhos que utilizam diretamente o sinal de pressão para o diagnóstico de condição de motores pode ser visto em [31], [35], [15].

Vibração

As mudanças bruscas de pressão no cilindro durante o processo de combustão geram uma gama de vibrações estruturais no motor. Essas vibrações portanto, carregam informações sobre o processo de combustão e podem ser medidas externamente no cabeçote ou até mesmo no bloco do motor. No entanto, devido a influência do caminho do sinal percorrido da fonte da vibração até a posição da aferição do sinal, a relação sinal ruído costuma ser baixa. Além disso, outros sinais de vibração, não relacionados ao processo de combustão, podem estar misturados no sinal aqui-sitado. Alguns trabalhos propõem ferramentas de diagnóstico de motores usando diretamente o sinal de vibração, como em [38] e [29].

Emissão acústica

Assim com o sinal de vibração, o sinal de emissão acústica também tem correlação com o processo de combustão, no entanto, por sua natureza, a emissão acústica monitora frequências mais altas que os sinal de vibração medidos por acelerômetros simples. Isso faz com que a relação de sinal-ruído nessas altas frequências seja melhor do que nos sinais de vibração. Alguns trabalhos utilizam-se dessa característica para diagnosticar falhas em motores de combustão interna, como em [21], [8], [9]. Essas aplicações no entanto, visam na maioria dos casos a detecção de falhas no sistema de injeção de combustível, e ou no sistema de admissão e exaustão de gases.

Velocidade angular

Quando há a explosão em um cilindro, o torque da combustão se torna maior que o torque externo, fazendo com que o virabrequim acelere. Quando o cilindro entra

em compressão, o torque diminui em relação ao torque externo, fazendo com que o virabrequim desacelere. Essa flutuação, portanto, contém informação relativa ao processo de combustão. Alguns trabalhos na literatura utilizam diretamente essa variação no diagnóstico de falhas em motores a combustão, como em [16].

3.1.3 Metodologia Proposta

Neste trabalho, serão utilizados sinais de medição indireta para a reconstrução do sinal de pressão interna dos cilindros. Sinais como vibração, velocidade angular e ultrassom são usados e, como demonstra a literatura, contêm informações sobre a pressão do cilindro, mas em regiões de frequência diferentes [27], portanto são informações complementares entre si.

Flutuações na velocidade angular vêm a partir do conteúdo de baixa frequência da pressão do cilindro, sendo assim, a medição de velocidade angular não é tão sensível quanto as vibrações estruturais às mudanças de pressão instantâneas. Em contrapartida, as medições de vibração no bloco do motor, sofrem de baixa razão sinal-ruído, tornando a reconstrução da fase de compressão e descompressão do processo de combustão com resultados incertos. Além disso, em ambos os casos, as relações entre a pressão do cilindro e a resposta de vibração e velocidade de rotação não é linear com as alterações e as condições de funcionamento.

Estes dois tipos de sinal medidos são usados como fonte de dados de entrada para um modelo não linear de aprendizado de máquinas, com o intuito de reconstruir o sinal de pressão dentro do cilindro. Vários modelos serão testados, com o intuito de se obter o que melhor se adapta ao problema proposto.

No entanto, como visto na seção 2.3, a maioria dos modelos precisa de uma etapa de pré ou pós-processamento dos sinais, seja para aumentar a relação sinal-ruído do sinal de vibração do bloco, ou para adequar o resultado a variações de carga e/ou rotação. Na figura 3.1 é possível observar as etapas propostas neste trabalho:

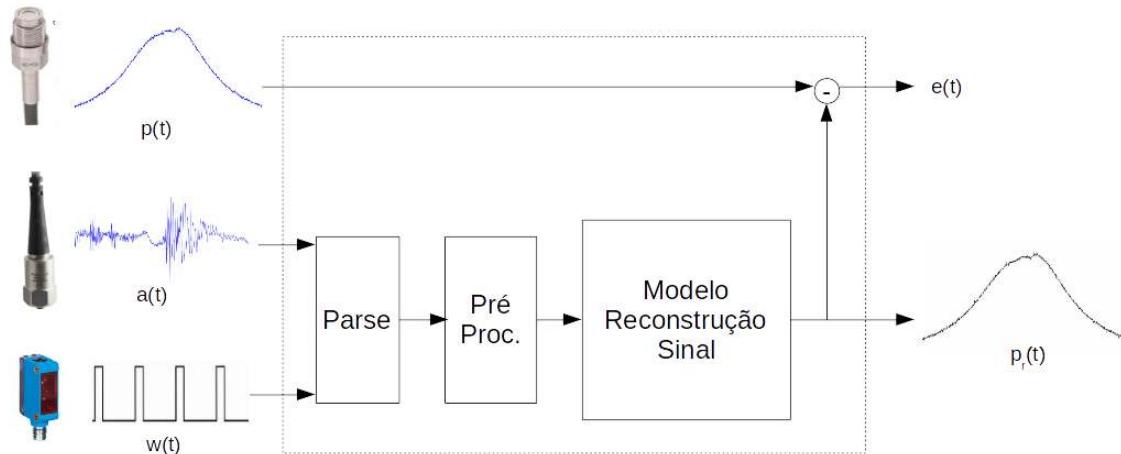


Figura 3.1: Metodologia proposta para reconstrução do sinal de pressão interna do cilindro

Na figura 3.1, são tomados como entradas $a(t)$ e $w(t)$, representando os sinais de vibração e rotação, medidos diretamente por acelerômetros e tacômetros, respectiva-

mente. Esses sinais passam por rotinas de Parsing do sinal, com o objetivo de dividir os sinais medidos em ciclos de combustão. E depois em rotinas de processamento de sinais para tratamento de ruído e realce de características.

Posteriormente, os sinais filtrados são passados para um dos modelos de reconstrução não linear, baseado em aprendizado de máquinas. Este modelo faz então a estimativa do sinal de pressão interna dos cilindros: $p_r(t)$. Esse sinal é comparado com o sinal real de pressão, medido nos motores instrumentados do laboratório e em campo, a fim de determinar o erro de aproximação $e(t)$ do sinal estimado.

As etapas de Parsing e Pré-processamento serão detalhadas na seção 3.5. No entanto, na seção 3.9 sobre redes neurais convolucionais, é possível observar que a etapa de pré-processamento não se faz necessária.

3.2 Simulação dos Sinais

Para gerar os sinais de vibração necessários e o sinal de pressão esperado, foi utilizado como modelo e inspiração os sinais utilizados no trabalho [27]. Os sinais no domínio do tempo que este trabalho utiliza são apresentados na figura 3.2.

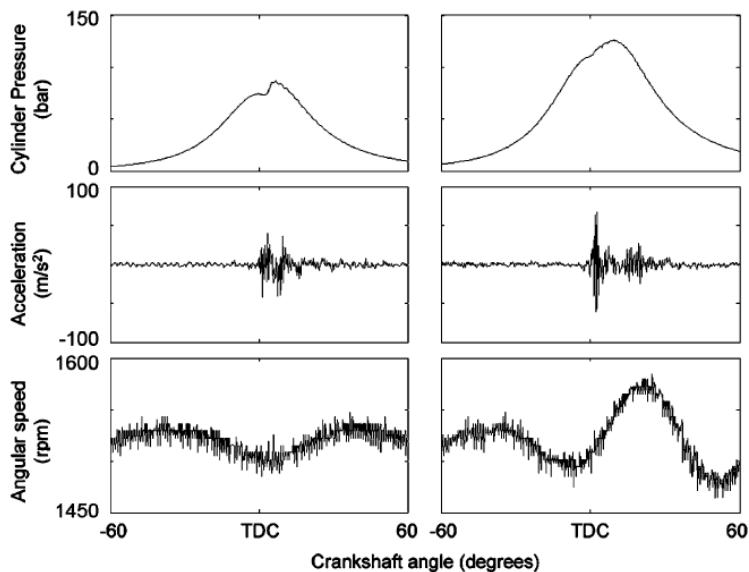


Figura 3.2: Ondas no tempo para os sinais de interesse

Na figura 3.2 pode-se observar os sinais de pressão do cilindro, de vibração estrutural do motor e de velocidade angular, para um motor a 1500 rpm com 25% e 75% de carga.

Ainda, pode-se observar através da figura 3.3 como os sinais de pressão variam de acordo com a rotação do motor e a carga aplicada.

Esses sinais servem de inspiração para a geração artificial dos sinais que serão utilizados para esta etapa preliminar do projeto, antes da aquisição de fato dos sinais reais nas bancadas em montagem.

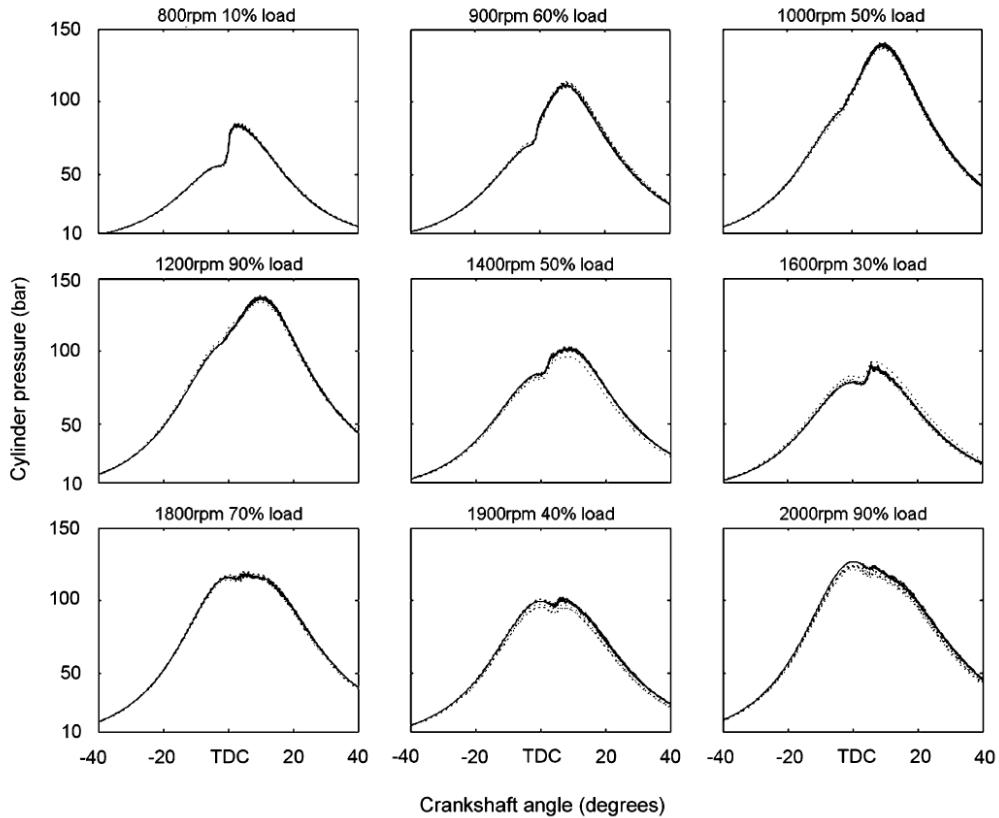


Figura 3.3: Curvas de pressão por rotação e carga do motor

Sinal de Pressão Artificial

Baseado nos sinais apresentados na figura 3.3, uma aproximação que se faz coerente é a aproximação destes sinais como sendo a soma de duas gaussianas com as médias ligeiramente deslocadas.

A função gaussiana é descrita através da seguinte formulação matemática 3.1, a partir de [4].

$$g(x) = \alpha e^{-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2} \quad (3.1)$$

Na equação 3.1, α representa o fator de amplitude da função, μ a média, ou seja, em torno de qual valor a função estará centrada (como pode ser visto na figura 3.4), e σ representa o valor de dispersão da curva.

A representação gráfica da função de Gauss pode ser vista na figura 3.4.

Assim o sinal de pressão artificial pode ser gerado, obtendo-se a seguinte formulação matemática:

$$g(x) = \alpha \left(e^{-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2} + \tau e^{-\frac{1}{2} \left(\frac{x - \mu + \varepsilon}{\rho\sigma} \right)^2} \right) \quad (3.2)$$

Nesta formulação, usamos ε como o deslocamento relativo entre as duas gaussianas.

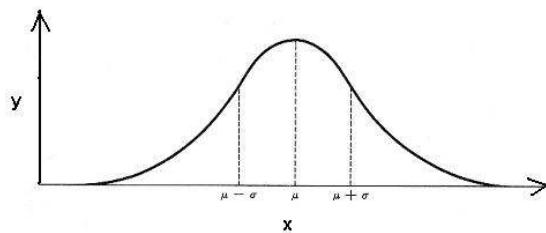


Figura 3.4: Função de Gauss

anas; ρ como um fator de proporção de dispersão e τ como um fator de proporção de amplitude entre as gaussianas; e por fim, é adicionado um ruído branco ao sinal, $rand()$, proporcional a 2% da amplitude das gaussianas modeladas.

Como resultado da equação 3.2, variando aleatoriamente os parâmetros descritos, as seguintes curvas artificiais de pressão puderam ser geradas, como pode ser visto na figura 3.5.

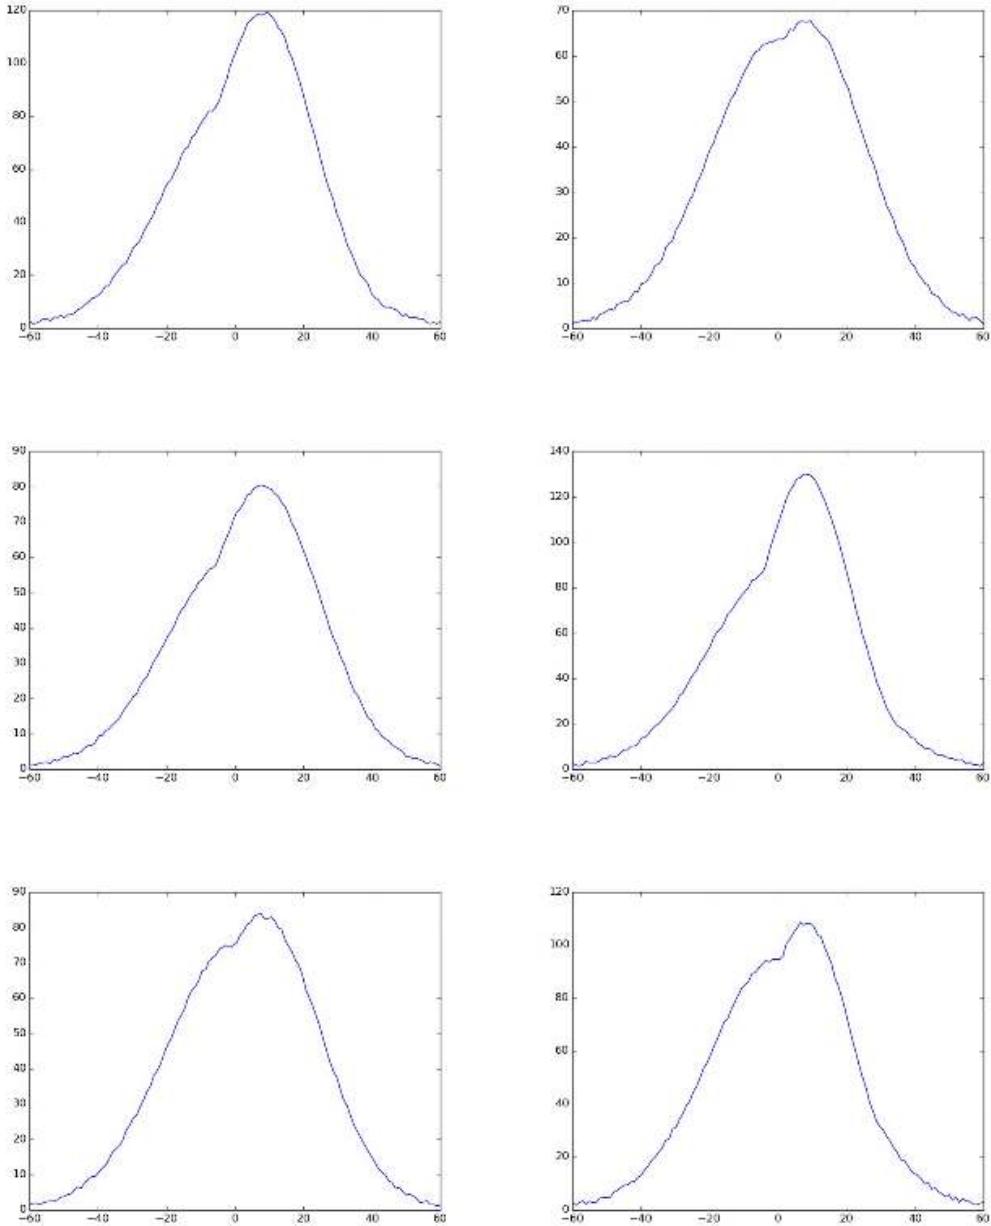


Figura 3.5: Curvas artificiais de pressão

Sinal de Vibração Artificial

Assim como o sinal de pressão, o sinal de aceleração pura foi inspirado nos sinais usados no trabalho [27]. Analisando a figura 3.2, intuiu-se que o sinal de aceleração pura poderia ser representado fundamentalmente por concatenações de uma função de *burst*, aqui modeladas por uma onda senoidal com decaimento exponencial [2], apresentada a seguir:

$$b(x) = e^{-\delta x} \cos(2\pi f(x/N)) \quad (3.3)$$

Nesta equação, δ representa o fator de decaimento da exponencial, f a frequência do cosseno e N o número de amostras total do sinal.

A representação gráfica da função “burst” apresentada pode ser vista na figura 3.6.

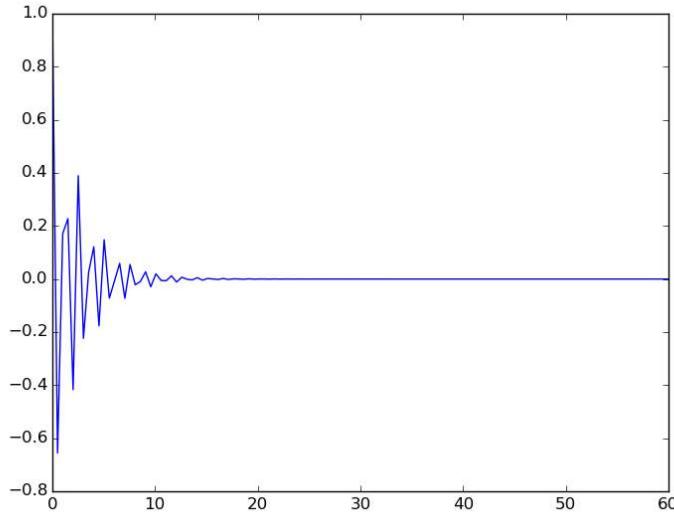


Figura 3.6: Função de ”burst”

Assim, o sinal de aceleração pura artificial foi modelado de acordo com a seguinte equação:

$$a(x) = \begin{cases} 0.8\alpha(0.04rand()), & \text{if } x \leq N/2 \\ 0.8\alpha(e^{-\delta(x-N/2)}b(x - N/2) + 0.04rand()), & \text{if } N/2 \leq x \leq 3N/4 \\ 0.8\alpha(e^{-\delta(x-3N/4)}b(x - 3N/4) + 0.04rand()), & \text{if } x > 3N/4 \end{cases} \quad (3.4)$$

Nesta equação, α representa a amplitude do sinal, $b(x)$ a função de “burst” descrita na equação 3.3, $rand()$ um ruído branco proporcional a 4% da amplitude do sinal calculado, e N o número de amostras da onda.

Como resultado da equação 3.4, variando aleatoriamente os parâmetros descritos, as seguintes curvas artificiais de aceleração pura puderam ser geradas, como pode ser visto na figura 3.7.

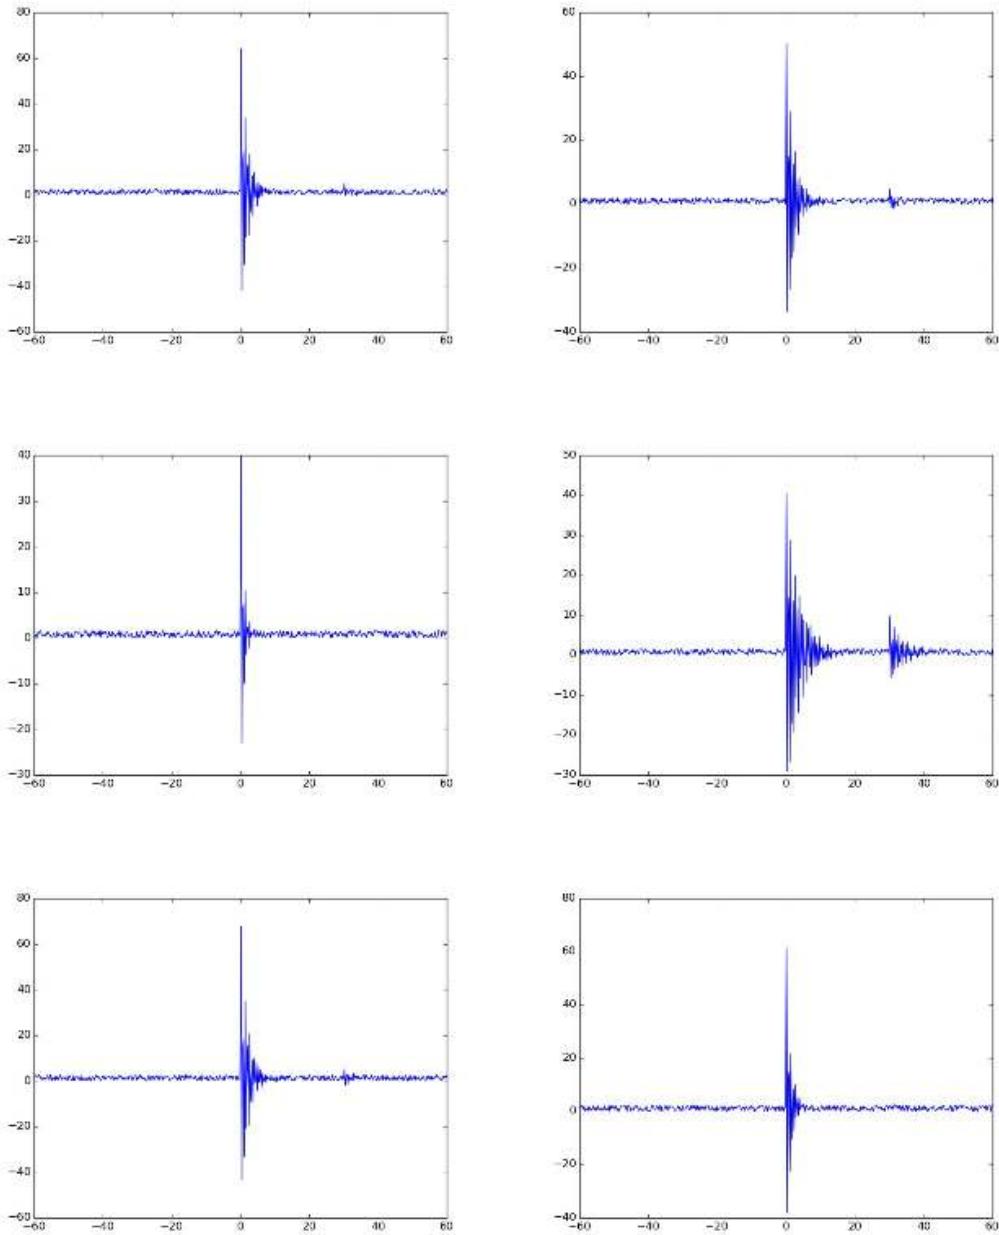


Figura 3.7: Curvas artificiais de aceleração pura - sinal de vibração

3.2.1 Sinal de Velocidade angular

Analizando a figura 3.2, o sinal de velocidade angular pode ser representado por uma concatenação de duas senoides, com amplitudes diferentes, como na equação a seguir:

$$w(x) = \begin{cases} \omega(\operatorname{sen}(2\pi f(x/N)))0.1rand(), & \text{if } x \leq N/2 \\ \omega(1 + (10(\tau - 1))\operatorname{sen}(2\pi f(x/N)))0.1rand(), & \text{if } x > N/2 \end{cases} \quad (3.5)$$

Na equação, ω representa a rotação do equipamento, f a frequência da senoide, neste caso fixa em 2 ciclos por N que é o número de amostras desejado. τ representa

a proporção de amplitude entre as senoides e $rand()$ um sinal de ruído, proporcional a 10% da amplitude do sinal proposto.

Como resultado da equação 3.5, variando aleatoriamente os parâmetros descritos, as seguintes curvas artificiais de velocidade angular puderam ser geradas, como pode ser visto na figura 3.8.

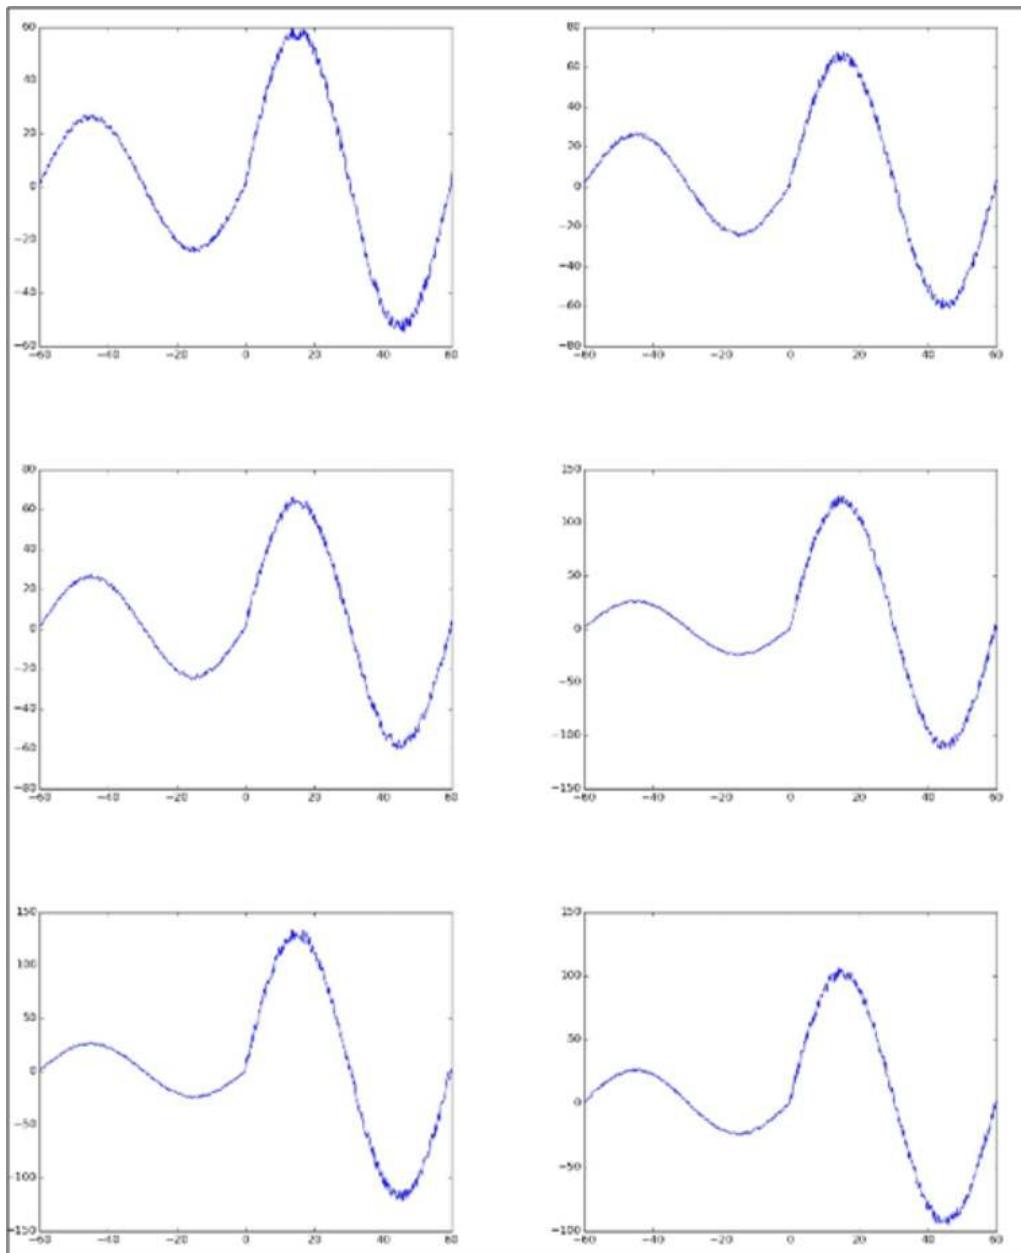


Figura 3.8: Curvas artificiais de velocidade angular

3.2.2 Correlação artificial entre os sinais

Para efeito de estudo, os sinais gerados de aceleração pura, velocidade angular e pressão, estão correlacionados através de 3 parâmetros.

- amplitude
- prop-amplitude
- prop-desvio

De acordo com as equações 3.4 e 3.2, sendo α = amplitude, então existe uma correlação entre as amplitudes dos sinais de pressão e aceleração pura, de acordo com as modelagens propostas. Ainda de acordo com as equações 3.4 e 3.2, se tomarmos $\rho = 1 - \delta$ e δ = prop-desvio, temos a correlação entre o desvio padrão das gaussianas que compõem o sinal de pressão com o decaimento exponencial do sinal de "burst" de aceleração pura.

Ainda, de acordo com as equações 3.5 e 3.2, tomando τ = prop-amplitude, temos o sinal de pressão correlacionado com o sinal de velocidade angular.

Esses três parâmetros foram variados aleatoriamente dentro dos seguintes intervalos:

- amplitude $\rightarrow [50,100]$
- prop-amplitude $\rightarrow [1.0,1.5]$
- prop-desvio $\rightarrow [0.5,0.9]$

Alguns exemplos de sinais correlacionados podem ser vistos na 3.9.

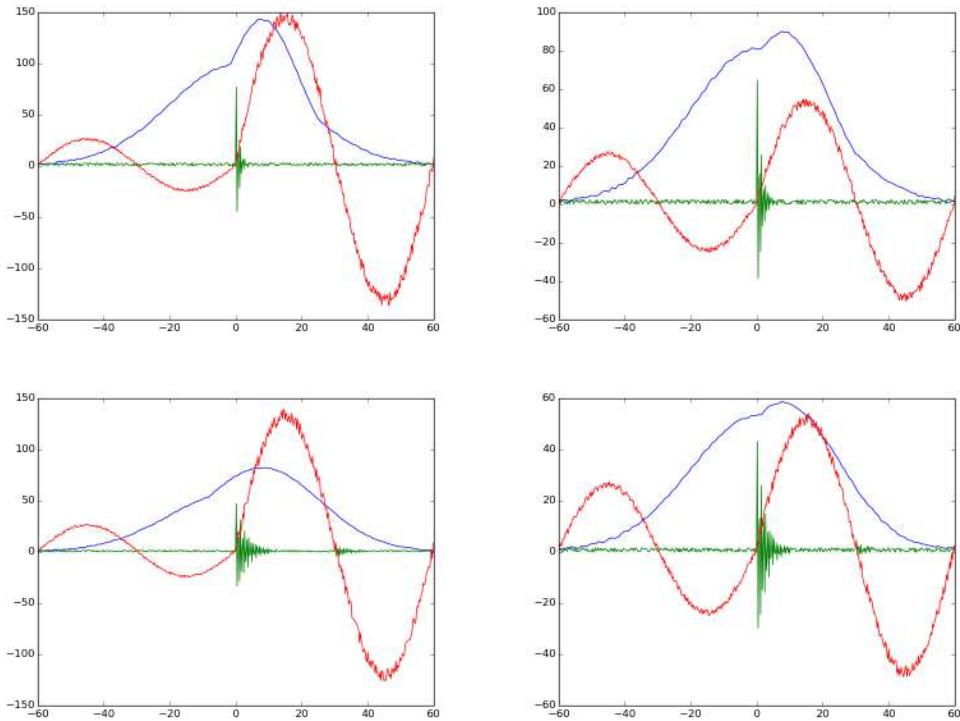


Figura 3.9: Curvas artificiais dos sinais correlacionados

3.2.3 Modelos Clássicos de Regressão

Este tópico simula o processo de regressão dos sinais artificiais que simulam os dados a serem aquisitados, apresentados no item anterior. Tem como objetivo o aprendizado do sinal de pressão vinculado a partir dos sinais de aceleração e velocidade angular.

O objetivo deste estudo é aplicar algumas técnicas e algoritmos conhecidos de regressão, sobre os sinais artificiais gerados no item anterior. Para isso, usaremos os sinais de aceleração e velocidade angular que foram gerados como entrada para os regressões selecionados, a fim de se aprender o sinal de pressão como saída.

Apesar de ser um estudo com dados artificiais, a utilização das regressões servirá de base, inclusive de comparação, quando estiverem disponíveis os sinais reais, aquisitados diretamente dos motores.

Foram desenvolvidas várias técnicas para a realização de análise de regressão. Métodos conhecidos, tais como regressão linear e regressão de mínimos quadrados são paramétricos, em que a função de regressão é definida em termos de um número finito de parâmetros desconhecidos que são estimados a partir dos dados. Regressão não paramétrica refere-se a técnicas que permitem a função de regressão para se encontrar um determinado conjunto de funções, que pode ser de dimensão infinita.

Linear Regression

Regressão Linear ajusta um modelo linear com coeficientes $w = (w_1, \dots, w_p)$ para minimizar a soma residual do quadrado da diferença entre a resposta esperada e a resposta prevista pela aproximação linear [6]. Matematicamente, resolve um problema da forma:

$$\min_w \|Xw - y\|_2^2 \quad (3.6)$$

Ridge Regression

Regressão de Ridge resolve o problema de *Ordinary Least Square* impondo uma penalidade no tamanho de coeficientes. Os coeficientes de ridge minimizam a penalidade residual das somas dos quadrados:

$$\min_w \|Xw - y\|_2^2 + \alpha \|w\|_2^2 \quad (3.7)$$

Aqui, $\alpha \geq 0$ é um parâmetro de complexidade que controla o encolhimento do número de coeficientes: quanto maior o valor de α , mais os coeficientes ficam robustos e colineares [7].

K-nn

Regressão baseada em vizinhos próximos pode ser usada em casos onde os labels dos dados são contínuos ao invés de variáveis discretas. Ou seja, o valor designado a um ponto em questão é computado baseado na média dos valores de seus vizinhos mais próximos.

É implementado baseado nos k vizinhos de cada ponto em questão, de tal forma que k é um inteiro especificado pelo usuário [5].

Decision Trees

Decision Trees (DTs) são um método de aprendizado não supervisionado usado para classificação e regressão. O objetivo é criar um modelo que prevê o valor de uma variável desejada, aprendendo regras simples de decisão, baseadas nas características dos dados de entrada [1].

Extra Trees

Extra-trees diferem do modelo clássico de *Decision Tree* na maneira como são construídas. Quando se olha para a melhor separação dos exemplos de um nó em dois grupos, divisões aleatórias são definidas para as max-features selecionadas aleatoriamente. Quando *max-features* é igual a 1, o algoritmo constrói uma árvore totalmente aleatória [3].

Rede Neural MLP

Redes neurais artificiais geralmente são apresentadas como sistemas de "neurônios interconectados que podem computar valores de entradas". O aprendizado consiste na modificação dos pesos das conexões entre os neurônios, os pesos iniciais (sinapses) são modificados de forma iterativa, por um algoritmo que segue o paradigma de aprendizado supervisionado: é apresentado um conjunto de treino, consistindo de entradas e correspondentes saídas desejadas.

3.2.4 Simulação de resultados

Para realizar a regressão dos sinais de aceleração e velocidade angular para o sinal de pressão, foram gerados um total de 3000 sinais, correlacionados, como descritos anteriormente. A seguir, são apresentados os resultados dos regressores para novas curvas geradas como teste, e a comparação com o resultado esperado.

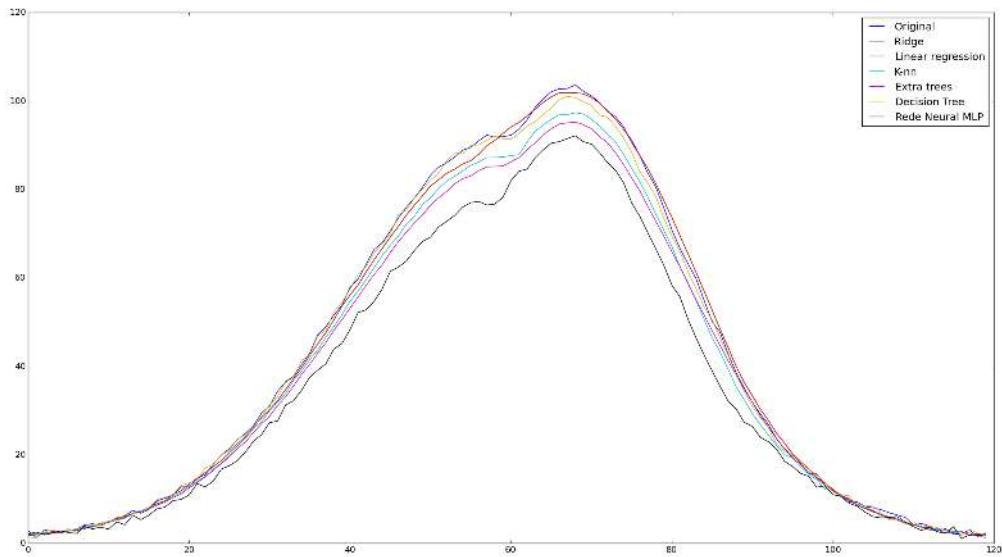


Figura 3.10: Comparação de resultados: exemplo 1.

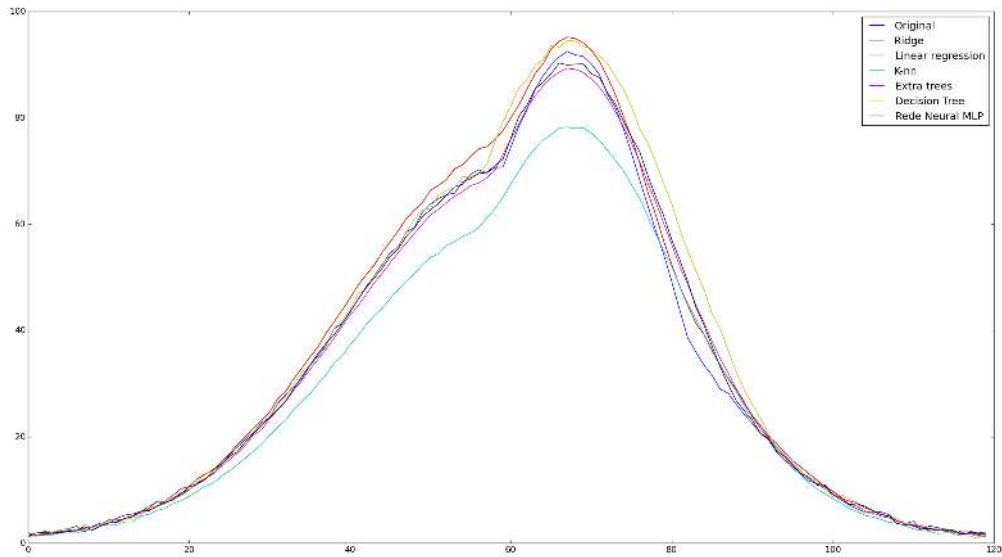


Figura 3.11: Comparação de resultados: exemplo 2.

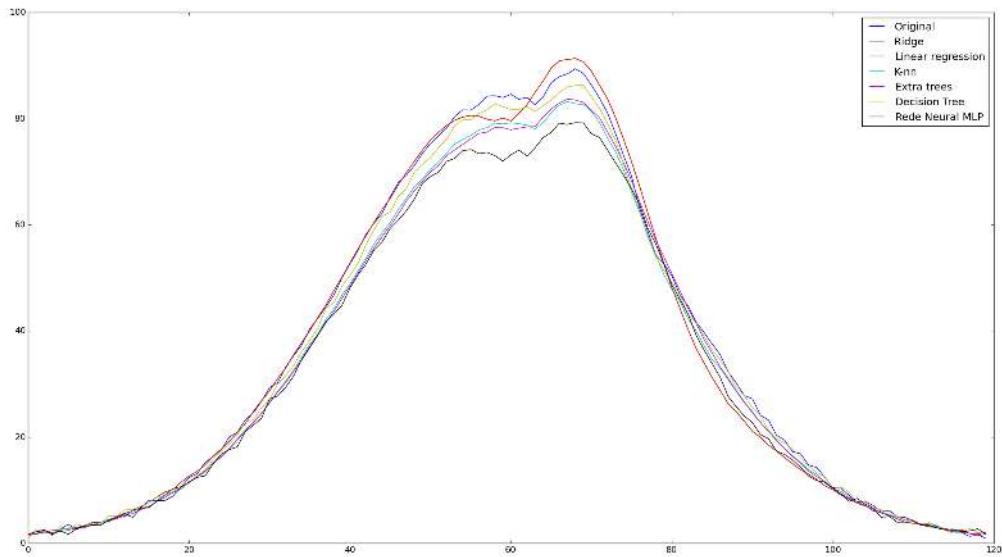


Figura 3.12: Comparação de resultados: exemplo 3.

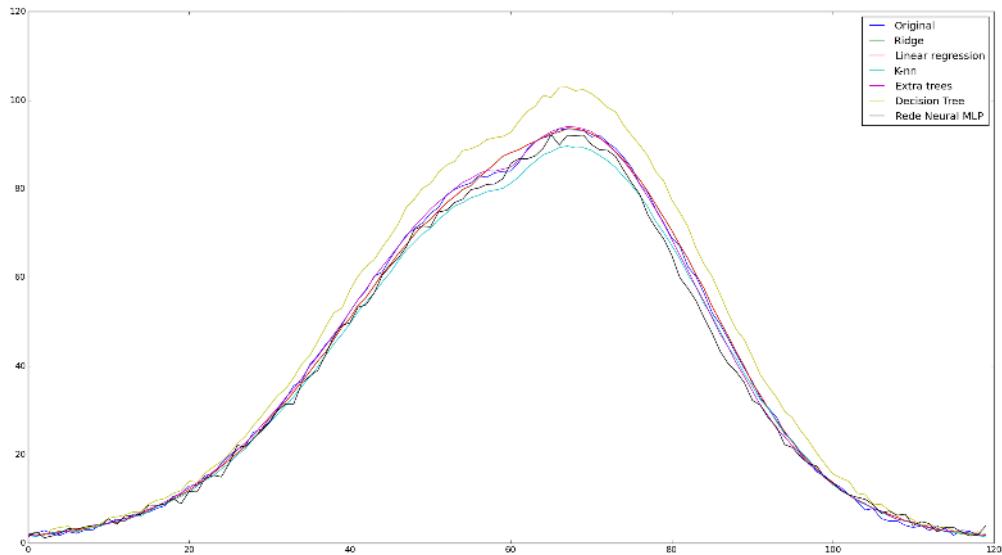


Figura 3.13: Comparação de resultados: exemplo 4.

3.3 Sistema de Aquisição

Para a realização dos ensaios, houve a necessidade de se montar um sistema de aquisição de sinais. Este sistema prevê a entrada de pelo menos 2 acelerômetros de vibração, um tacômetro e um sensor de pressão. A alimentação do sistema é bivolt 110/220V, e a comunicação é realizada através de um cabo USB.



Figura 3.14: Sistema de Aquisição

A seguir, é apresentado um breve relato das atividades envolvidas na montagem do sistema de aquisição.

3.3.1 Sensores

Os sensores utilizados para a aquisição de sinais, necessários aos ensaios a serem realizados, são apresentados a seguir:

Acelerômetro

Para a aquisição dos sinais de vibração são utilizados acelerômetros piezoelétricos, de 100mV/g, 50g pico. Alimentação necessária de 18-30VDC. Temperatura de trabalho varia de -50 a 121°C . Um acelerômetro piezoelétrico usado pode ser visto na figura 3.15.



Figura 3.15: Acelerômetro piezoelétrico

Tacômetro

O sinal de vibração torcional será extraído das rodas fônicas, através de um tacômetro laser. O tempo de resposta do tacômetro é de 0.25ms, alimentado com 10-30VDC.

Temperatura de trabalho varia de -10 a $50^{\circ}C$. O tacômetro pode ser visto na figura 3.16.



Figura 3.16: Tacômetro

Sensor de Pressão

A pressão interna dos cilindro será aferida nos ensaios através de um sensor de pressão. Range de medição é de 0 a 250bar. Sensibilidade de 13mV/bar. Alimentação de 0 a 32VDC e temperatura de operação entre -10 a $110^{\circ}C$. O sensor de pressão pode ser visto na figura 3.17.



Figura 3.17: Sensor de pressão

3.3.2 Tratamento do sinal analógico

A fim de aquisitar os sinais analógicos dos sensores, foram montadas placas de tratamento de sinal, vistas na figura 3.18. A função delas é alimentar os sensores, e filtrar os sinais dos mesmos, para evitar ruído e aliasing na aquisição. As placas recebem alimentação de 5VDC, e regulam esta tensão para 24VDC, necessário para alimentar os sensores.

São três placas montadas na figura 19, pois cada placa é capaz de alimentar e tratar o sinal de 2 sensores somente.

3.3.3 DAQ

Para a conversão do sinal analógico/digital utilizaremos uma DAQ modelo USB-1208HS-4AO. Ela possuí 8 canais com 13bits de resolução cada e 1MS/s de taxa de aquisição. Como utilizaremos 6 canais no máximo, a taxa de aquisição por canal será de no máximo 167KS/s.

Os ranges possíveis de aquisição são os seguintes: $\pm 10V$, $\pm 5V$, $\pm 2.5V$ or 0 a $10V$. A alimentação e comunicação da DAQ são feitas através de um cabo USB.



Figura 3.18: Placas de tratamento do sinal analógico



Figura 3.19: DAQ e fonte do sistema de aquisição

Na figura 3.19 é possível também observar a fonte de alimentação do sistema de aquisição. Ela é alimentada com 110/220V e fornece 5VDC com 3A de máxima corrente.

3.4 Ensaios no Laboratório

Conforme proposto, os ensaios desta etapa serão realizados no laboratório hidromecânico da Universidade Federal de Itajubá – UNIFEI, mais especificamente no Prédio Central, localizado no município de Itajubá, no sul de Minas Gerais. Para

isso serão montadas duas bancadas de testes com motores e carga. A primeira será dotada de um motor monocilíndrico e como carregamento um freio mecânico. A segunda bancada será composta por um motor multicilíndrico e um gerador elétrico conectado com a rede elétrica da concessionária como carga.

Diante disso, apresentam-se, aqui, um breve relato das atividades que foram desenvolvidas no laboratório visando os ensaios de vibração a serem realizados com motores a diesel de combustão interna com um e com mais cilindros.

3.4.1 Base do motor

Para possibilitar a execução desses ensaios, primeiramente, foi dimensionada uma base para fixação dos motores diesel e do gerador para ser empregado como carga mecânica.

O local escolhido para essa base fica do lado esquerdo do antigo grupo motogerador Sulzer. Também foi prevista a extensão de uma tubulação de abastecimento da água de resfriamento e a colocação de um ralo com ligação ao esgoto para o seu descarte. O desenho esquemático dessa base está mostrado na figura 3.20. A figura 3.21a e a figura 3.21b apresentam, respectivamente, um corte longitudinal e um corte transversal para mostrar mais detalhes e dimensões da base.

A base foi concretada e finalizada, estando pronta para a instalação do motor monocilíndrico.

3.4.2 Motor monocilíndrico MWM

O primeiro ensaio a ser realizado será feito em um motor diesel monocilíndrico. Nesse ensaio será necessário instalar um sensor de pressão para medir as variações dessa grandeza no interior da câmara de combustão do equipamento. Como os cabeçotes desses motores são peças com muitas passagens de água e partes ocas, essa instalação é bastante complexa, pois se corre o risco de surgirem vazamentos de gases e da água de resfriamentos que circula no interior desses cabeçotes.

Por esse motivo, antes da aquisição de um motor desse tipo foi feito um teste preliminar para a instalação do sensor de pressão na câmara de combustão em um motor mais antigo existente no laboratório. Esse equipamento é da marca MWM e pode ser visto figura 3.22.

Como esse motor esteve muito tempo fora de operação ele foi totalmente desmontado para verificação do estado das principais peças, ou seja: virabrequim, bielas, casquilhos, bronzinas, camisa, pistão e seus anéis. Observou-se algum desgaste mais acentuado no colo do mancal dianteiro do virabrequim, como pode ser visto na figura 3.23.

Observou-se também uma folga acentuada na bucha desse mancal, mostrado na figura 3.24.

Para colocação desse motor em funcionamento normal será necessário a retífica desse virabrequim e a substituição das buchas e casquilhos.

Verificou-se também uma grande dificuldade na adaptação do sensor de pressão no cabeçote desse motor, pois não existe espaço suficiente para acomodar o sensor e o seu receptáculo. Isso pode ser visto na figura 3.25. O sensor deve ser instalado

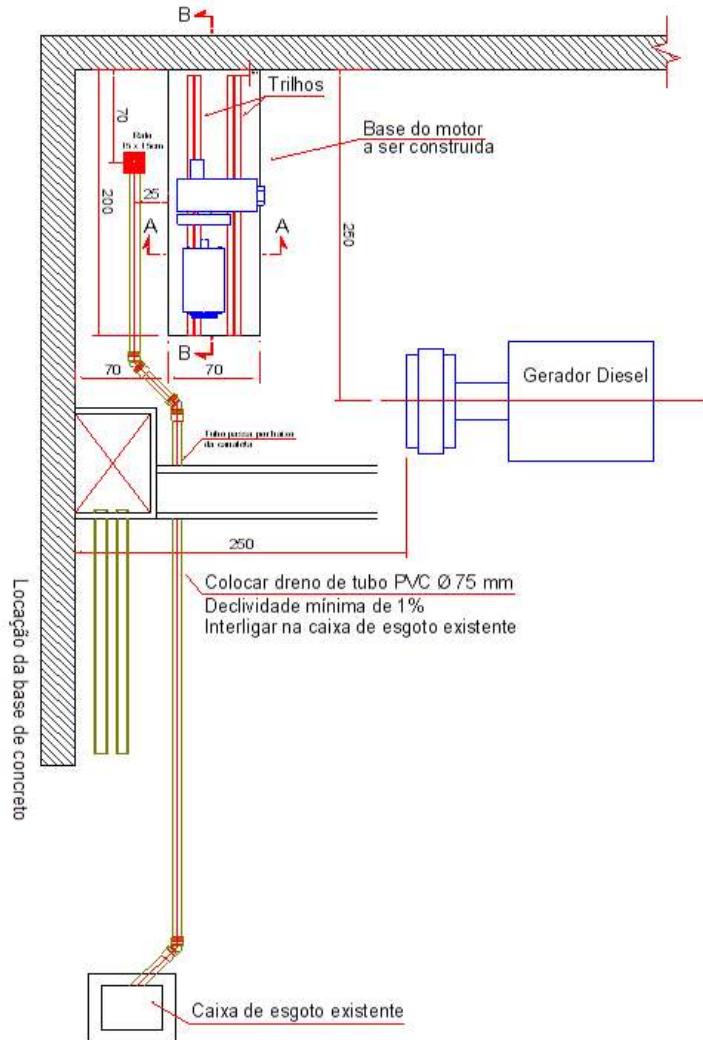


Figura 3.20: Local escolhido para a construção da base

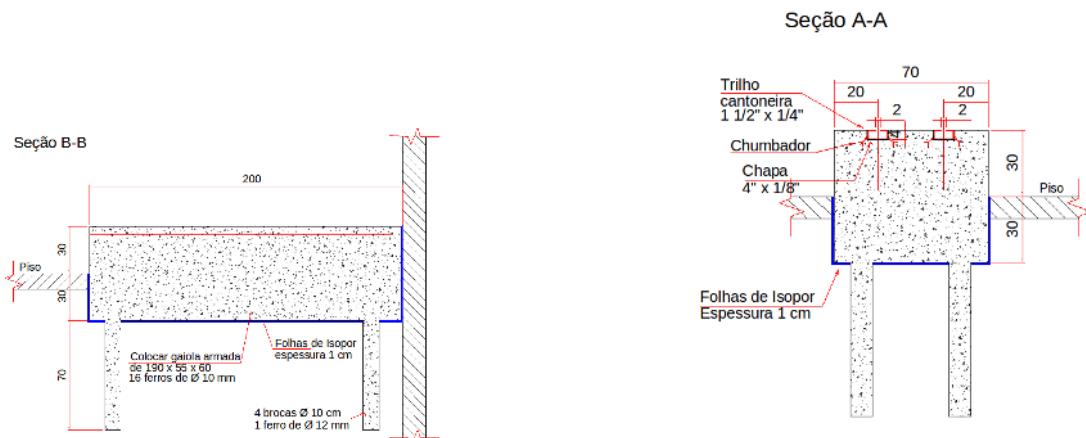
o mais próximo possível da face do cabeçote, porém distante da válvula de escape em razão da maior temperatura.

Em face de todos esses empecilhos e da dificuldade de adquirir peças de reposição para esse equipamento, uma vez que ele foi fabricado na década de 50, resolveu-se fazer esse ensaio em outro motor do mesmo tipo.

3.4.3 Motor Yanmar

Procurou-se então uma alternativa para esse ensaio usando um motor diesel monocilíndrico mais novo, com mais facilidade para a compra de peças de reposição e para a manutenção. Assim conseguiu-se um cabeçote de um motor estacionário da marca Yanmar. Esse cabeçote foi cortado no sentido transversal para verificar a possibilidade de adaptação do sensor de pressão. A figura 3.26 mostra essa peça podendo-se observar a quantidade de passagens para a circulação da água de resfriamento.

Observando-se a figura 3.27, constata-se a existência de muitos vazios e partes



(a) Corte longitudinal da base do banco de ensaios

(b) Corte transversal dessa mesma base

Figura 3.21: Detalhes e dimensões da base



Figura 3.22: Motor monocilíndrico existente no Laboratório



Figura 3.23: Detalhe do virabrequim e o local com desgaste



Figura 3.24: Suporte do mancal dianteiro mostrando a bucha



Figura 3.25: Cabeçote do motor MWM onde se destacam as duas válvulas



Figura 3.26: Parte interna de um cabeçote de um motor Yanmar

ocas. Isso também dificulta a colocação do sensor de pressão em função do risco de vazamentos de gases, da passagem da água de resfriamento para o interior do pistão e do enfraquecimento dessa peça, pois ela está sujeita a elevados esforços mecânicos.



Figura 3.27: Outra vista do corte desse cabeçote

3.4.4 Motor Sulzer

Para contornar todos esses problemas resolveu-se, então, realizar esses ensaios utilizando o grupo motogerador Sulzer existente no Laboratório.

Esse equipamento pode operar como um motor de apenas um cilindro, isolando-se um dos pistões (cortando-se a sua alimentação de combustível e mantendo aberta a válvula de alívio), ou então em operação normal como um motor convencional de dois cilindros. Além disso, os cabeçotes desse equipamento já possuem locais apropriados para instalação dos sensores de pressão. Esse motor também permite a colocação de uma roda fônica com relativa facilidade já que o eixo virabrequim tem uma das extremidades visível. Essa roda fônica é um dispositivo que possibilita determinar a velocidade e a posição angular do eixo do motor para a verificação do instante em que ele passa pelo ponto morto superior, pouco antes de ocorrer a injeção do combustível e a sua detonação.

A figura 3.28 mostra a parte de cima de um dos cilindros destacando-se o local onde é colocada a mecha para a partida do motor, que nesse caso é realizada utilizando-se ar comprimido.



Figura 3.28: Parte de cima do motor Sulzer de dois cilindros

Na figura 3.29 é possível observar um dos bicos injetores de combustível e a válvula de tomada de pressão. Essa válvula será retirada e nesse local que será inserido o receptáculo para o sensor de pressão.



Figura 3.29: Detalhe de uns dos cabeçotes desse motor

3.4.5 Ensaio Elétrico do Gerador

O objetivo deste ensaio é identificar a condição do gerador após realização dos testes com o equipamento de Análise de Motor Elétrico.

A seguir, são apresentados os resultados dos ensaios realizados.

AC Standard Test

Este ensaio tem como finalidade medir a isolamento e sua respectiva correção por temperatura, capacidade à terra e medidas de indutância. Os resultados podem ser vistos na figura 3.30.

Algumas medidas, destacadas na imagem, apresentam valores insatisfatórios, de acordo com a norma NBR5383-2:2007:

- 6.8 Valores mínimos recomendados da resistência de isolamento e do índice de polarização:
 - 6.8.2 A resistência de isolamento mínima recomendada para enrolamento de motores de indução é de $5M\Omega$ a uma temperatura ambiente de $40^\circ C$.
 - 6.8.3 O índice de polarização mínimo recomendado para motores de Indução é
 - * Para classe 105 (A): 1,5
 - * Para classe 130 (B): 2,0
 - * Para classe 155 (F): 2,0

	M.T.E
Measured Mohm	3.80
Corrected Mohm	1.34
pF Ph 1 to Ground	175
ohm Ph 1 to 2	0.52973
ohm Ph 1 to 3	0.83549
ohm Ph 2 to 3	0.49818
mH Ph 1 to 2	2.037
mH Ph 1 to 3	1.162
mH Ph 2 to 3	1.357
Average Inductance	1.519
% Res. Imbalance	3.45
% Ind. Imbalance	34.10
	M.T.E
DA Ratio	1.017
Polarization	1.028

Figura 3.30: AC Standard Test

Polarization Index

Este ensaio apresenta os valores de índice de polarização (IP), absorção dielétrica (AD) e curva de polarização a fim de apresentar as reais condições da camada isolante do conjunto ensaiado.

Os valores de IP e AD se mostram insatisfatórios, porém sua curva de polarização se apresenta satisfatória, sem contaminação por umidade ou sujeira, como pode ser visto na figura 3.31.

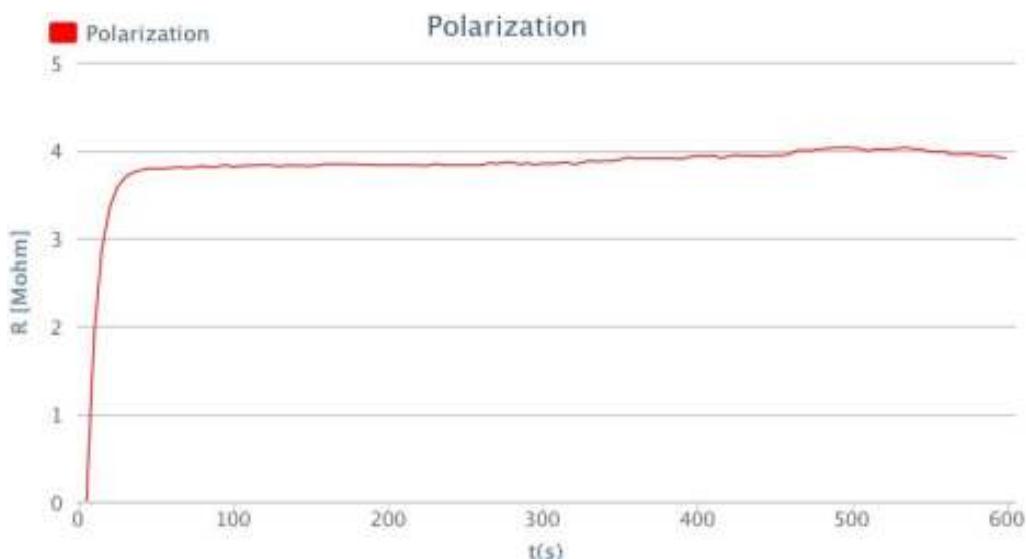


Figura 3.31: Curva de Polarização

RIC

O ensaio de RIC (*Rotor Check Influence*) é uma representação gráfica da relação entre rotor e estator. Este ensaio é capaz de medir o magnetismo residual que existe no rotor que afeta a indutância fase a fase. Na ausência de falhas, deve-se observar três senoides defasadas em 120 graus cada.

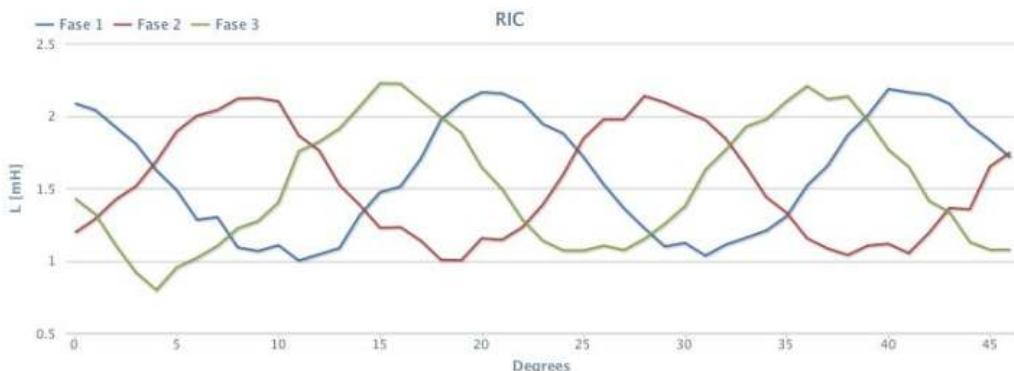


Figura 3.32: RIC

Neste ensaio o gerador apresentou resultado satisfatório.

Conclusão

O valor de desbalanceamento resistivo apresentado está acima do recomendado.

- Desequilíbrios resistivos em um circuito causam desequilíbrio de tensão.
- Desequilíbrio de tensão de 1% pode resultar em um desequilíbrio de corrente de 6 a 7% de acordo a *Electrical Apparatus Service Association* (EASA)
- Desequilíbrio de voltagem de 3.5% pode aumentar a temperatura das bobinas em 25% de acordo com a *Electric Power Research Institute* (EPRI)

Tendo em vista os valores coletados podemos afirmar que o estator do gerador se encontra abaixo do recomendado pela norma.

Ação Recomendada

Devem ser verificadas as conexões internas do gerador. Desbalanceamento resistivo pode causar aquecimento no gerador prejudicando a vida útil do gerador.

Devido ao índice de absorção e índice de polarização, solicitamos limpeza com material dielétrico. Caso os valores não fiquem satisfatórios, fazer rejuvenescimento do mesmo.

3.4.6 Teste do Motor Sulzer

Neste teste, o objetivo era verificar o correto funcionamento do motor acoplado ao gerador e da instrumentação a ser utilizada para os futuros ensaios. O sistema

de aquisição utilizado e o apresentado no apêndice 3.14. Para isso, era necessária a aquisição dos sinais de vibração do bloco do motor, em conjunto ao sinal de vibração torcional com o intuito de posteriormente fazer o ajuste dos modelos para a regressão do sinal de pressão interno ao cilindro. Para isso, o sinal de pressão medido diretamente através de um transdutor de pressão, a fim de comparação de resultados apenas.

O sinal de vibração do motor foi medido através de dois acelerômetros de 100 mV/g, fixados através de bases magnéticas diretamente no motor, como mostra a figura 3.33.



Figura 3.33: Posição dos acelerômetros no motor Sulzer

O sinal de vibração torcional, para este ensaio, foi aquisitado através de um fototacômetro e fitas reflexivas fixadas no volante de inércia do motor. Ao todo, foram fixadas 42 fitas ao longo do volante de inércia do motor Sulzer.

E por fim, o sinal de pressão, utilizado somente como referência para a regressão a ser feita posteriormente, foi aquisitado pelo transdutor de pressão, instalado diretamente através de um orifício na camisa do cilindro, como pode ser visto na figura 3.34.

Após instrumentação, o motor foi ligado e funcionou corretamente. Neste ensaio o gerador foi conectado em paralelo com a rede do laboratório, e os sinais de vibração, pressão e velocidade angular foram aquisitados.

Resultados do ensaio

O laboratório utilizado está instalado no Prédio Central da Universidade Federal de Itajubá – UNIFEI. Este laboratório está localizado no centro da cidade e, quando foi projetado, não haviam prédios no entorno do laboratório. Após o ensaio, notou-se que a chaminé de exaustão da fumaça gerada pelo motor Sulzer expelia a fumaça na direção de prédios residenciais e pontos comerciais instalados mais recentemente ao redor do laboratório.

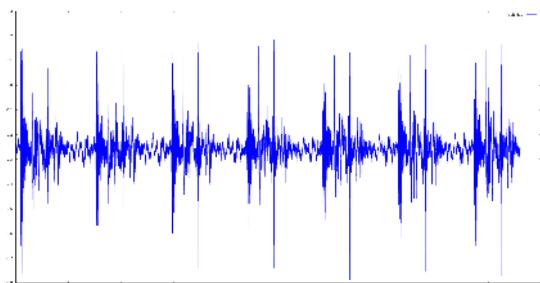


Figura 3.34: Posição do transdutor de pressão no cilindro

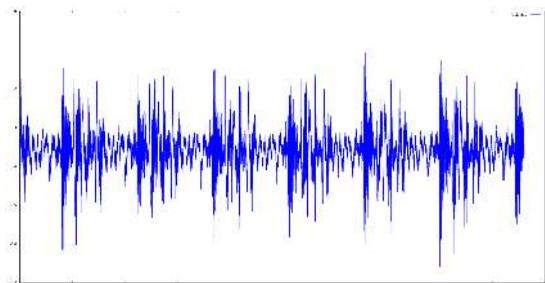
Como resultado do ensaio, ficou comprovada a necessidade de uma solução para este problema, seja através da modificação da chaminé, ou do sistema de exaustão do motor - instalação de um lavador de gases ou alguma espécie de filtro. Esta solução deve ser projetada, especificada e instalada a fim de se realizar novos ensaios sem mais problemas.

Aquisição dos sinais de vibração

Os sinais de vibração aquisitados pelos acelerômetros e posicionados um em cada cilindro podem ser vistos na figura 3.35.



(a) Sinal medido pelo acelerômetro no cilindro 1



(b) Sinal medido pelo acelerômetro no cilindro 2

Figura 3.35: Sinais de vibração dos cilindros

Os sinais apresentados são os sinais de vibração no tempo. A amplitude dos

sinais é da ordem de 9g e 7g pico a pico, respectivamente. O tempo dos sinais demonstrados na figura 3.35 é de 1 segundo de aquisição.

Aquisição do sinal de pressão

O sinal de pressão não pôde ser aquisitado neste ensaio devido a um problema na placa de tratamento do sinal analógico a que o sensor estava conectado. O regulador de tensão apresentou problema, e assim o sensor não foi alimentado.

Aquisição do sinal de velocidade angular

O sinal de velocidade angular foi aquisitado e pode ser visto na figura 3.36.

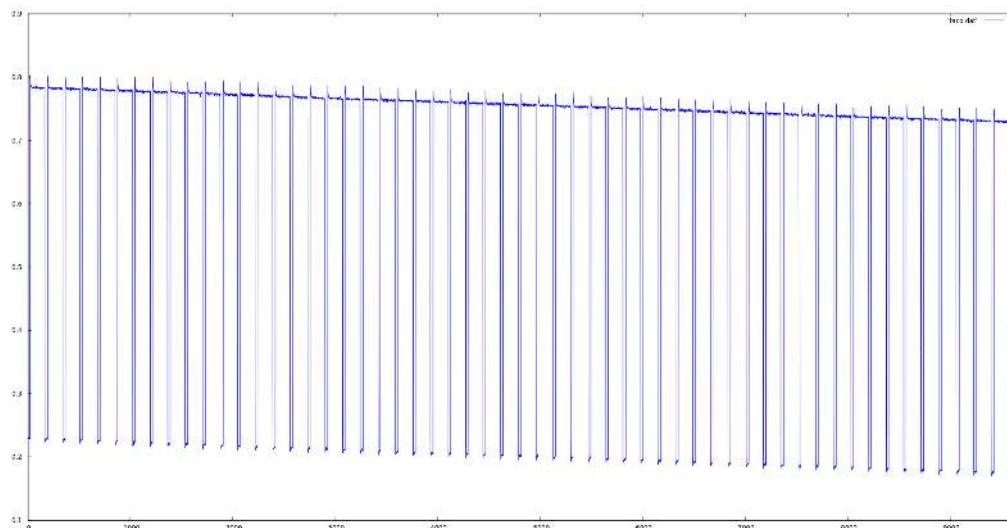


Figura 3.36: Sinal medido pelo tacômetro

A taxa de aquisição utilizada foi de $48KHz$. O sinal apresentado na figura 3.36 possui 9600 pontos, o equivalente a 0,2 segundos de aquisição.

3.4.7 Ensaio do Motor Sulzer com Variação de Carga

Diferentemente do ensaio anterior - de teste do sistema de aquisição e do motor Sulzer, apresentado na seção 3.4.6 - neste ensaio será utilizado um sistema de geração isolado, movido pelo motor Sulzer. Esse sistema irá alimentar uma bomba do laboratório hidromecânico em que está instalado o motor. A bomba em questão pode ser vista na figura 3.37, e é de potência equivalente ao sistema de geração desenvolvido.

A variação da carga no motor é realizada através da regulagem da vazão na bomba, como pode ser visto na figura 3.38.

Outro objetivo deste ensaio era o de rodar o motor Sulzer com os dois cilindros funcionando, mas também, com somente um dos cilindros funcionando.

Novamente os ensaios utilizaram o sistema de aquisição testado, porém com os problemas detectados no ensaio anterior resolvidos: transdutor de pressão devidamente alimentado pela placa de tratamento de sinal analógico; fita alternada



Figura 3.37: Bomba instalada no laboratório hidromecânico



Figura 3.38: Regulando vazão na bomba - variação de carga no sistema

clara/escura, com mais faixas para se obter uma resolução maior do sinal de velocidade angular, e consequentemente, um sinal mais preciso de vibração torcional.

Ensaios com 2 cilindros funcionando

Primeiramente foram aquisitados os sinais com os dois cilindros funcionando. A carga foi variada de acordo com os seguintes níveis aproximados: vazio, 30%, 50%, 70% e 95%.

O posicionamento dos sensores é o mesmo do explanado no ensaio da seção 3.4.6, e podem ser vistos na figura 3.39.



Figura 3.39: Ensaio do motor Sulzer com variação de carga - instrumentação

Nas figuras 3.40, 3.41, 3.42, 3.43, 3.44, são apresentados os sinais dos 2 acelerômetros e o sinal de pressão interna do cilindro.

O sinal verde é o sinal de vibração medido no mesmo cilindro do sinal de pressão; o sinal vermelho é o sinal de pressão interna do cilindro; o sinal azul é o sinal de vibração medido no segundo cilindro.

Os acelerômetros são de $100mV/g$. Nota-se que a amplitude dos sinais varia de $900mV$ com o motor a vazio. Isso representa um sinal de $9g$ pico a pico. Com 100% de carga, o sinal varia até mais de $5V$, que seriam $50g$ pico a pico, ou seja, saturando a resposta do sensor e o range de aquisição proposto. Fica claro aqui, com esses resultados, que para cargas maiores aplicadas no motor, tem-se a necessidade de se utilizar acelerômetros com sensibilidade menor, de $50mV/g$, ou até mesmo de $10mV/g$.

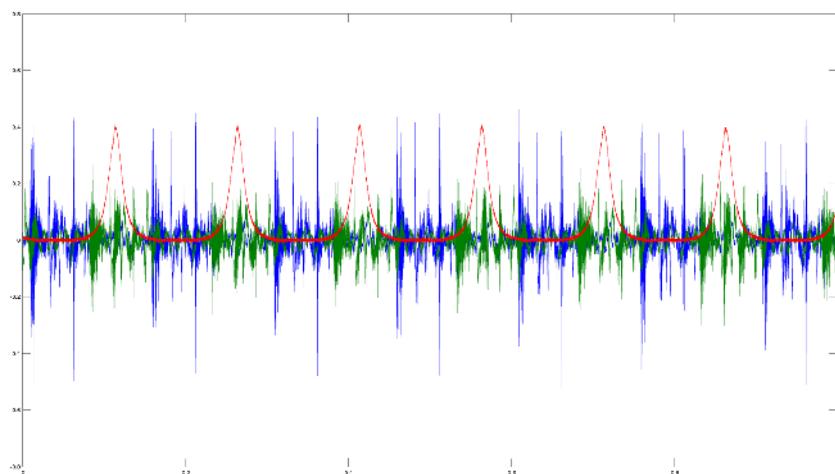


Figura 3.40: Sinais com motor a 0% de carga 2 cilindros

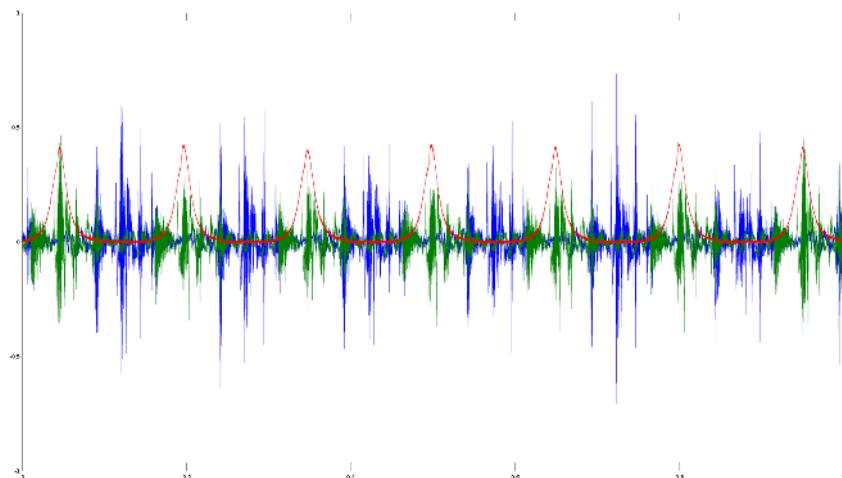


Figura 3.41: Sinais com motor a 30% de carga 2 cilindros

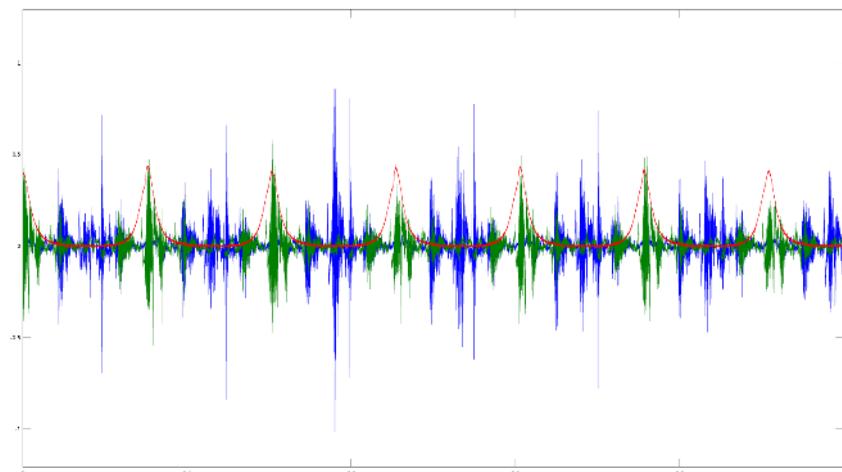


Figura 3.42: Sinais com motor a 50% de carga 2 cilindros

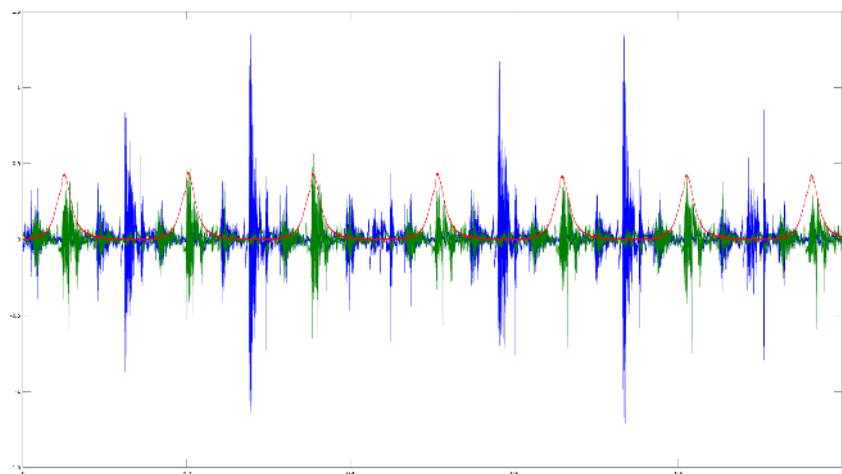


Figura 3.43: Sinais com motor a 70% de carga 2 cilindros

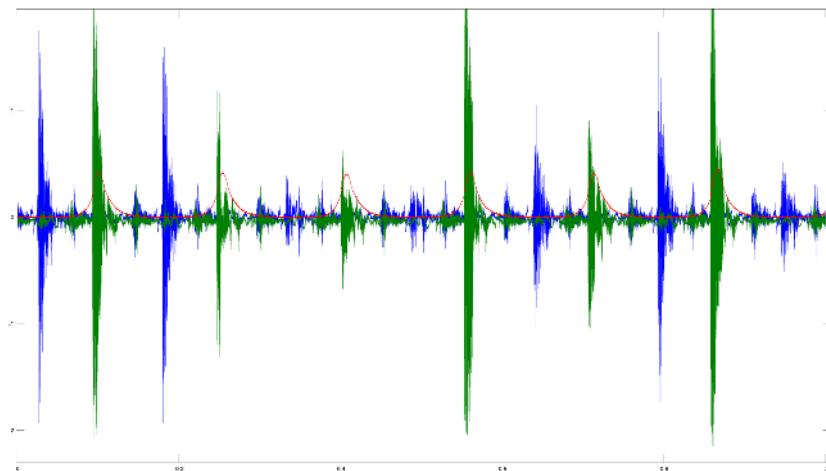


Figura 3.44: Sinais com motor a 95% de carga e 2 cilindros

Ensaios com 1 cilindro funcionando

Nesta etapa, foi utilizado somente 1 cilindro ativo no motor, e foram aquisitados os sinais com a carga variando de acordo com os seguintes níveis aproximados: vazio, 10%, 40% e 50% no máximo. Não aumentou-se mais a carga pois com um cilindro somente a potência do motor diminuiu e notou-se que com 50% a rotação do motor já estava caindo.

Nas figuras 3.45,3.46,3.47,3.48 são apresentados os resultados para 1 cilindro. Nota-se que para 50% de carga o sinal de pressão já começa a se degenerar, a rotação é menor e os níveis de vibração também, sinal de que o motor estava trabalhando já em regime de sobrecarga. Por isso, para os próximos ensaios, com 1 cilindro, o máximo de carga aplicado no motor será de 40%.

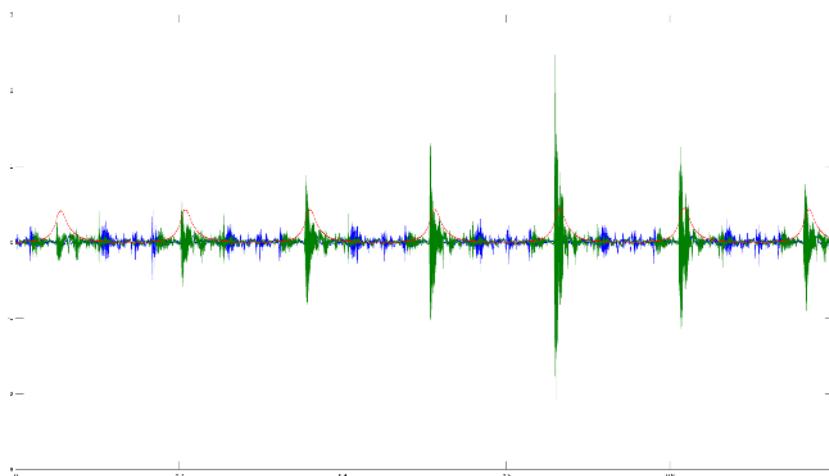


Figura 3.45: Sinais com motor a 0% de carga e 1 cilindro

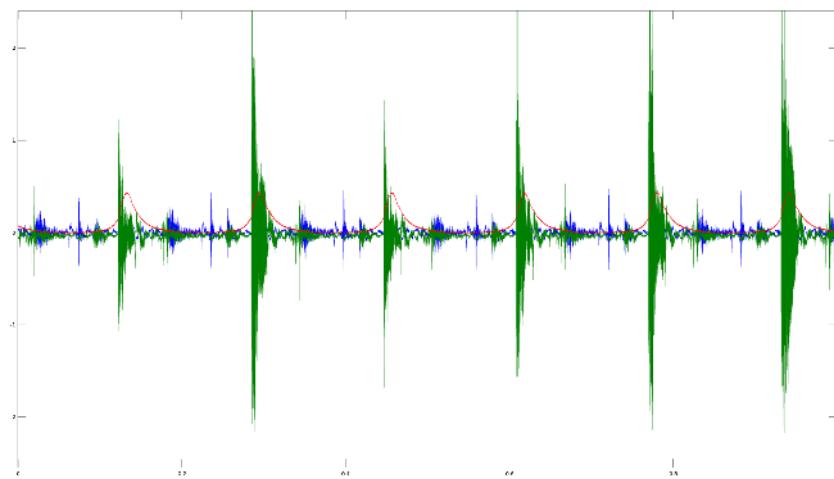


Figura 3.46: Sinais com motor a 10% de carga e 1 cilindro

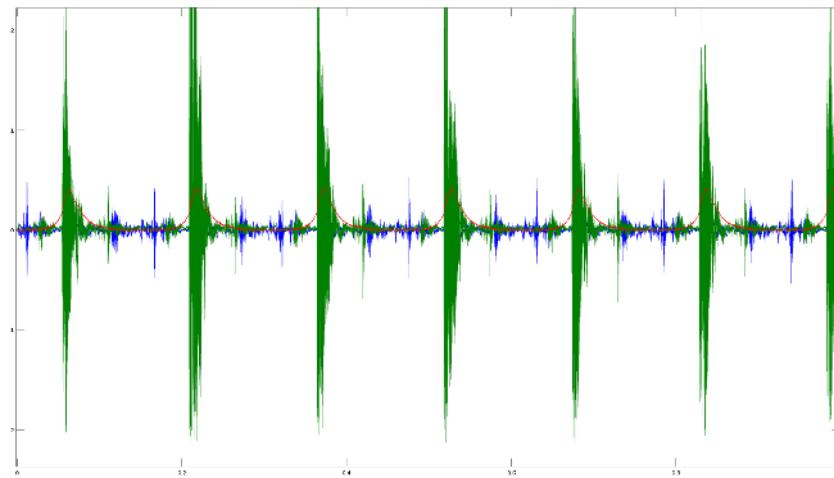


Figura 3.47: Sinais com motor a 40% de carga e 1 cilindro

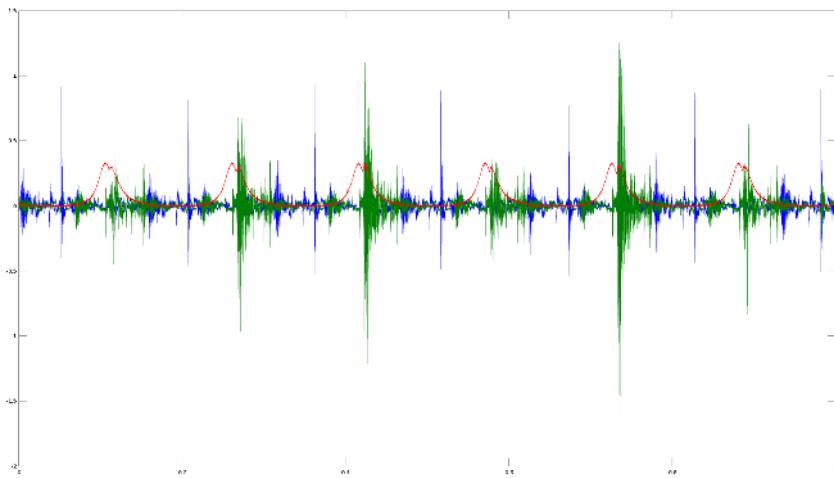


Figura 3.48: Sinais com motor a 50% de carga e 1 cilindro

3.4.8 Ensaio para Aquisição dos Sinais

A sistemática do ensaio foi mantida, ou seja, os sinais foram medidos em cinco condições diferentes de carga (0, 25, 50, 75 e 100%). Em cada uma dessas condições, foram aquisitados 25 ensaios intervalados de duração de 2 segundos de aquisição cada. Como o motor roda a velocidade de 400 rpm, cada trecho de sinal aquisitado de 2 segundos, propicia a visualização de 13 ou 14 ciclos de combustão completos. Como foram feitos 25 ensaios, isso equivale a gravação de até 350 ciclos de combustão, por condição de carga.

Foram feitos dois ensaios, em dias distintos, seguindo o mesmo procedimento descrito acima. Exemplos dos sinais aquisitados podem ser vistos nas figuras 3.49, 3.50.

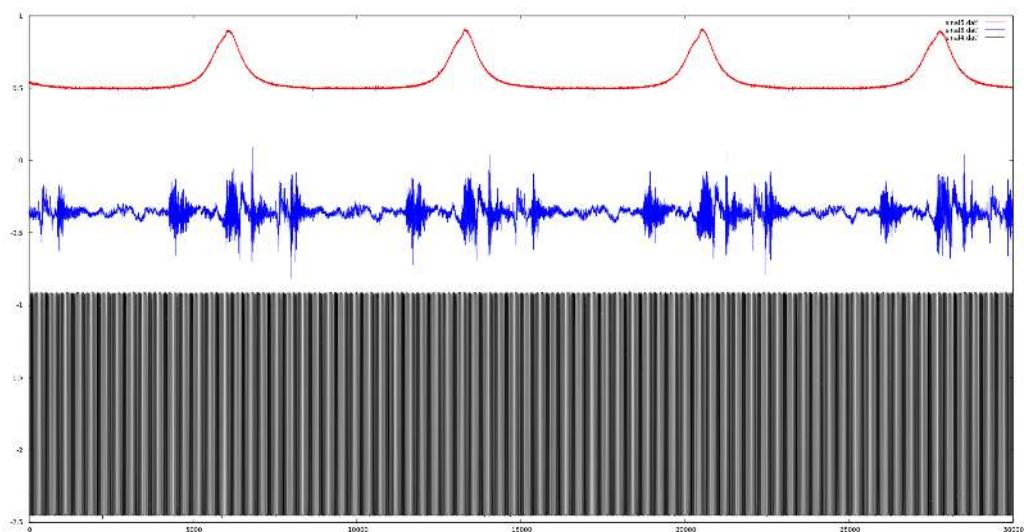


Figura 3.49: Exemplo dos sinais aquisitados

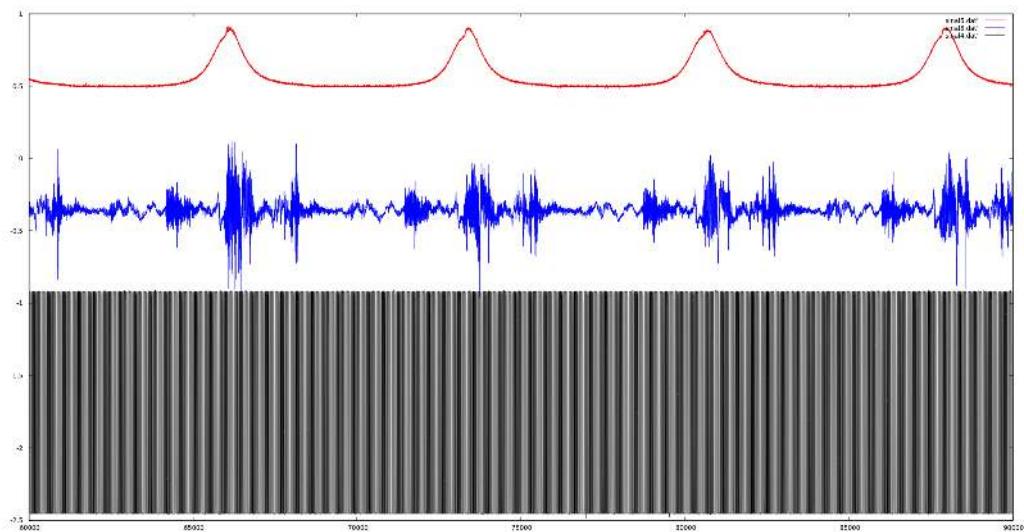


Figura 3.50: Exemplo dos sinais aquisitados

3.5 Tratamento dos Sinais e Modelos Clássicos

De acordo com a metodologia proposta, que pode ser vista na figura 3.1, algumas etapas além da reconstrução são necessárias para a aplicação dos modelos clássicos de regressão.

Como os sinais de pressão e de aceleração pura são medidos simultaneamente e continuamente no tempo, é necessária uma etapa com a finalidade de segmentá-los. Dessa forma, usaremos cada ciclo de compressão e combustão no cilindro separadamente - a esse processo, damos o nome de *parsing* ou *slicing* dos sinais.

Além da segmentação dos ciclos de compressão e combustão, são feitas algumas etapas de eliminação de ruído e preparação dos sinais, detalhadas nas seções a seguir.

3.5.1 *Slicing* dos sinais

Como dito anteriormente, os sinais são medidos continuamente no tempo, durante a execução do motor, como pode ser visto na figura 3.51.

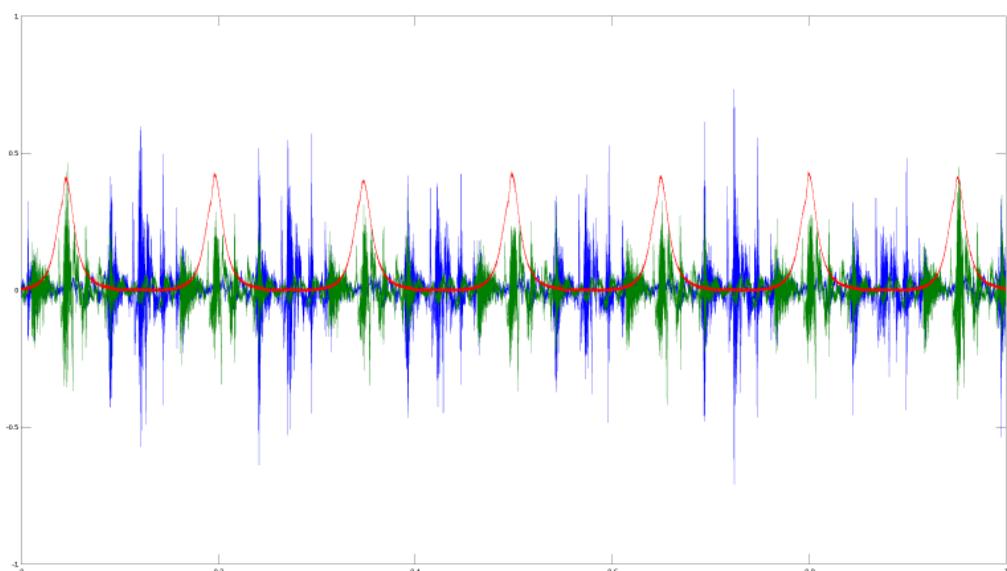


Figura 3.51: Sinais aquisitados continuamente

No entanto, para o ajuste do modelo, vamos considerar cada ciclo de combustão separadamente. Para isso, é necessário dividir os sinais aquisitados e essa divisão é feita tomando uma janela uniforme do sinal, sincronizando com a velocidade angular, para que cada ciclo comece exatamente na mesma posição relativa do eixo.

Os sinais, aquisitados a 48KHz, são divididos em porções de 2000 pontos cada, que representa cerca de 0,041 segundos do total da onda aquisitada. Uma fatia desses sinais, pode ser vista na figura 3.52.

Na figura 3.52, podemos ver os sinais de pressão (vermelho) e aceleração pura (azul), num intervalo de 2000 pontos, relativos a um ciclo de combustão do cilindro monitorado.

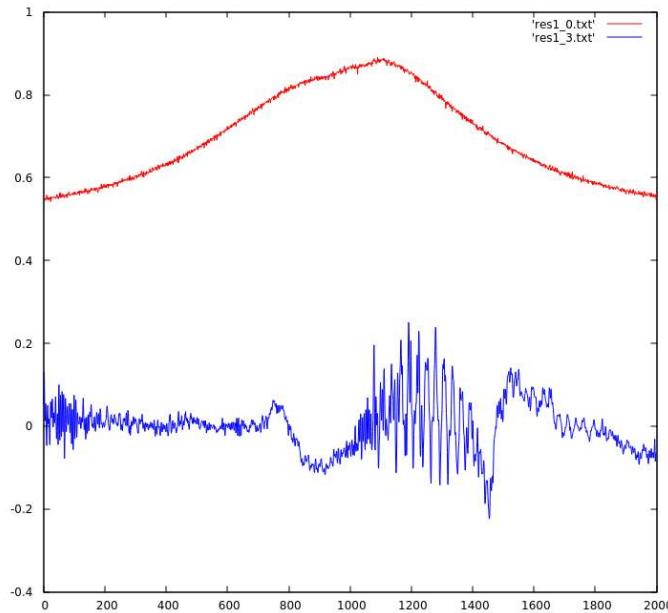


Figura 3.52: Porção dos sinais correspondente a um ciclo de combustão

3.5.2 Preparo do Sinal de Pressão

Dada a alta taxa de amostragem utilizada no sistema de aquisição usado (48KHz) e à presença de ruído no processo de aquisição, o sinal original de pressão possui o aspecto apresentado na figura 3.53.

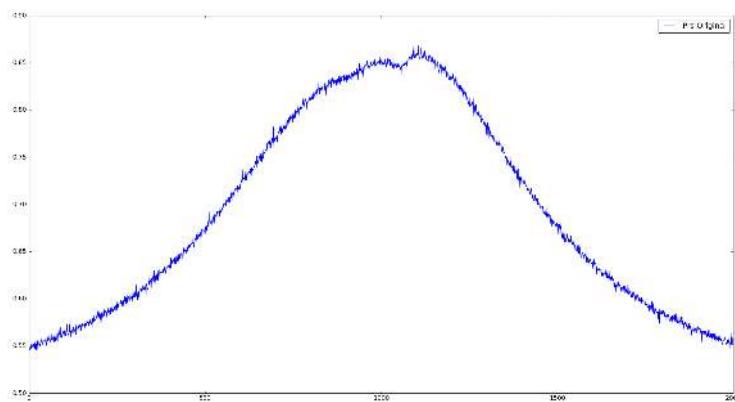


Figura 3.53: Sinal aquisitado do acelerômetro

Para eliminar o ruído presente no sinal, foi utilizado o filtro Savitzky-Golay: um filtro digital que pode ser aplicado a um conjunto de pontos de uma função com a finalidade de alisamento dos dados, ou seja, para aumentar a relação sinal-ruído, sem distorcer o sinal original. Isto é conseguido, num processo conhecido como convolução, por encaixe de sub-conjuntos sucessivos de pontos adjacentes com um polinômio de baixo grau pelo método dos mínimos quadrados lineares.

O filtro de Savitzky-Golay possui a seguinte formulação:

$$\left\{ Y_j = \sum_{i=-\frac{m-1}{2}}^{\frac{m-1}{2}} C_i y_{j+i}, \quad \frac{m+1}{2} \leq j \leq n - \frac{m+1}{2} \right. \quad (3.8)$$

Onde C_i é um conjunto de um total de m coeficientes de convolução.

Para o preparo do sinal de pressão, foram utilizados 121 coeficientes e o polinômio de aproximação com grau 3. O resultado para o filtro do sinal de pressão, pode ser visto na figura 3.54.

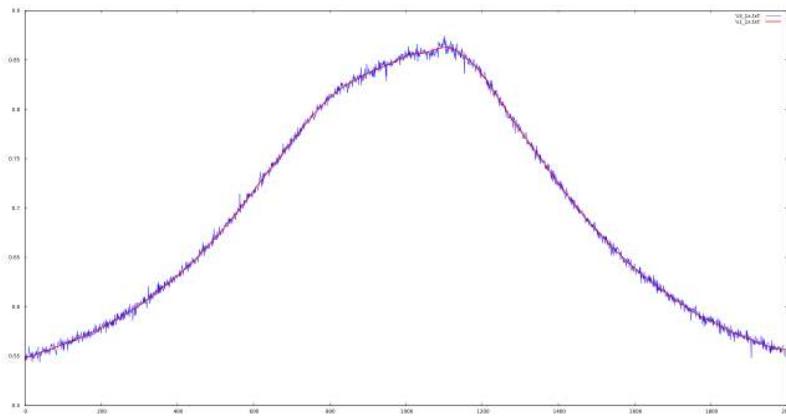


Figura 3.54: Sinal de pressão filtrado.

Usaremos o sinal de pressão filtrado como objetivo do modelo de regressão. Para tornar o processo de regressão mais eficiente, o sinal de pressão é ainda subamostrado por um fator de 10. Assim o resultado final da preparação do sinal de pressão pode ser visto na figura 3.55. Este sinal possui entrão, um total de 200 pontos.

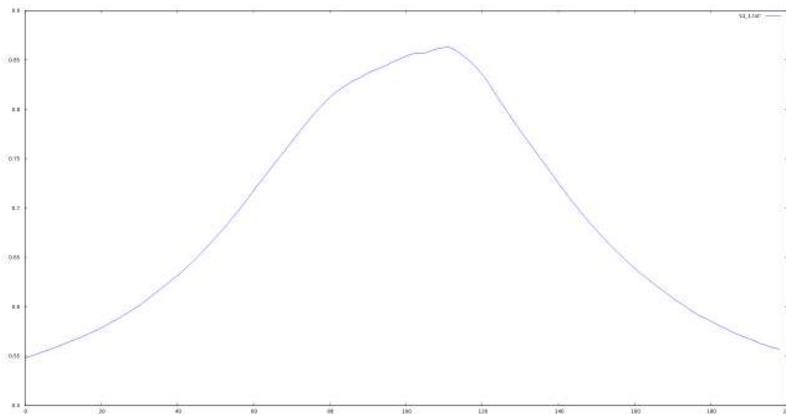


Figura 3.55: Sinal de pressão final.

3.5.3 Preparo do Sinal de Aceleração

O sinal de aceleração pura original aquisitado pode ser visto na figura 3.56.

Já o sinal de aceleração, no domínio da frequência, pode ser visto através do espectro da figura 3.57.

Através do sinal de aceleração pura no domídio da frequência, pode-se observar que não há informação relevante acima de 400Hz. Portanto o sinal pode ser filtrado

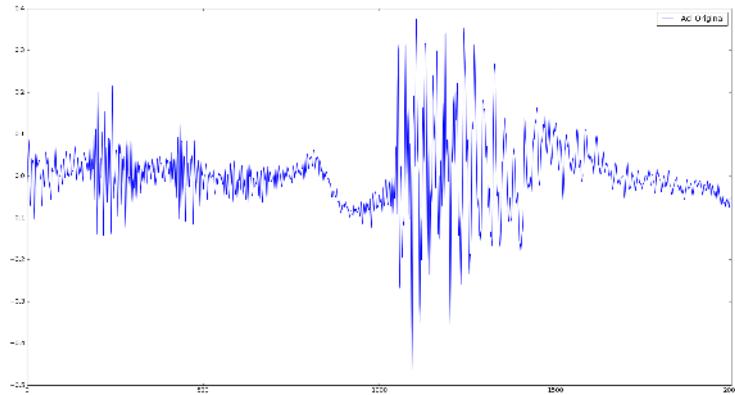


Figura 3.56: Sinal de aceleração pura.

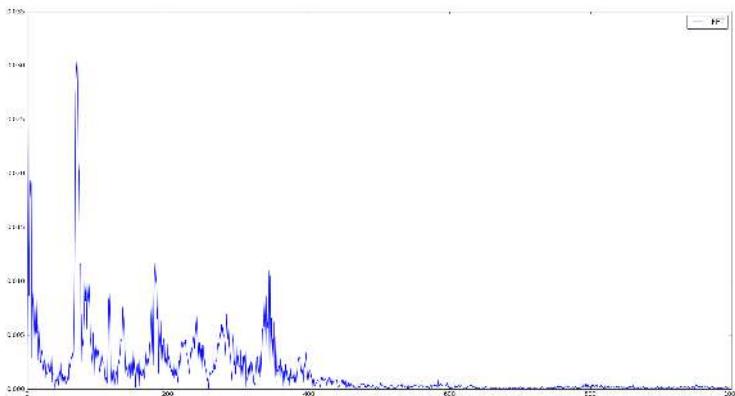


Figura 3.57: FFT do sinal de aceleração pura.

com um passa baixa de 400Hz. Com o objetivo de se trabalhar somente com os harmônicos mais altos da frequência de combustão do cilindro, iremos filtrar o sinal de aceleração pura acima de 30Hz, eliminando assim todas as componentes espectrais até 30Hz, que compreende a primeira região de alta energia espectral, como pode ser visto na figura 3.57. O sinal de aceleração pura filtrado por um passa banda no domínio do tempo, de 30 a 400Hz, pode ser visto na figura 3.58.

O sinal é filtrado através de um passa-banda Butterworth de ordem 1. Com o intuito de realçar ainda mais as características do sinal de aceleração filtrada, calculamos a derivada do sinal resultante, como pode ser visto na figura 3.59.

E a comparação dos sinais de aceleração pura, do sinal de aceleração filtrado entre 30 e 400Hz, e o sinal derivado, pode ser visto na figura 3.60.

O sinal de aceleração resultante (filtrado de 30 a 400Hz e derivado), é utilizado no modelo de regressão.

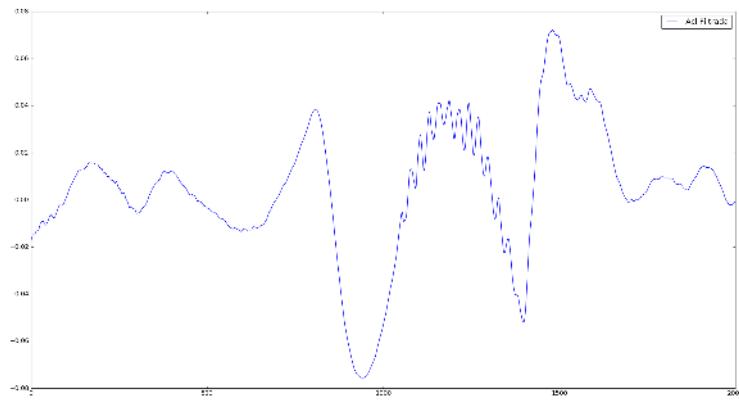


Figura 3.58: Sinal de aceleração pura filtrada de 30 a 400Hz.

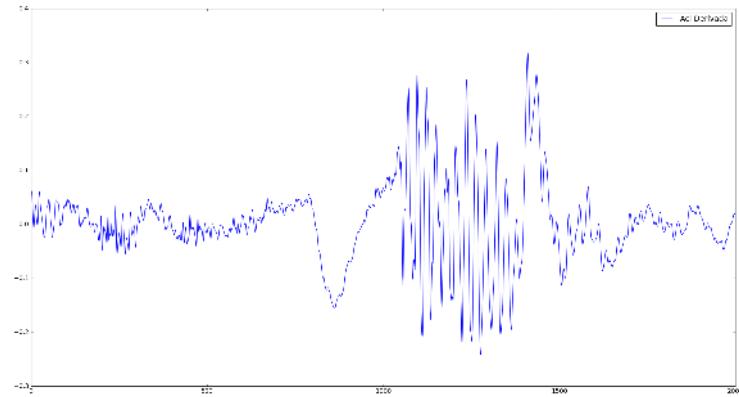


Figura 3.59: Sinal de aceleração pura filtrada de 30 a 400Hz e derivada.

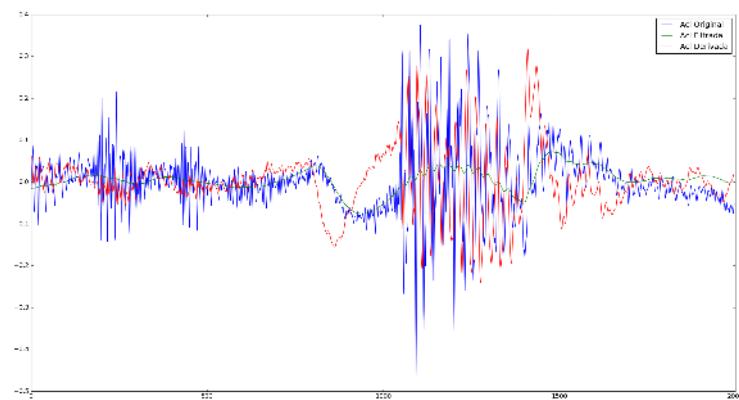


Figura 3.60: Comparação entre os sinais de aceleração pura, filtrada e derivada.

3.5.4 Treinando os Modelos

Com os sinais preparados tanto de pressão, quanto de aceleração, podemos treinar os modelos de regressores propostos na seção 3.2.3, sendo eles:

- Decision Tree
- Extra trees
- K-nn
- Linear regression
- RidgeCV
- GaussianProcess

Como descrito na seção 3.4.8, os ensaios foram feitos em dias separados. Com isso, usaremos os sinais aquisitados em um dos dias para o aprendizado do modelo de regressão, e os sinais aquisitados no outro dia para testar os modelos construídos. Neste dia de teste, somente o sinal de aceleração é fornecido aos algoritmos propostos, e o resultado dos modelos é então comparado com o sinal real aquisitado. Exemplos da comparação pode ser visto na figura 3.61.

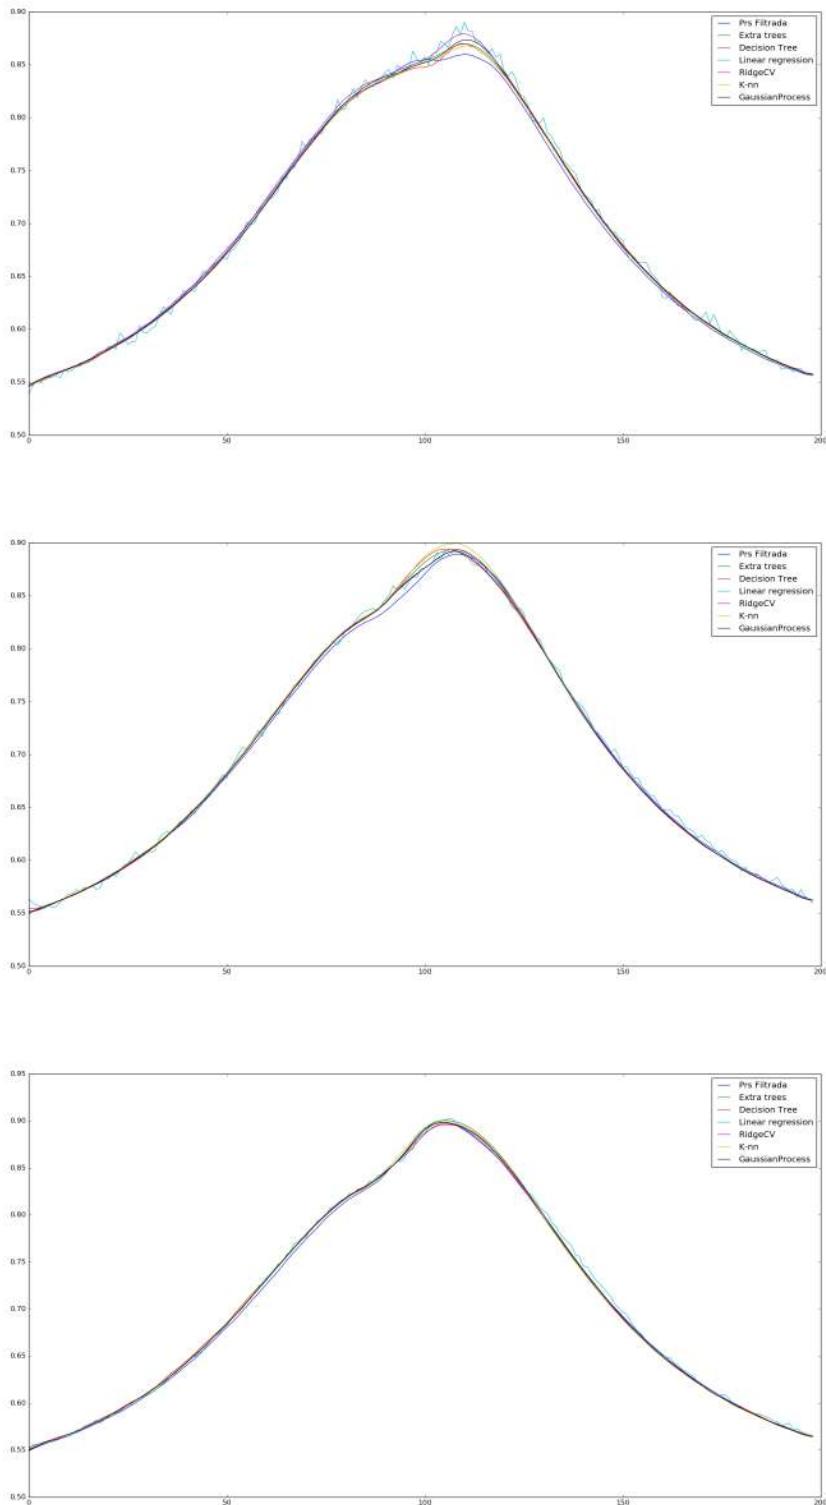


Figura 3.61: Resultados das regressões pelos modelos propostos.

Mais alguns exemplos são exibidos na figura 3.62.

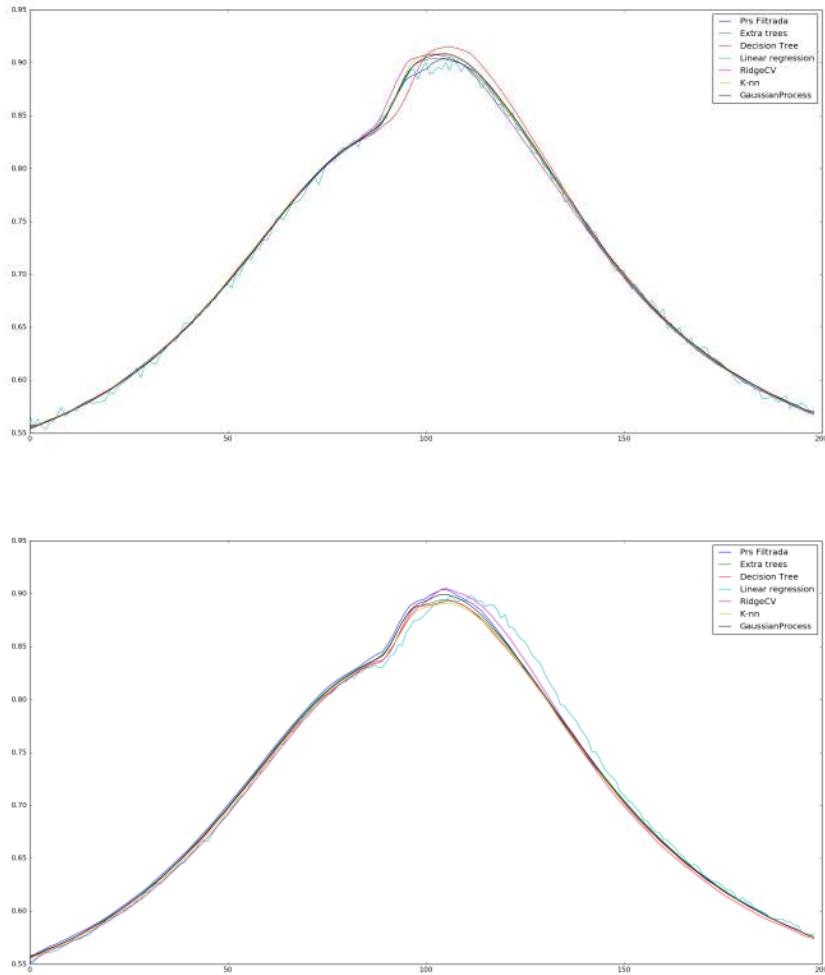


Figura 3.62: Resultados das regressões pelos modelos propostos.

3.5.5 Medida de Desempenho

Para medirmos o desempenho dos modelos de regressão, usaremos o coeficiente de correlação de Pearson, também chamado de coeficiente de correlação produto-momento, que mede o grau da correlação entre dois sinais.

Interpretando o coeficiente de correlação de Pearson (ρ):

- acima de 0.9 positivo ou negativo indica uma correlação muito forte.
- 0.7 a 0.9 positivo ou negativo indica uma correlação forte.
- 0.5 a 0.7 positivo ou negativo indica uma correlação moderada.
- 0.3 a 0.5 positivo ou negativo indica uma correlação fraca.
- 0 a 0.3 positivo ou negativo indica uma correlação desprezível.

O coeficiente de correlação de Pearson (ρ) é calculado através da seguinte fórmula:

$$\rho = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{cov(X, Y)}{\sqrt{var(X).var(Y)}} \quad (3.9)$$

Além do coeficiente de correlação de Pearson, usaremos também a medida de soma quadrática residual (*residual sum of squares - RSS*). Este coeficiente pode ser medido através da seguinte formula:

$$RSS = \sum_{i=1}^n (x_i - y_i)^2 \quad (3.10)$$

A interpretação desse índice é feita da seguinte maneira: quanto o menor o valor residual, mais próximo é o sinal estimado do sinal real medido.

3.5.6 Resultados

Os resultados para cada condição de carga (0, 25, 25, 75 e 100%) podem ser vistos nas tabelas a seguir:

CARGA 0%					
	Extra Trees	Decision Tree	Linear regression	RidgeCV	K-nn
ρ	0.979	0.961	0.944	0.959	0.974
RSS	0.962	1.606	5.143	2.149	0.853

Tabela 3.3: Carga 0%

CARGA 25%					
	Extra Trees	Decision Tree	Linear regression	RidgeCV	K-nn
ρ	0.993	0.988	0.979	0.993	0.991
RSS	0.588	0.911	1.782	0.614	0.723

Tabela 3.4: Carga 25%

CARGA 50%					
	Extra Trees	Decision Tree	Linear regression	RidgeCV	K-nn
ρ	0.994	0.988	0.970	0.992	0.994
RSS	0.484	0.950	2.004	1.015	0.461

Tabela 3.5: Carga 50%

CARGA 75%					
	Extra Trees	Decision Tree	Linear regression	RidgeCV	K-nn
ρ	0.995	0.989	0.926	0.967	0.994
RSS	0.516	1.265	5.711	2.428	0.634

Tabela 3.6: Carga 75%

CARGA 100%					
	Extra Trees	Decision Tree	Linear regression	RidgeCV	K-nn
ρ	0.992	0.989	0.959	0.988	0.990
RSS	0.923	1.231	2.148	0.685	1.323

Tabela 3.7: Carga 100%

Conclusão

Podemos notar que os resultados dos modelos obtiveram todos uma correlação bastante alta com o sinal real de pressão aquisitado. Os modelos que melhores se ajustaram ao problema de regressão do sinal de pressão a partir do sinal de aceleração pura, foram os algoritmos: *Extra Trees* e *Gaussian Process*, sendo o segundo o mais eficiente de todos os modelos, comparando as duas medidas de desempenho propostas.

3.6 Ensaios na Bancada

3.6.1 Configuração e Montagem da Bancada

O bloco do motor montado na bancada pode ser visto na figura 3.63.

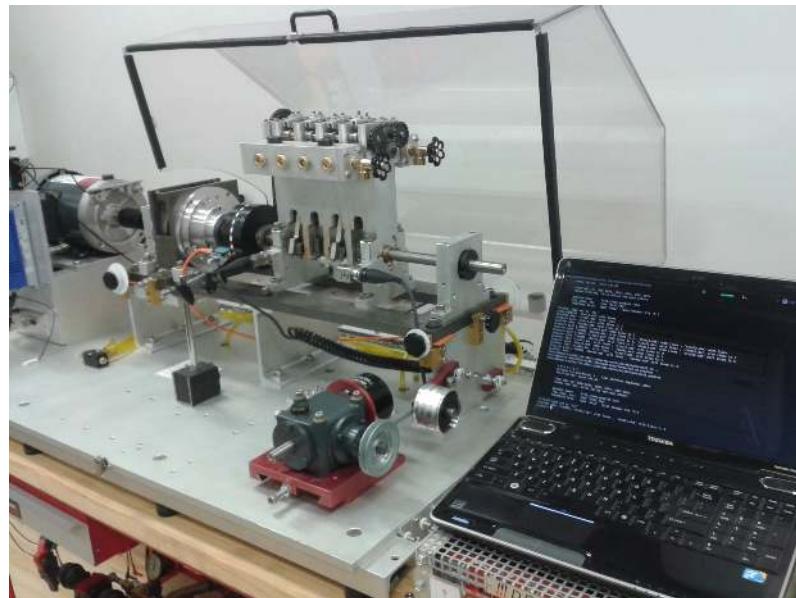


Figura 3.63: Bancada com motor a combustão.

Na figura 3.64 podemos ver mais detalhes do bloco do motor.

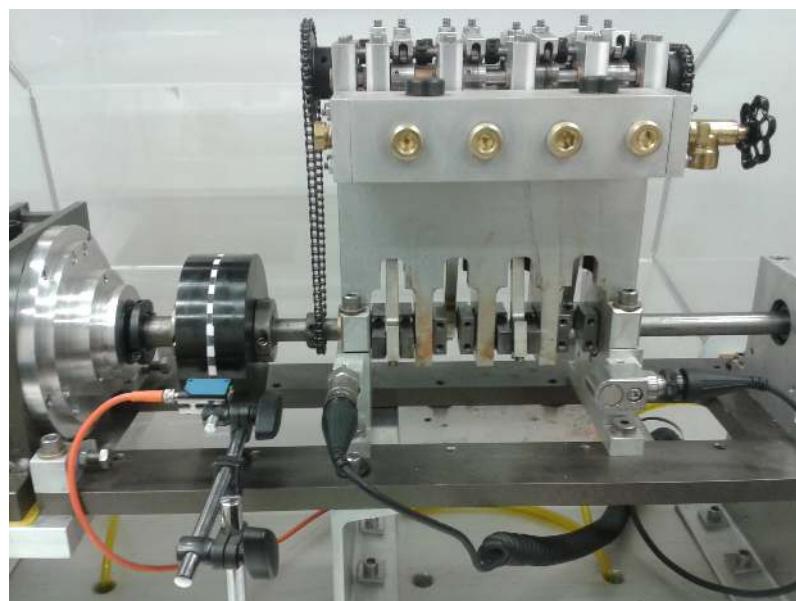


Figura 3.64: Bancada com motor a combustão.

3.6.2 Sinal de aceleração e rotação

O sinal de aceleração pura ($a(t)$) da metodologia pode ser observado na figura 3.65.

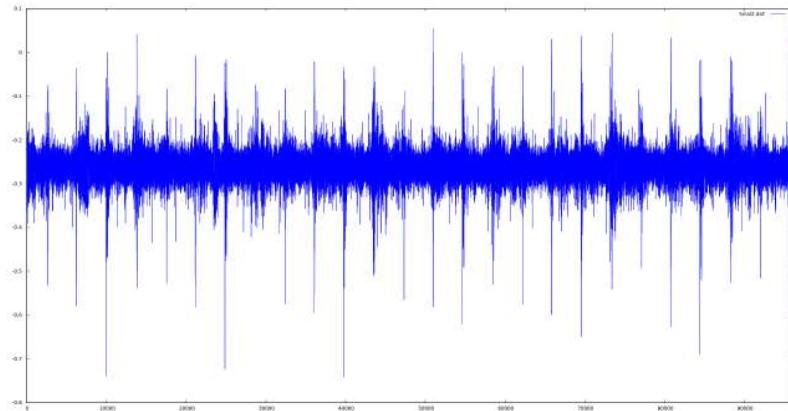


Figura 3.65: Sinal de aceleração pura do motor da bancada.

Podemos observar um zoom de um ciclo do sinal de aceleração na figura 3.66, juntamente com o sinal do tacômetro para a mesma porção do sinal.

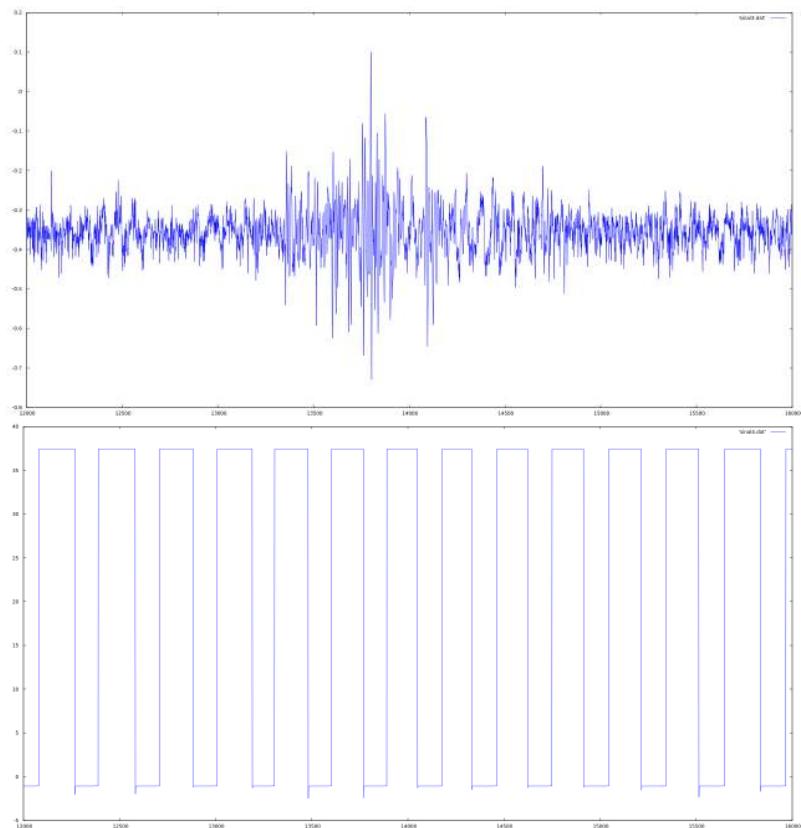


Figura 3.66: Um ciclo do sinal de aceleração pura e do tacômetro do motor da bancada.

No entanto, ainda não é possível medir a pressão interna no cilindro, para isso, algumas adaptações devem ser feitas na bancada, como apresentado na seção a seguir.

3.6.3 Adaptação da Bancada para medir Pressão

Para medirmos o sinal de pressão interno de cada cilindro na bancada, foi necessário realizar pequenos furos de acesso para o sensor à câmara de combustão. Esse furos podem ser observados na figura 3.67.

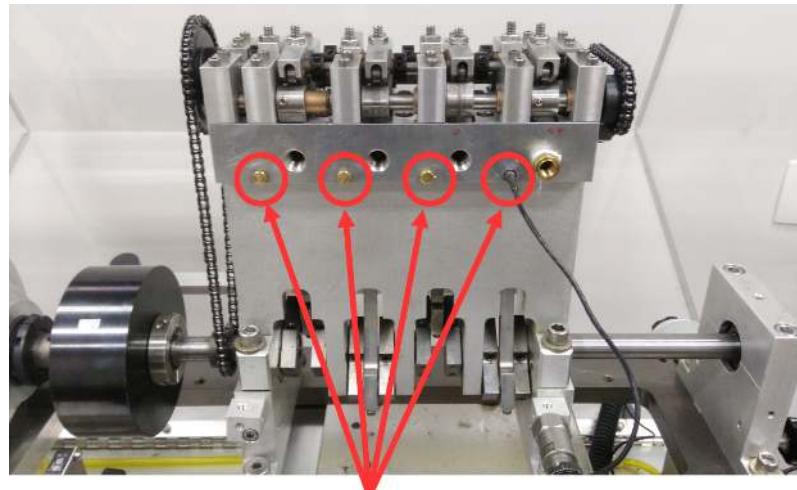


Figura 3.67: Localização dos furos na bancada.

Mais detalhes do posicionamento dos furos e seu acesso a câmara de combustão podem ser vistos na figura 3.68.



Figura 3.68: Detalhamento dos furos na bancada.

Para a aquisição dos sinais de pressão, foi necessário a aquisição de um outro sensor de pressão com um range menor, de 0 a 10bar. O sensor original, demonstrado na seção 3.3.1, tem um range de 0 a 100bar, normal para o monitoramento de motores

de médio a grande porte. Porém para os ensaios na bancada, as pressões internas ao cilindro não ultrapassam os 3bar , ficando muito baixo na escala de medição do sensor original e consequentemente com muito ruído.

Dessa forma, foi comprado o sensor que pode ser visto na figura 3.69, que além de ter um range de pressão mais favorável, também possui um tamanho bem menor, facilitando a furação e instalação do mesmo na bancada de teste.



Figura 3.69: Sensor de pressão utilizado na bancada.

Com a bancada devidamente preparada e o sensor comprado e adaptado ao sistema de aquisição descrito na seção 3.3, foi possível realizar as aquisições dos sinais da bancada.

Sinais de vibração, rotação e pressão

Analizando um dos quatro cilindros da bancada, podemos notar que são necessários dois ciclos para o correto funcionamento do processo de combustão. Adotaremos o ponto de máxima distância do pistão em relação ao virabrequim o TDC (*Top Dead Center*) como referência.

Ao atingir o TDC, abre-se a válvula de admissão, enquanto o pistão faz o percurso em direção ao BDC (*Bottom Dead Center*), posição mais próxima do pistão em relação ao virabrequim. Neste percurso, a mistura de ar e combustível é inserida na câmara de combustão do cilindro. Há então a compressão necessária para a combustão da mistura dentro da câmara do cilindro. Para isso, ambas as válvulas se encontram fechadas durante esse ciclo. E por fim, enquanto o pistão sobe em relação ao eixo até atingir novamente o TDC (*Top Dead Center*) e a válvula de escape está aberta, é feita a exaustão dos gases resultantes da combustão.

Este processo pode ser visto na imagem 3.70, a seguir:

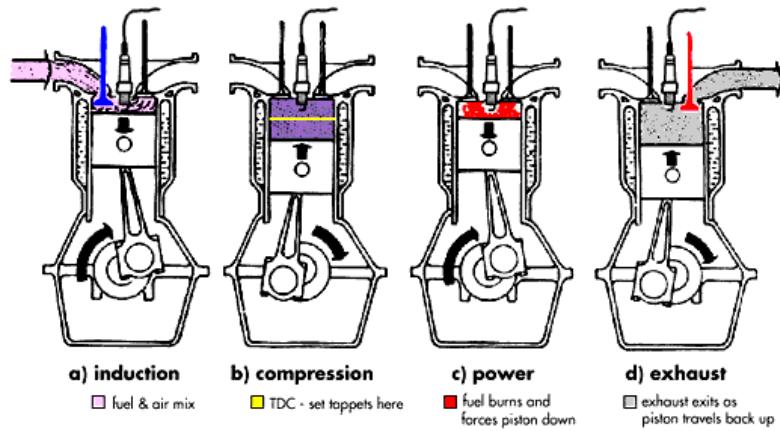


Figura 3.70: Ciclos do processo de combustão.

Na bancada de teste, não ocorre o processo de combustão em si, então na admissão e exaustão não há a presença de combustível, nem há explosão no ciclo de combustão. Tendo isso em vista, podemos ver os sinais de pressão, vibração e de rotação medidos diretamente da bancada. Em roxo o sinal de pressão, em azul o de vibração, através de aceleração pura e em amarelo o sinal do tacômetro, usado como referência no eixo do comando de válvula.

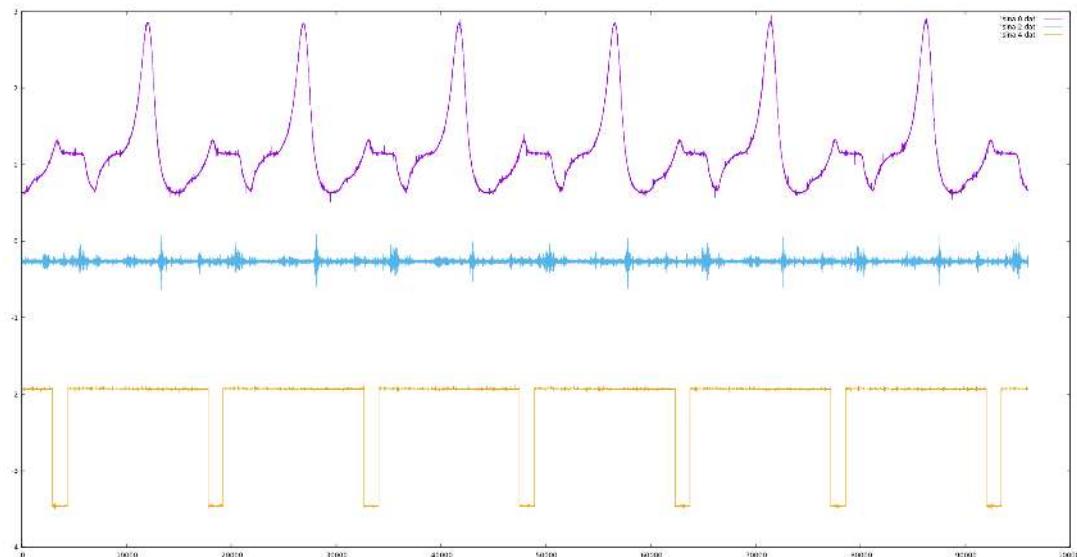


Figura 3.71: Sinais aquisitados da bancada.

Na figura 3.71, é possível ver vários ciclos consecutivos de funcionamento do motor na bancada, enquanto na figura 3.72 vemos em detalhes as quatro fases do processo de combustão descritos e exemplificados na figura 3.70, sendo eles: admissão, compressão, força e exaustão, consecutivamente.

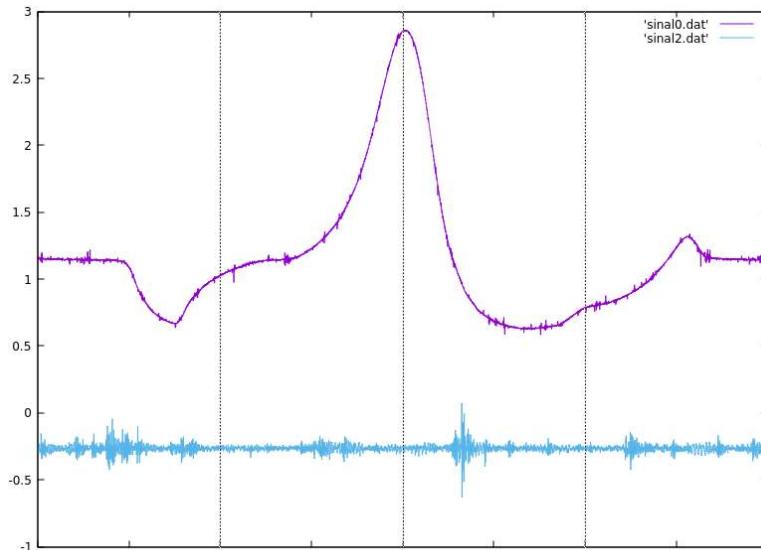


Figura 3.72: Zoom dos sinais aquisitados na bancada.

3.6.4 Regressão do Sinal de Pressão

O procedimento de regressão do sinal de pressão, através dos sinais aquisitados de vibração é o mesmo apresentado na seção 3.5. Para isso, são necessárias as mesmas etapas de *slicing* dos sinais e de preparo dos sinais de pressão e aceleração pura. A seguir seguem os resultados dessas etapas para os sinais aquisitados na bancada.

Slicing dos Sinais

Assim como descrito em 3.5.1, os sinais têm de ser divididos, com o intuito de separar os ciclos consecutivos de admissão, combustão e exaustão dos sinais aquisitados da bancada. Para isso, nessa etapa, utilizamos o tacômetro, instalado diretamente no comando de válvula, que permite identificar propriamente todo o intervalo necessário, como pode ser visto na figura 3.71.

Assim, alguns exemplos dos sinais segmentados podem ser vistos na figura 3.73.

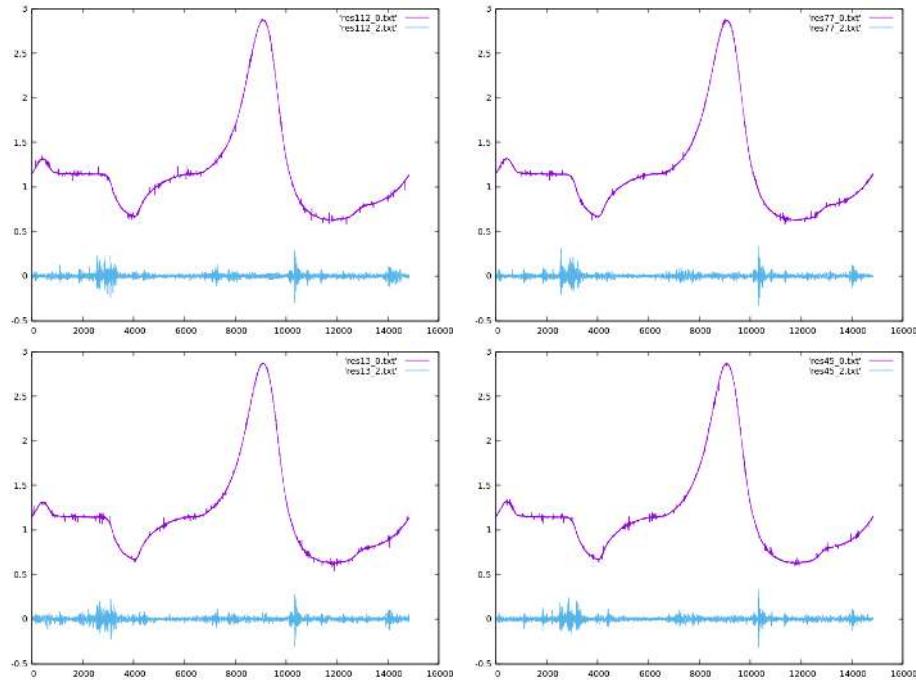


Figura 3.73: *Slicing* dos sinais aquisitados na bancada.

Uma vez segmentados os sinais, é necessário fazer os pré-processamentos de preparo dos sinais, como pode ser visto a seguir.

Preparo dos sinais de pressão

O sinal de pressão é filtrado e decimado, assim como descrito em 3.5.2. Um exemplo do sinal de pressão filtrado e decimado pode ser visto na figura 3.74. Em roxo o sinal de pressão filtrado e decimado, e em azul o sinal de pressão original.

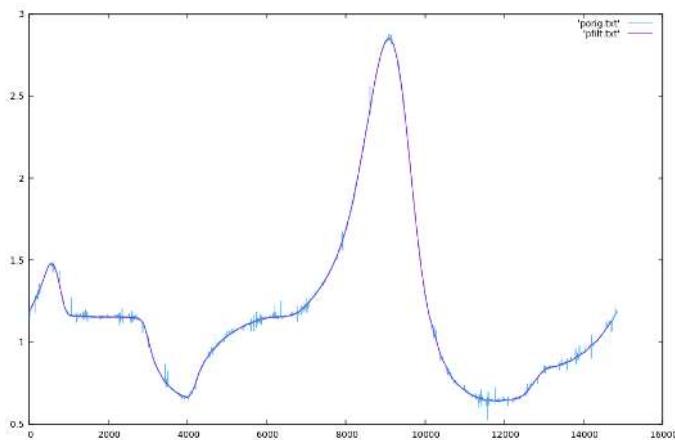


Figura 3.74: Sinal de pressão filtrado e decimado.

Preparo dos sinais de aceleração

O sinal de vibração é preparado assim como descrito em 3.5.3. Um exemplo do sinal de aceleração pode ser visto na figura 3.75. Em azul o sinal de aceleração original, em roxo o final filtrado e em amarelo o sinal resultante.

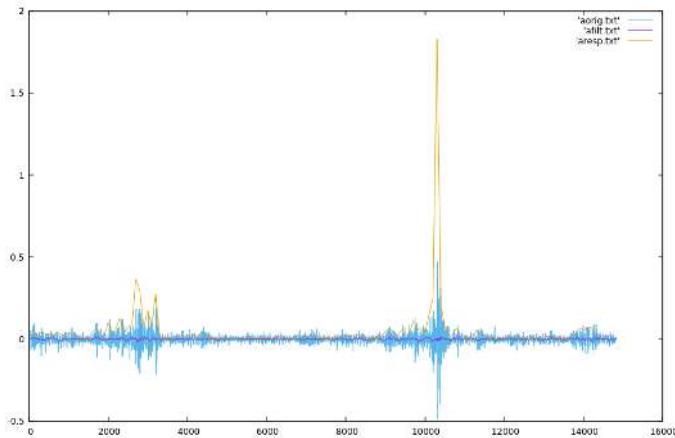


Figura 3.75: Sinal de aceleração filtrado e decimado.

Treinando os modelos

Os mesmos modelos utilizados em 3.5.4 serão utilizados para a regressão do sinal de pressão a partir do sinal de aceleração. Os modelos usados são os seguintes:

- Decision Tree
- Extra trees
- K-nn
- Linear regression
- RidgeCV

E as métricas de desempenho também seguem os mesmos critérios propostos na seção 3.5.5: coeficiente de correlação de Pearson (ρ); e soma quadrática residual (*residual sum of squares - RSS*).

Resultados

A seguir podem ser vistos alguns exemplos dos resultados da comparação entre os sinais aprendidos através dos modelos com relação ao sinal real de pressão aquisitado da bancada. Em azul o sinal real de pressão aquisitado, e nas demais cores, o resultado da regressão dos modelos.

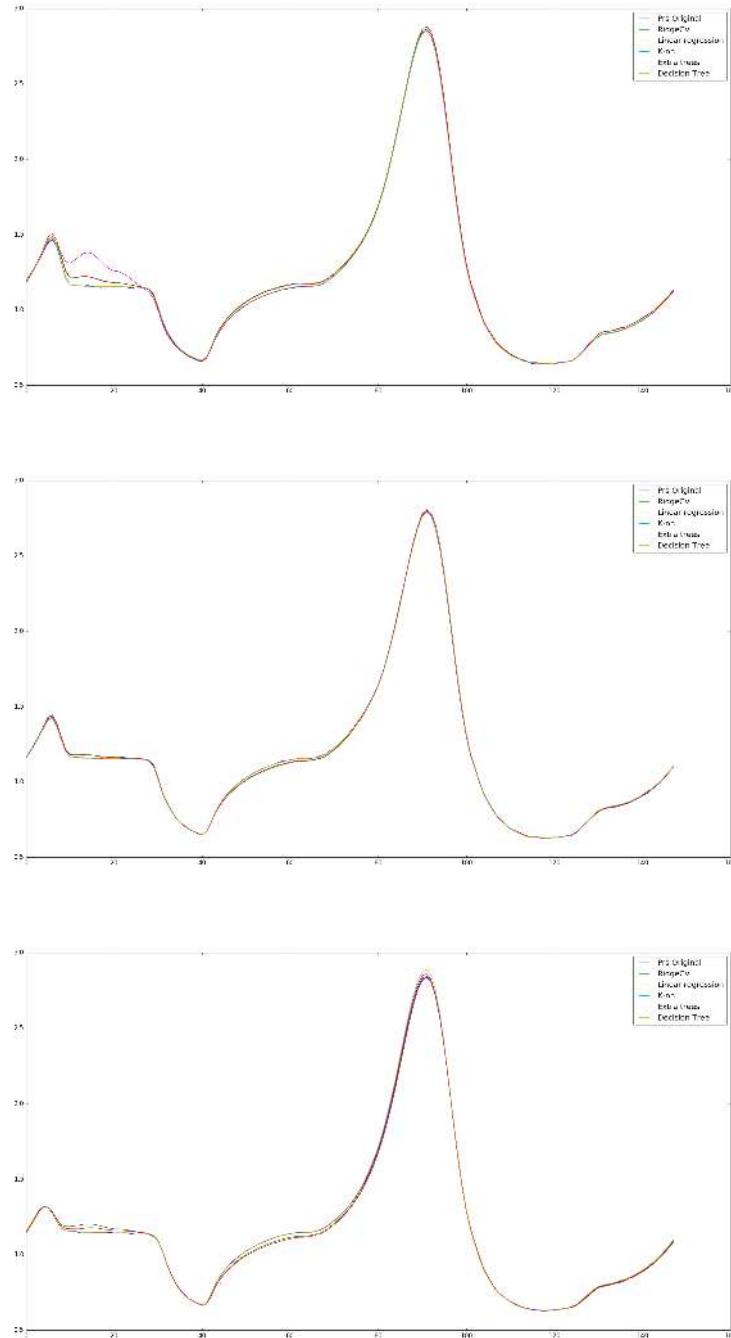


Figura 3.76: Comparação dos sinais aprendidos com o sinal de pressão real.

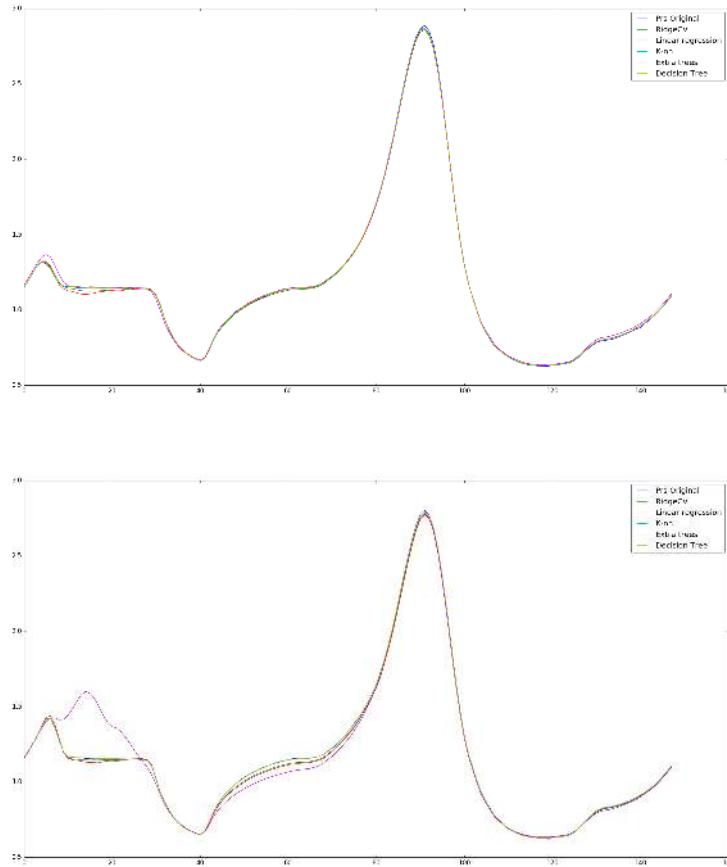


Figura 3.77: Comparação dos sinais aprendidos com o sinal de pressão real.

E os resultados para as medidas de desempenho da regressão dos sinais podem ser vistos na tabela 3.8.

	Desempenho das regressões					
	Extra Trees	Decision Tree	Linear regression	RidgeCV	K-nn	Gaussian Process
ρ	0.999	0.999	0.891	0.999	0.999	0.999
RSS	0.617	0.666	6.621	0.512	0.551	0.733

Tabela 3.8: Resultados da comparação dos sinais aprendidos.

Assim como nos resultados obtidos em 3.5.6, os resultados da comparação dos sinais aprendidos foram muito próximos aos sinais reais de pressão aquisitados diretamente na bancada. Foram testados um conjunto de 108 ciclos de pressão, todos com o motor na mesma condição de regulagem e rotação. Esses dados foram obtidos através de *cross-validation* (validação cruzada). A validação cruzada é uma técnica para avaliar a capacidade de generalização de um modelo, a partir de um conjunto de dados. Esta técnica é amplamente empregada em problemas onde o objetivo da modelagem é a predição. Busca-se então estimar o quão preciso é este modelo na prática, ou seja, o seu desempenho para um novo conjunto de dados.

Validação cruzada consiste em dividir o conjunto total de dados em k subconjuntos mutuamente exclusivos do mesmo tamanho e, a partir disto, um subconjunto é utilizado para teste e os $k - 1$ restantes são utilizados para estimativa dos parâmetros e calcula-se a acurácia do modelo. Esse processo foi repetido 20 vezes, para vinte partições aleatórias de subconjuntos diferentes, e depois tirada a média das medidas de desempenhos adotadas, para as duas medidas de desempenho utilizadas (ρ e RSS).

3.6.5 Simulação de Falhas na Bancada

Na seção anterior, reproduzimos os resultados de regressão do sinal de pressão ($p_r(t)$) a partir do sinal de aceleração pura medido diretamente do bloco do motor da bancada ($a(t)$), após filtrado e preparado ($a_p(t)$). Calculamos os erros ($e(t)$) desse aprendizado de acordo com os modelos utilizados.

No entanto, a grande vantagem da utilização da bancada, é a possibilidade de inserirmos algumas falhas conhecidas (F_b) no motor de combustão e identificar como essas falhas influenciam os sinais de aceleração ($a_f(t)$) e o quanto essa influência prejudica a reconstrução do sinal de pressão. Essa etapa do estudo está exemplificada na figura 3.78.

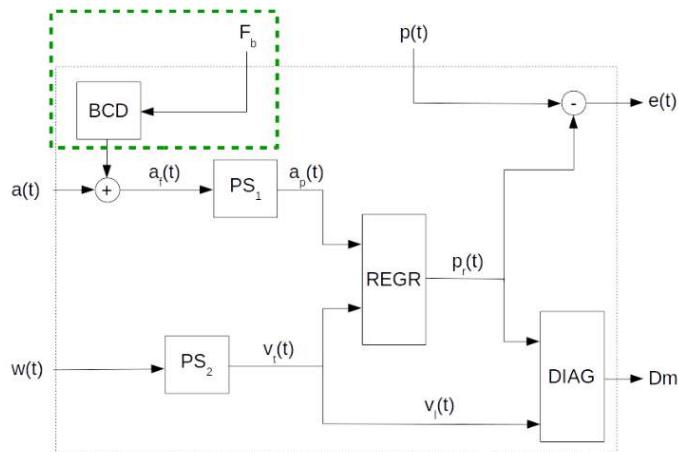


Figura 3.78: Inserção de falhas conhecidas na bancada.

Falhas Induzidas

Para os ensaios na bancada, as falhas não destrutivas mais fáceis de serem simuladas são as falhas vinculadas às válvulas. Pela tabela de probabilidade de falhas 3.1 apresentada na seção 3.1, essas falhas representam mais de 5% das falhas apresentadas por motores de combustão.

As válvulas de cada cilindro podem ser ajustadas para ficarem permanentemente abertas, permanentemente fechadas, ou abrindo e fechando adequadamente. É possível ver em detalhes as válvulas de admissão e exaustão de um dos cilindros na figura 3.79.

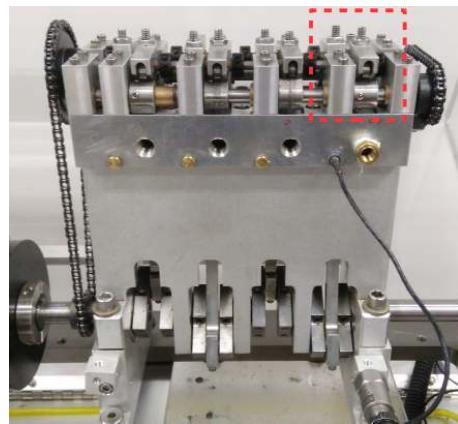


Figura 3.79: Detalhe das válvulas de um cilindro.

Válvula de Admissão Travada

Para simular falha de válvula travada na bancada, basta soltar a porca que ajusta a válvula (vide figura 3.79), de tal forma que ela não possua mais contato com o comando de válvula. Dessa forma, a válvula de admissão permanece fechada por todo o tempo. O resultado dessa falha induzida nos sinais de aceleração e pressão pode ser visto na figura 3.80.

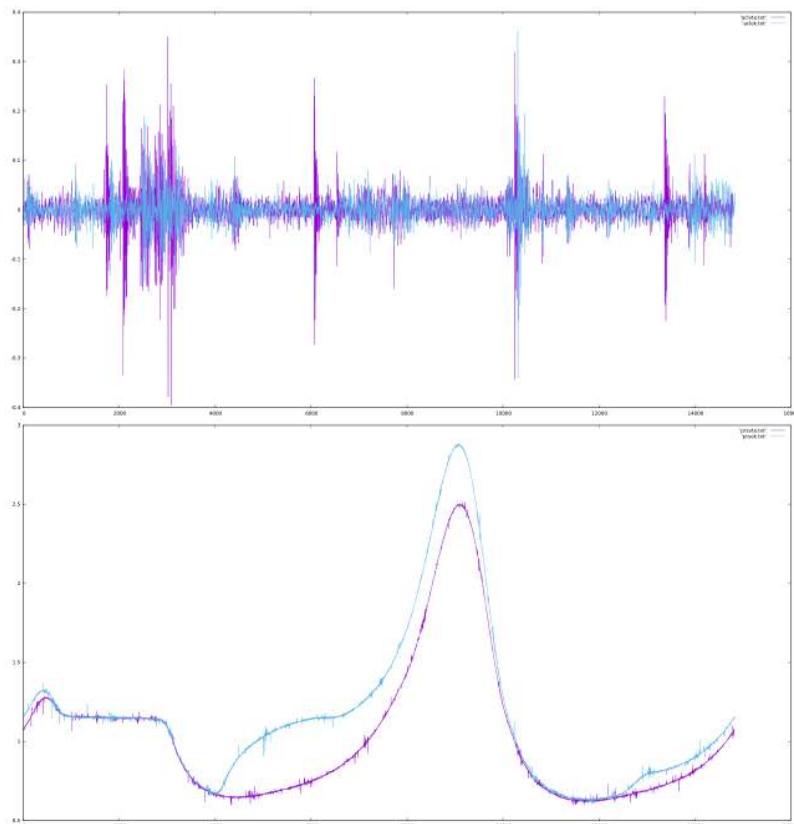


Figura 3.80: Comparação dos sinais de referência e com válvula de admissão travada.

As curvas em azul nas imagens são os sinais aquisitados para o motor regulado

corretamente, entanto as curvas em roxo são os sinais aquisitados com a válvula de admissão travada. Pode-se notar no sinal de aceleração alguns picos de vibração no sinal com a válvula travada que não aparecem no sinal de referência do motor regulado.

No sinal de pressão, pode-se notar que a maior diferença se encontra na fase de admissão (antes do ciclo de combustão). Com a válvula travada, nesta fase, crie-se uma período de pressão negativa interno ao cilindro durante todo o percurso do pistão. Para o motor corretamente regulado, esse período de pressão negativa ocorre somente até o momento da abertura da válvula, que zera a pressão interna até o final do percurso do pistão até o BDC.

Válvula de Escape Travada

Similar ao procedimento de simulação da falha anterior, para travarmos a válvula de escape basta soltar a porca de ajuste desta no comando de válvula, fazendo com que ela se mantenha fechada durante o funcionamento do motor. O resultado dessa falha induzida nos sinais de aceleração e pressão pode ser visto na figura 3.81.

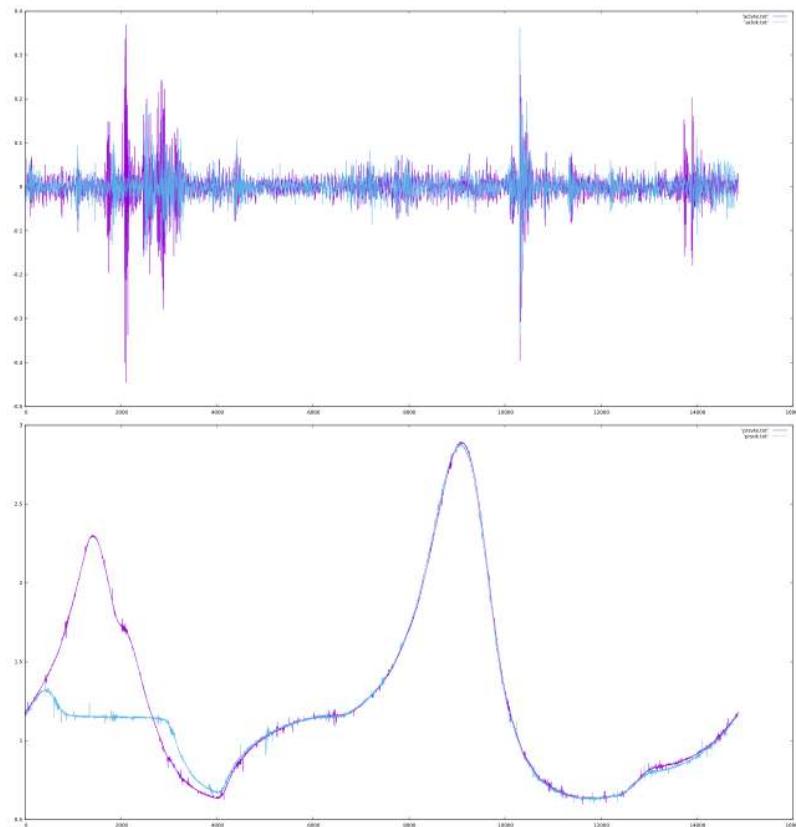


Figura 3.81: Comparação dos sinais de referência e com válvula de escape travada.

As curvas em azul nas imagens são os sinais aquisitados para o motor regulado corretamente, enquanto as curvas em roxo são os sinais aquisitados com a válvula de escape travada. Assim como para válvula de admissão, pode-se notar no sinal de aceleração alguns picos de vibração no sinal com a válvula de escape travada que não aparecem no sinal de referência do motor regulado.

O sinal de pressão se diferencia do motor regulado na fase de exaustão, no início do gráfico. Nesta fase, pelo fato do pistão estar em seu percurso de subida até o TDC e a válvula de exaustão permanecer fechada, há um aumento na pressão interna do cilindro, o que não acontece no motor regulado.

Válvula Vazando

Para simular falha de válvula vazando, independente se for de admissão ou de escape, basta apertar a porca de ajuste da válvula até mantê-la permanentemente aberta durante o funcionamento do motor. Independente de qual válvula estiver vazando, o comportamento dos sinais de aceleração e de pressão é o mesmo e pode ser visto na figura 3.82.

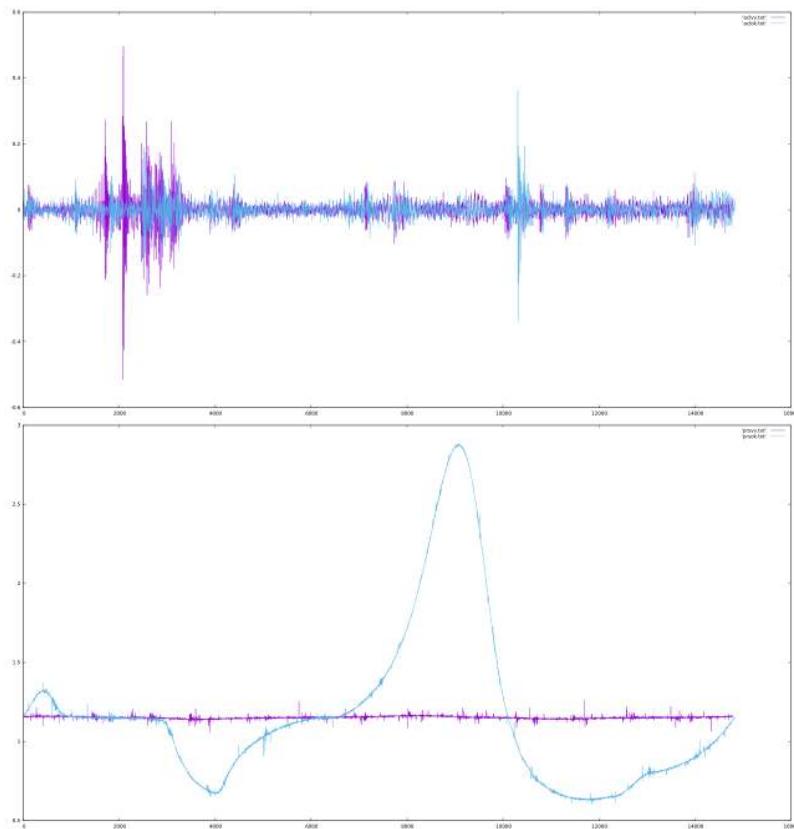


Figura 3.82: Comparação dos sinais de referência e com válvula vazando.

Neste caso, há uma alteração no sinal de aceleração, mas a alteração mais significativa é com relação ao sinal de pressão. Uma vez que há uma das válvulas constantemente aberta, em momento algum há variação de pressão interna no cilindro.

Influência de Falhas no Modelo

Nas seções anteriores vimos como a inserção de falhas na bancada influencia os sinais de aceleração e de pressão aquisitados. Como a metodologia proposta no trabalho

é de utilizar o sinal de aceleração para aprender o sinal de pressão, é necessário verificar o quanto essa influência nos sinais poderia afetar os modelos de regressão.

Para isso, foram misturadas todas as condições de funcionamento do motor. O motor regulado, com válvula de admissão travada e com válvula de escape travada. A falha de válvula vazando não gera sinal de pressão interna ao cilindro por isso os sinais aquisitados nessa condição não foram utilizados nessa etapa de validação dos modelos na presença de falhas.

Uma vez feito isso, geramos um conjunto total de 327 amostras de sinais misturados entre motor regulado e com falhas nas válvulas. Novamente foi feita uma validação cruzada para a estimativa da acurácia dos modelos, repetindo-se 20 vezes o processo para subconjuntos aleatoriamente escolhidos para teste. Os resultados podem ser visto na tabela 3.9

Desempenho das regressões						
	Extra Trees	Decision Tree	Linear regression	RidgeCV	K-nn	Gaussian Process
ρ	0.953	0.987	0.983	0.993	0.999	0.995
RSS	4.705	1.032	2.917	1.926	0.588	1.847

Tabela 3.9: Resultados da comparação dos sinais aprendidos com falhas misturadas.

Pode-se notar, pelos resultados obtidos com os sinais de falha misturados aos sinais do motor regulado, que os modelos de regressão tiveram uma medida de desempenho um pouco menor, ou seja, um erro ligeiramente maior do que quando os sinais eram somente do motor regulado. No entanto, os valores de correlação (ρ) dos sinais de pressão aquisitados e aprendidos pelos modelos ainda ficam muito próximos dos 99%, resultados que indicam alto índice de correlação. A medida de soma quadrática residual (RSS) também se manteve relativamente baixa, principalmente para o modelo de *KNN* proposto.

Interferência entre Cilindros

Nas seções anteriores, testamos os modelos de maneira isolada nos cilindros. No entanto, é possível verificar na bancada a influência de uma falha em um cilindro interferir no modelo de aprendizado do sinal de pressão em outro cilindro.

Na seção anterior (3.6.5), o conjunto de dados continha os sinais do motor regulado, com a válvula de admissão de um cilindro travada e a válvula de escape do mesmo cilindro travada. Neste ensaio, além desses dados, há também os sinais com a válvula de admissão de um outro cilindro travada e a válvula de escape deste outro cilindro travada. Apesar dessas válvulas apresentarem defeito, a válvula do cilindro sendo monitorado com o acelerômetro estava com ambas as válvulas reguladas. Dessa forma, o esperado era que nesses casos, a falha simulada nas válvulas de um outro cilindro, que não o cilindro cujo sinal de aceleração estava sendo aquisitado, não gerasse qualquer interferência no processo.

Os resultados com esses conjuntos de dados podem ser visto na tabela 3.10.

O conjunto de dados possui 548 amostras de sinais com o motor totalmente regulado, com as válvulas do cilindro monitorado travadas (admissão e escape) e

Desempenho das regressões					
	Extra Trees	Decision Tree	Linear regression	RidgeCV	K-nn
ρ	0.970	0.983	0.989	0.992	0.999
RSS	3.145	1.167	2.259	1.877	0.566

Tabela 3.10: Resultados da comparação dos sinais aprendidos com falhas misturadas em cilindro diferentes.

com válvulas de outro cilindro que não o monitorado travadas (admissão e escape). Podemos notar pouca influência nos resultados das regressões nessas condições se compararmos com os resultados gerados anteriormente, na tabela 3.9.

Portanto podemos concluir que o modelo responde com bastante independência da influência de vibrações oriundas de outros cilindros.

3.6.6 Diagnóstico de Falhas na Bancada

Nas seções anteriores demonstramos a possibilidade da inserção de falhas na bancada e a influência dessas falhas nos sinais de aceleração e pressão aquisitados. Ainda, mostramos que mesmo os sinais com falha ainda permitiam aos modelos aprender o sinal de pressão com alta precisão, de acordo com os resultados apresentados e as medidas de desempenho adotadas.

Porém, além da inserção e da influência das falhas simuladas nos sinais, é possível realizar o diagnóstico automático dessas falhas, utilizando os sinais de aceleração e de pressão aprendidos a partir dos modelos (sem utilizar o sinal real de pressão aquisitado). Essa etapa foi descrita na metodologia proposta, como pode ser vista na figura 3.83.

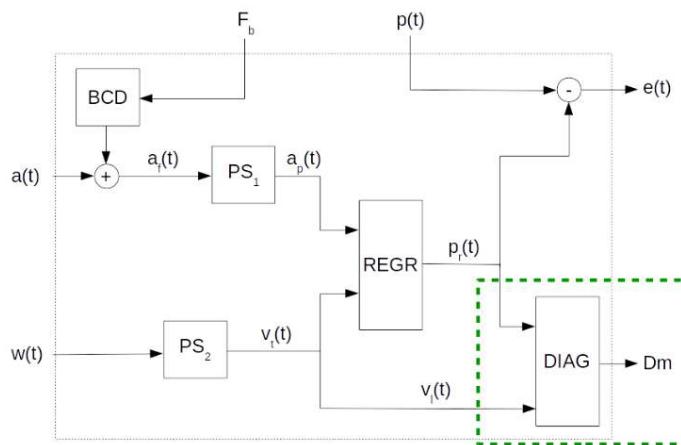


Figura 3.83: Diagnóstico das falhas conhecidas na bancada.

Para fazer o diagnóstico de falhas, é necessário olhar, assim como na seção anterior, para um cilindro como referência. O objetivo é identificar se este cilindro está regulado, com válvula de admissão travada ou com a válvula de escape travada, tomando como base a princípio somente o sinal de aceleração.

Para a classificação da falha, utilizamos o mesmo conjunto de dados de 548 ciclos de exemplo, incluindo uma combinação aleatória das três condições citadas do motor. Utilizamos os seguintes modelos para classificação de falhas:

- K-nn
- Decision Tree
- SVM
- ADABoost
- Gaussian Process
- Random Forest
- Redes Neurais MLP
- QuadraticDiscriminant

A seguir, são apresentados os resultados de classificação dos modelos para todo o conjunto de exemplos de 548 ciclos, incluindo o motor regulado (OK), com a válvula de admissão travada (VTA) e com a válvula de escape travada (VTE). As matrizes apresentadas mostram nas linhas a classificação real da amostra e nas colunas a classificação prevista por cada modelo separadamente. Portanto a diagonal principal da matriz apresenta o número de acertos do modelo, enquanto as outras posições indicam erros de classificação.

		PREVISTO		
		OK	VTA	VTE
REAL	OK	329	0	0
	VTA	0	108	0
	VTE	0	0	111

Tabela 3.11: Resultados para o K-nn

		PREVISTO		
		OK	VTA	VTE
REAL	OK	329	0	0
	VTA	0	108	0
	VTE	0	0	111

Tabela 3.12: Resultados para o Decision Tree

		PREVISTO		
		OK	VTA	VTE
REAL	OK	329	0	0
	VTA	0	108	0
	VTE	0	0	111

Tabela 3.13: Resultados para o SVM

		PREVISTO		
		OK	VTA	VTE
REAL	OK	322	7	0
	VTA	15	93	0
	VTE	0	0	111

Tabela 3.14: Resultados para o ADABoost

		PREVISTO		
		OK	VTA	VTE
REAL	OK	329	0	0
	VTA	0	108	0
	VTE	0	0	111

Tabela 3.15: Resultados para o Gaussian Process

		PREVISTO		
		OK	VTA	VTE
REAL	OK	329	0	0
	VTA	0	108	0
	VTE	3	0	108

Tabela 3.16: Resultados para o Random Forest

		PREVISTO		
		OK	VTA	VTE
REAL	OK	329	0	0
	VTA	27	80	1
	VTE	0	0	111

Tabela 3.17: Resultados para o Redes Neurais MLP

		PREVISTO		
		OK	VTA	VTE
REAL	OK	329	0	0
	VTA	27	80	1
	VTE	0	0	111

Tabela 3.18: Resultados para o QuadraticDiscriminant

Uma vez feito isso, geramos a partir do conjunto total de 548 amostras de sinais uma validação cruzada para a estimativa da acurácia dos modelos, repetindo-se 20 vezes o processo para subconjuntos aleatoriamente escolhidos para teste. Os resultados podem ser visto na tabela 3.19

	Desempenho das Classificações							
	KNN	DT	SVM	ADA	GP	RF	MLP	QD
Acurácia	1.0	0.99	1.0	0.94	1.0	0.87	1.0	0.6
Desvio	0.0	0.04	0.0	0.1	0.0	0.09	0.0	0.3

Tabela 3.19: Resultado da validação cruzada para os modelos de classificação.

Podemos notar que o desempenho de classificação é bastante alto, ou seja, é possível identificar a falha simulada na bancada apenas utilizando o sinal de aceleração pura, filtrada e tratada assim como utilizado para a regressão do sinal de pressão.

Conclusão

Neste capítulo, mostramos os ensaios realizados na bancada de teste. Para isso demonstramos a montagem e configuração da bancada assim como as alterações necessárias para que pudessem ser feitas as aquisições dos sinais de aceleração e pressão. Isso inclui a posição dos furos necessários e o sensor ideal para a correta tomada das medições.

Uma vez com a bancada preparada, mostramos que o processo de aprendizado, ou regressão do sinal de pressão, a partir do sinal de aceleração pura medido diretamente pelos acelerômetros no bloco do motor, se mostram eficientes também na bancada, assim como descrito na seção 3.4, que apresenta o processo e os resultados no laboratório. É possível concluir portanto, que o procedimento possui repetibilidade, tendo sido possível obter resultados muito aproximados dos sinais, tanto em um motor real, de médio porte, no laboratório, quanto em um motor de pequeno porte, montado na bancada de testes.

Pudemos também, neste capítulo, mostrar a influência de algumas falhas mecânicas nos sinais aquisitados (aceleração e pressão), assim como constatamos que essa influência pouco interfere na qualidade da regressão do sinal proposta pelo modelo. Ainda estudamos a interferência de uma falha simulada em um cilindro vizinho, na aquisição dos sinais de um cilindro de referência. Viu-se que é possível isolar o efeito das falhas entre cilindros, mesmo pra um bloco de pequeno porte, como o utilizado na bancada.

Além disso, mostrou-se que é possível identificar a influência das falhas simuladas nos sinais aquisitados, de tal forma a classificar qual a origem da falha. Com isso, tornou-se possível identificar automaticamente o defeito durante o funcionamento do motor.

3.7 Ensaios em Campo - Gera Amazonas

Apesar desta etapa não estar prevista no projeto, foram realizados ensaios na usina instalada em Manaus – Amazonas, uma vez que a unidade do Maranhão permaneceu em *Stand By* por um período prolongado de tempo. Com a necessidade da realização dos ensaios em campo, tomou-se a iniciativa de fazê-los na usina Gera Amazonas, mesmo tendo motores diferentes dos instalados na unidade do Maranhão.



Figura 3.84: Usina Gera Maranhão.

A usina Gera Amazonas possui 05 grupos geradores Wärtsilä W18V46, com potência de 17,076MW cada. Esses motores possuem 18 cilindros, 2 a menos que os motores instalados na unidade do Maranhão, porém o diâmetro do cilindro é consideravelmente maior: 460mm contra 320mm dos motores do maranhão. O curso do pistão é de 580mm e a biela possui 1050mm. A rotação desses motores é de 514rpm.

3.7.1 Adaptação do Sensor de Pressão

Com a finalidade de realizar as medições em campo, foi necessário adaptar o sensor de pressão utilizado no projeto, descrito na seção 3.3.1 para torná-lo mais robusto, com maior capacidade de dispersão térmica, para que este resistisse aos ensaios realizados nos motores em campo.

A figura 3.85 mostra o sistema de arrefecimento de um sensor de mercado, utilizado como modelo. Também é possível observar mais detalhes do sensor de pressão, da junta de conexão e do sistema de dissipação do calor do sensor.

Como os diâmetros dos sensores de mercado e o utilizado neste projeto diferem (como pode ser visto na figura 3.86), foi necessário desenvolver um adaptador para



Figura 3.85: Sensor de pressão de mercado.

que o sensor pudesse ser conectado a junta e ao sistema de arrefecimento. A comparação entre os sensores, o adaptador desenvolvido e o sensor de pressão montado, podem ser vistos na figura 3.86.



Figura 3.86: Adaptação do sensor de pressão.

Com o sensor devidamente adaptado para a junta dos pontos de inspeção dos motores, e com o sistema de arrefecimento necessário para suportar pelo menos a bateria de ensaios propostos, foi possível realizar as medições em campo.

3.7.2 Levantamento da Geometria dos Motores

Antes das medições serem realizadas, o levantamento dos dados de geometria do motor é necessário. As informações dos ângulos de combustão de cada cilindro, relativo à uma referência do virabrequim foram levantadas. Esta etapa é importante para a segmentação dos sinais aquisitados em porções correspondentes a cada ciclo de combustão por cilindro.

Esses dados foram levantados através de informações de *datasheet* dos motores e podem ser observados na figura 3.87 e na tabela 3.20 a seguir.

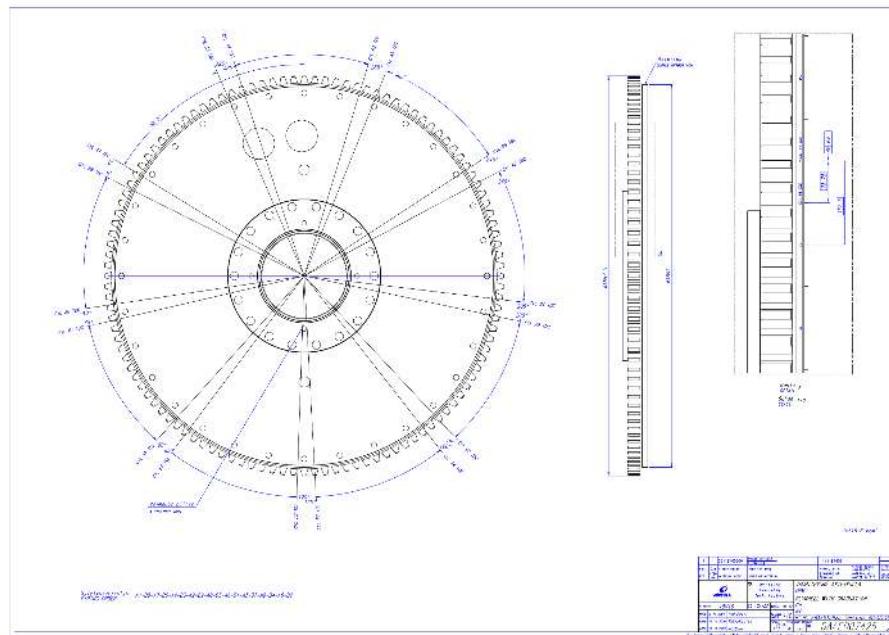


Figura 3.87: Datasheet com os ângulos dos cilindros.

Tabela 3.20: Ângulos de TDC dos cilindros.

Ângulos dos cilindros: Referência A1									
A1	A2	A3	A4	A5	A6	A7	A8	A9	
0	240	480	160	640	400	80	320	560	
B1	B2	B3	B4	B5	B6	B7	B8	B9	
405	645	165	565	325	85	485	5	245	

3.7.3 Posicionamento do Tacômetro

A tabela 3.20 mostra todos os ângulos de TDC de cada cilindro com referência ao ângulo do cilindro A1. Por isso, a fita reflexiva usada de referência do tacômetro, é posicionada exatamente no ponto demarcado como sendo o TDC do cilindro A1 no volante de inércia do motor. Este procedimento facilita a sincronização dos dados e posterior divisão dos sinais aquisitados em pedaços correspondentes ao ciclo de combustão de cada cilindro.



Figura 3.88: Marcação no volante de inércia.

Na figura 3.88 a seguir é possível ver uma marcação no volante do motor.

Através dessas marcações, e a partir do giro lento do motor, a fita reflexiva do tacômetro foi posicionada no ponto zero, de TDC do cilindro A1, usado como referência. Após a fixação da fita, o tacômetro foi instalado como na figura 3.89 para a realização das leituras, gerando um pulso a cada giro do volante, na posição do TDC do cilindro A1.

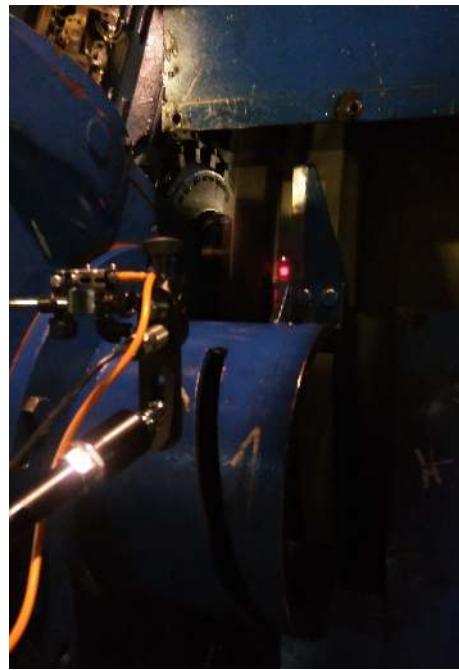


Figura 3.89: Leitura do tacômetro.

3.7.4 Medições

Com o sensor de pressão devidamente adaptado e os ângulos de referência de cada cilindro, foi possível realizar as medições dos motores em campo. Na figura 3.90 é possível observar as medidas sendo realizadas no motor em operação.



Figura 3.90: Medições sendo realizadas.

Na usina de Manaus, são 4 geradores em operação contínua e 1 motor que fica em *stand by*. Por isso, no período em que foram feitas as medições, 4 motores puderam ser marcados com a fita reflexiva e medidos através dos sensores de pressão e vibração propostos.

Os motores medidos foram os seguintes: DG#1W18V46, DG#2W18V46, DG#4W18V46 e DG#5W18V46. A seguir podemos ver algumas amostras dos sinais medidos de cada motor.

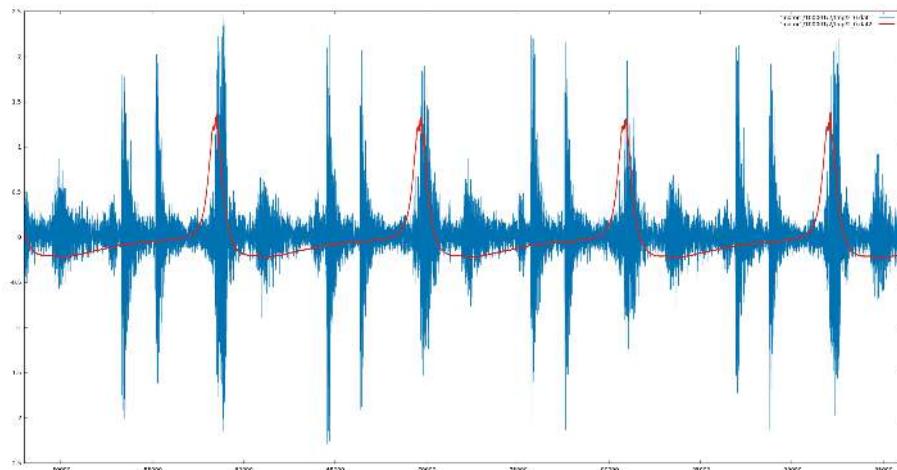


Figura 3.91: Sinal de vibração e pressão: Motor DG#1W18V46.

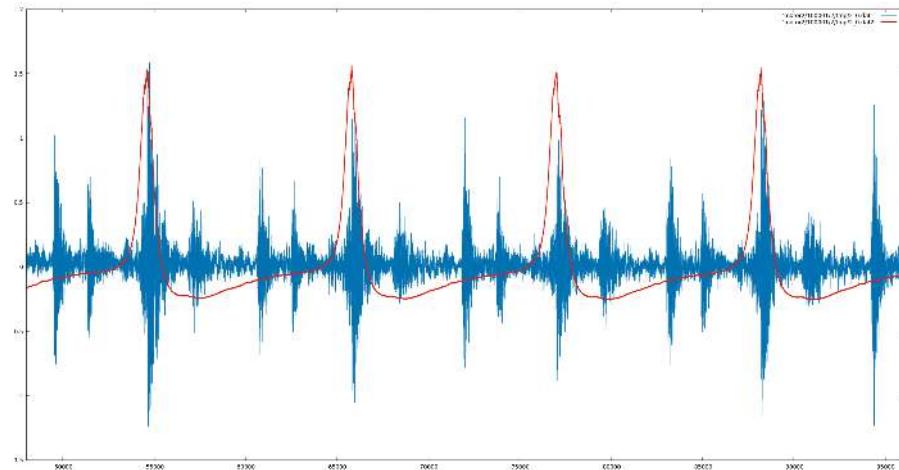


Figura 3.92: Sinal de vibração e pressão: Motor DG#2W18V46.

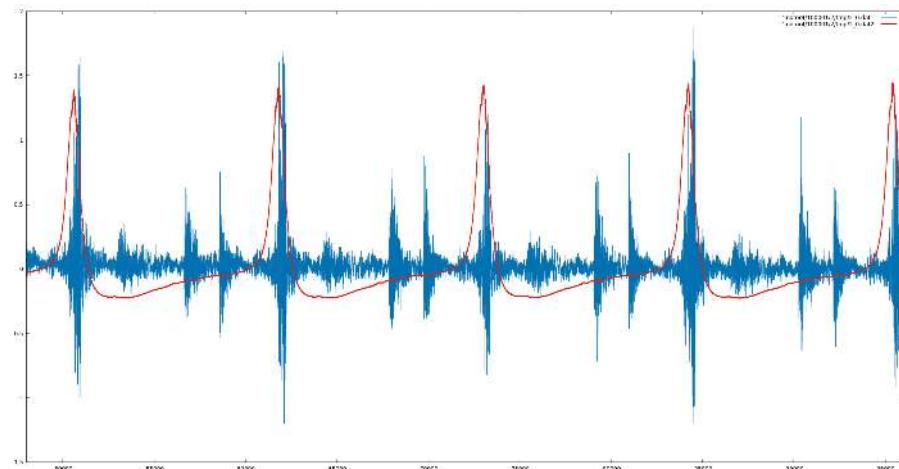


Figura 3.93: Sinal de vibração e pressão: Motor DG#4W18V46.

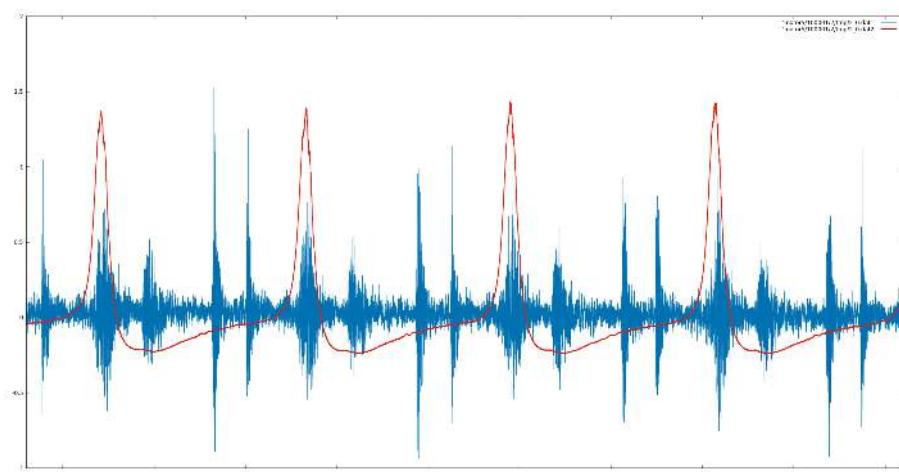


Figura 3.94: Sinal de vibração e pressão: Motor DG#5W18V46.

Nas figuras a seguir podemos ver como exemplo, o resultado da sincronização realizada através dos ângulos extraídos do *datasheet* dos motores.

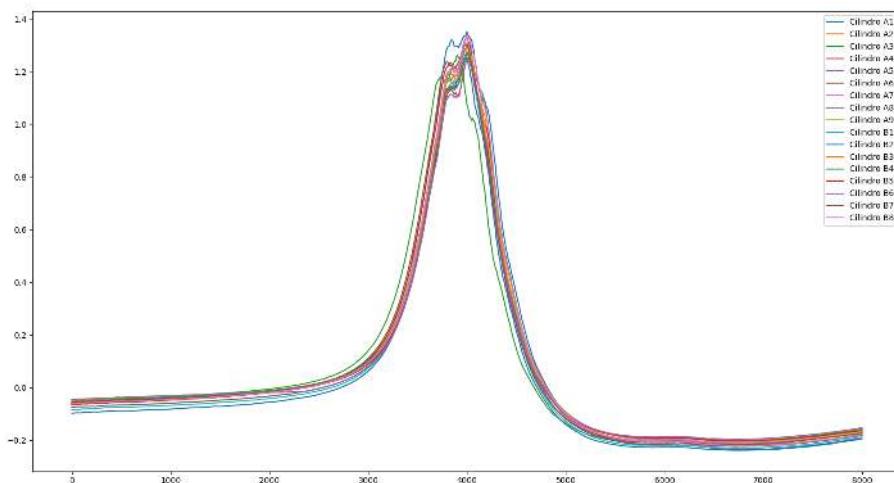


Figura 3.95: Pressões sobrepostas e sincronizadas. Motor DG#1W18V46.

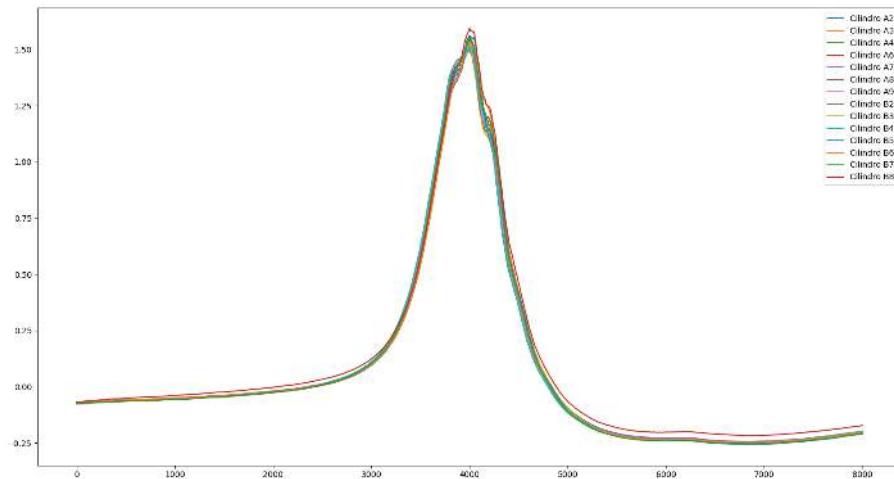


Figura 3.96: Pressões sobrepostas e sincronizadas. Motor DG#2W18V46.

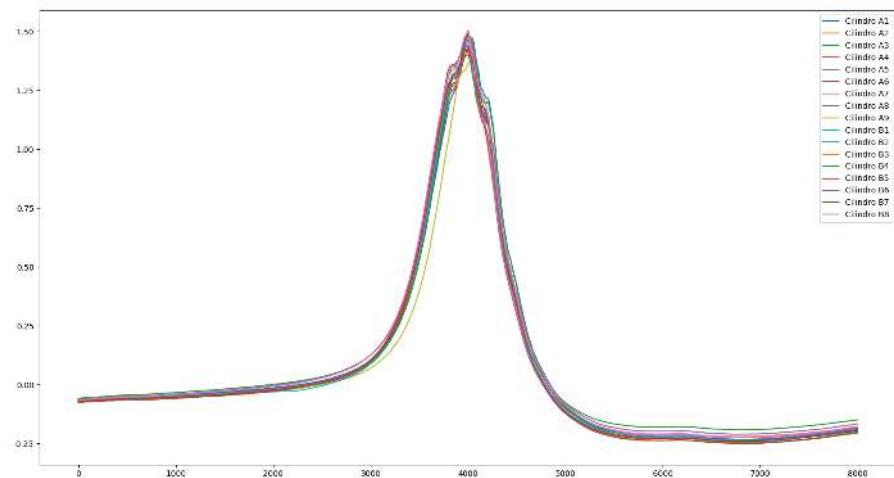


Figura 3.97: Pressões sobrepostas e sincronizadas. Motor DG#4W18V46.

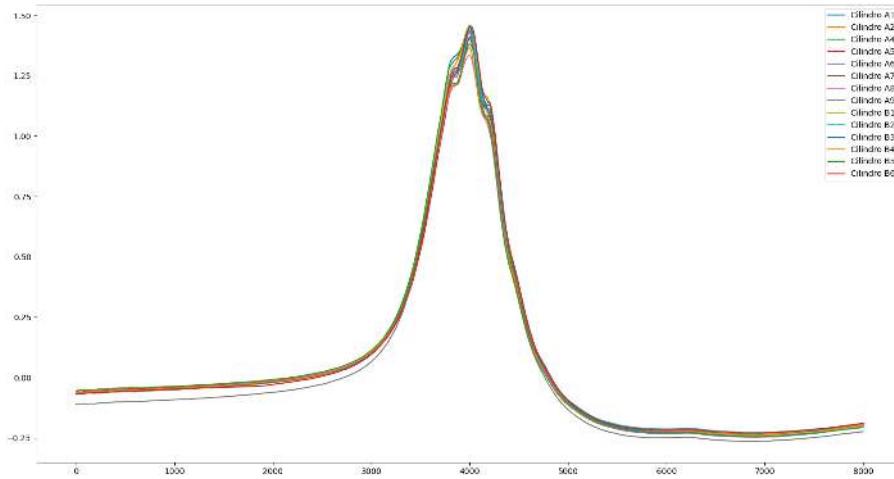


Figura 3.98: Pressões sobrepostas e sincronizadas. Motor DG#5W18V46.

3.7.5 Validação dos sinais medidos

Para validarmos os sinais medidos, foi utilizado um equipamento de monitoramento de motores de combustão utilizado no mercado. O equipamento em questão pode ser visto na figura 3.99 a seguir.



Figura 3.99: Equipamento de mercado para monitoramento da pressão em motor de combustão.

Para a validação, iremos plotar, lado a lado, os sinais de pressão medidos tanto pelo equipamento de mercado quanto pelo sistema de aquisição utilizado no projeto.

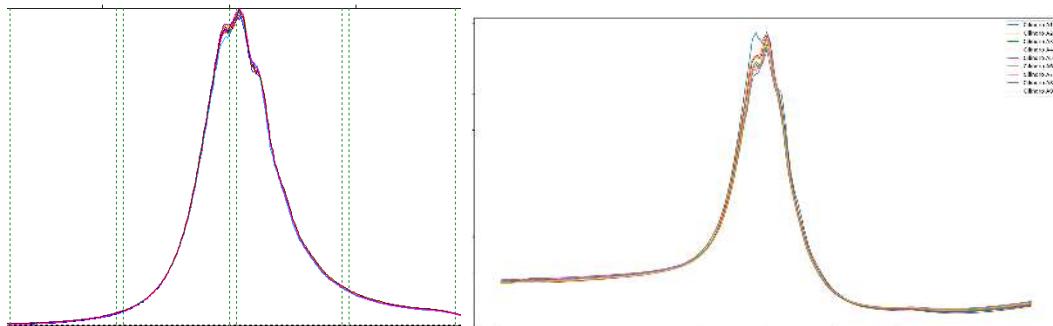


Figura 3.100: Comparação dos sinais. Motor DG#1W18V46.

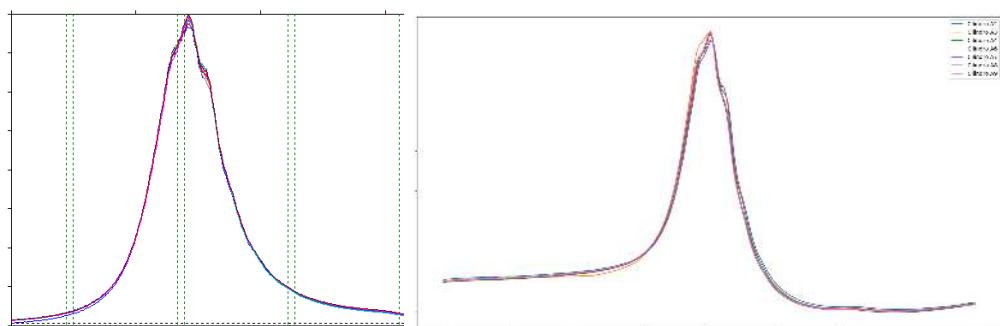


Figura 3.101: Comparação dos sinais. Motor DG#2W18V46.

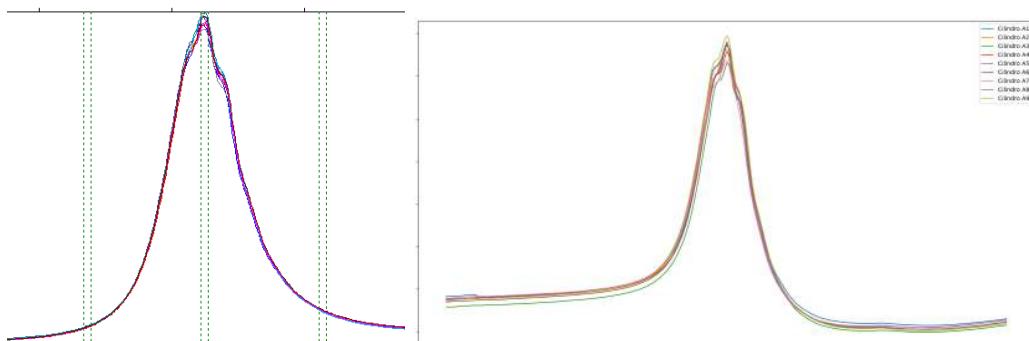


Figura 3.102: Comparação dos sinais. Motor DG#4W18V46.

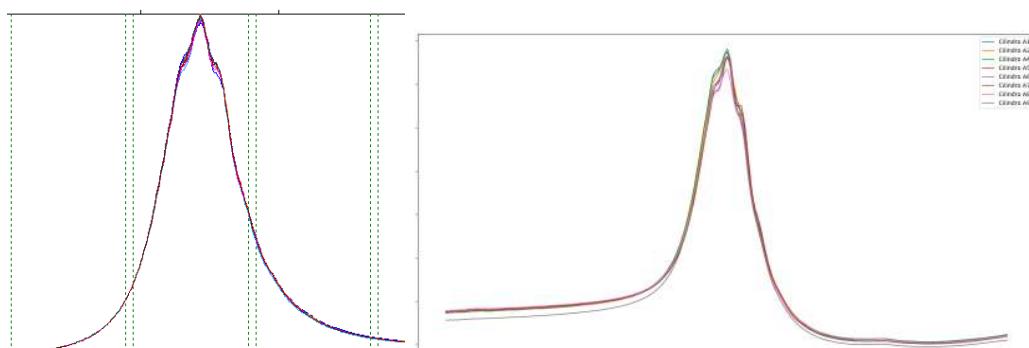


Figura 3.103: Comparação dos sinais Motor DG#5W18V46

3.7.6 Tratamento dos sinais e Modelos Clássicos

Assim como realizado na seção 3.5, os sinais foram tratados e os modelos clássicos foram treinados a partir dos sinais tratados.

Sinal de Pressão

Exemplo do resultado do tratamento dos sinais de pressão na figura 3.105:

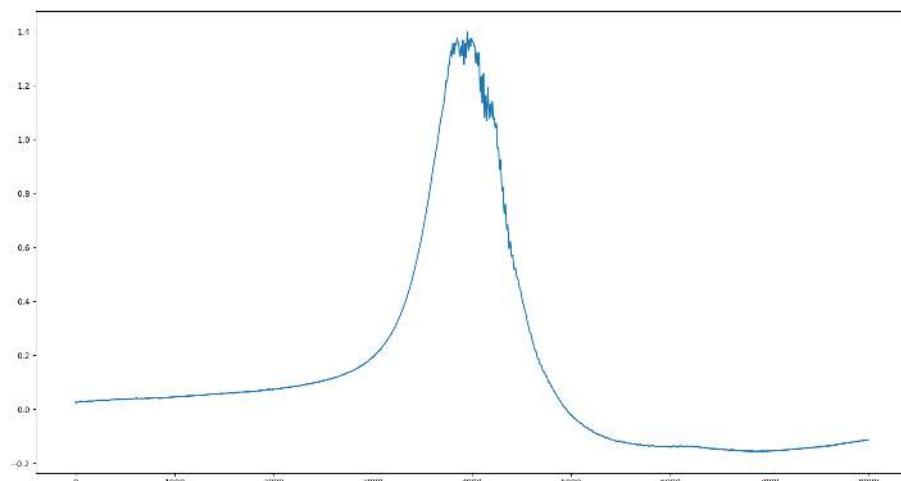


Figura 3.104: Sinal de pressão original.

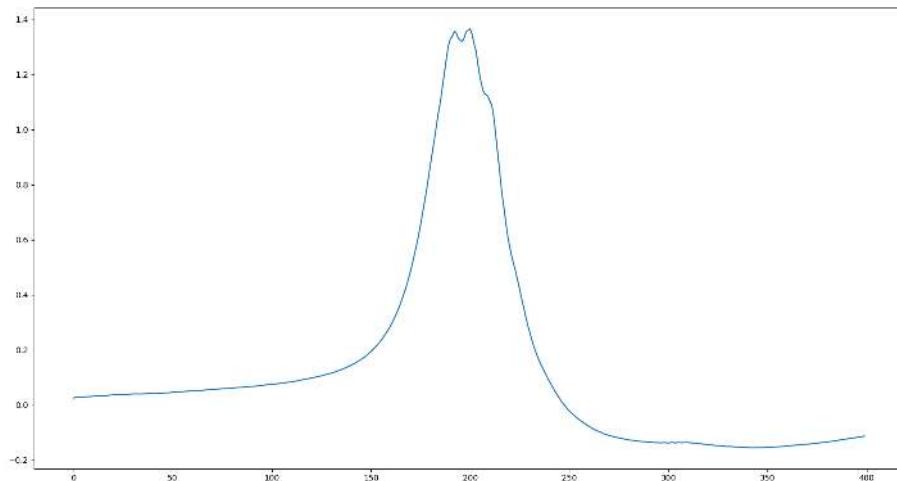


Figura 3.105: Sinal de pressão tratado.

Sinal de Vibração

Assim com o sinal de pressão, o sinal de vibração também foi tratado como descrito na seção 3.5. O resultado pode ser visto na figura 3.107 a seguir.

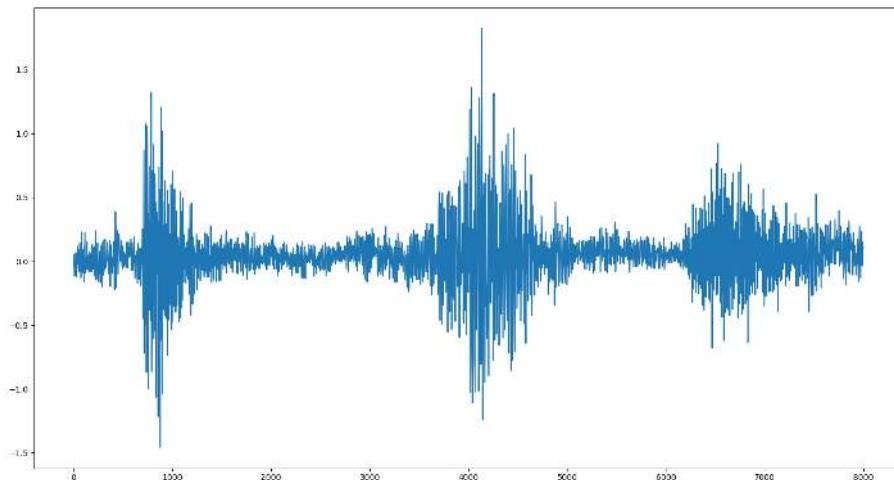


Figura 3.106: Sinal de vibração original.

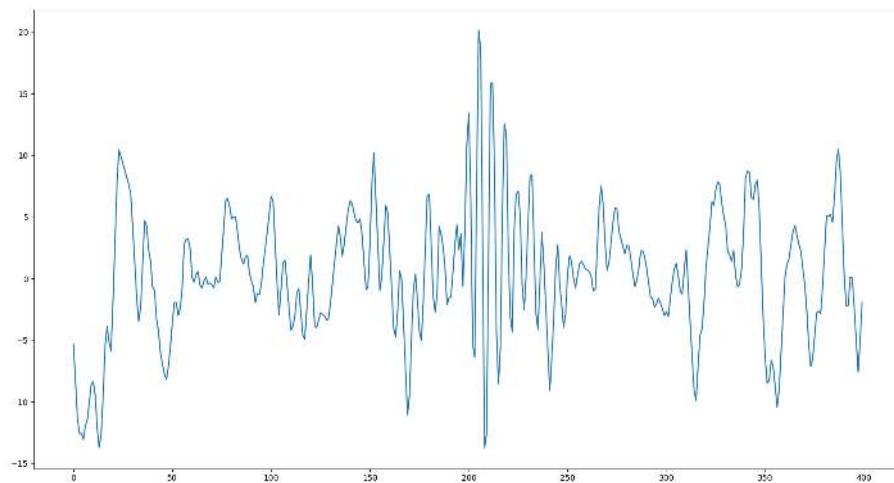


Figura 3.107: Sinal de vibração tratado.

Treinando os Modelos

Os modelos clássicos treinados foram os seguintes:

- Extra trees
- K-nn Regressor
- Ridge Regressor
- Rede Neural MLP

Uma breve explanação de cada um desses algoritmos pode ser visto na seção 3.5. Como dito anteriormente, os ensaios foram realizados em 4 motores distintos. Para termos um caráter real na aplicação e mesuração dos resultados, foi utilizada a estratégia de *Leave One Out Cross Validation* – LOOCV. Esta estratégia permite uma análise estatística mais robusta e próxima da aplicação real.

A cada rodada, são utilizados 3 motores para aprendizado do modelo e o motor restante é utilizado para medir a efetividade do modelo treinado. Dessa forma, 4 rodadas foram realizadas de treinamento e teste do modelo, uma para cada motor.

Essa estratégia permite uma análise mais generalizada dos resultados, pois o modelo é aplicado em um motor cujos dados não foram usados para o aprendizado, assim como propõe-se fazer na prática.

As medidas de erro utilizadas nestes ensaios são as seguintes:

- MAE (*mean absolute error*) – Representa a média da diferença absoluta entre o sinal de pressão real e o sinal reconstruído pelo modelo

$$MAE = \frac{\sum_{i=1}^n |p_r - p_e|}{n}$$

- MSE (*mean squared error*) – Representa a média do quadrado da diferença entre o sinal de pressão real e o sinal reconstruído pelo modelo

$$MSE = \frac{\sum_{i=1}^n (p_r - p_e)^2}{n}$$

- R^2 (coeficiente de determinação) – Representa a proporção de variação do sinal de pressão reconstruído com relação ao sinal de pressão real

$$R^2 = 1 - \frac{\sum_{i=1}^n (p_r - \bar{p}_r)^2}{\sum_{i=1}^n (p_r - p_e)^2}$$

Onde p_r é o sinal de pressão real, p_e o sinal de pressão estimado pelo modelo e \bar{p}_r o valor médio do sinal de pressão real.

3.7.7 Resultados

Nas tabelas 3.21 e 3.22 são apresentados os resultados para as 4 rodadas da estratégia de LOOCV. E na tabela 3.23, as medidas de desempenho consolidadas.

Tabela 3.21: Resultados dos modelos para cada motor.

	DG#1W18V46			DG#2W18V46		
	MAE	MSE	R ²	MAE	MSE	R ²
MLP Regressor	16,908	2,439	0,976	14,172	2,39	0,986
Extra Trees	18,139	2,587	0,974	14,508	2,603	0,986
KNN Regressor	19,031	2,581	0,973	11,764	2,2	0,989
RidgeCV	18,171	2,531	0,974	14,673	2,507	0,986

Tabela 3.22: Resultados dos modelos para cada motor.

	DG#4W18V46			DG#5W18V46		
	MAE	MSE	R ²	MAE	MSE	R ²
MLP Regressor	12,928	1,925	0,984	16,102	2,001	0,981
Extra Trees	11,782	1,854	0,985	11,511	1,764	0,987
KNN Regressor	12,396	1,914	0,984	15,505	2,008	0,982
RidgeCV	14,473	2,054	0,982	13,31	2,062	0,985

Tabela 3.23: Média e desvio padrão dos resultados anteriores.

	MAE		MSE		R ²	
	μ	δ	μ	δ	μ	δ
MLP Regressor	15,03	1,81	2,19	0,26	0,98	0,00
Extra Trees	13,99	3,08	2,20	0,46	0,98	0,01
KNN Regressor	14,67	3,33	2,18	0,30	0,98	0,01
RidgeCV	15,16	2,10	2,29	0,27	0,98	0,01

Nas figuras a seguir é possível observar alguns resultados de sinais de pressão reconstruídos em comparação com o sinal real de pressão medido.

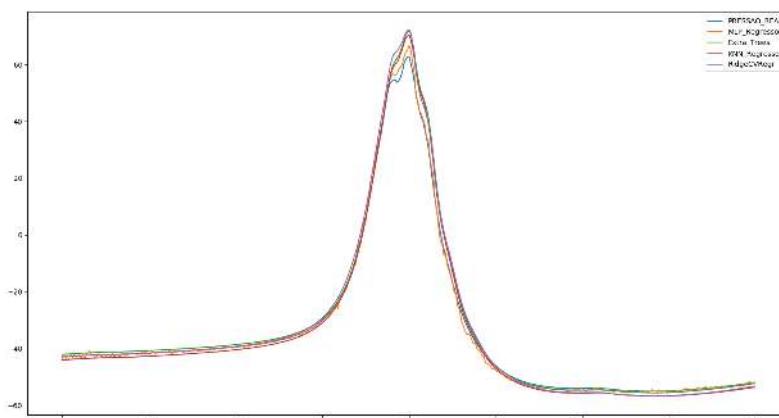


Figura 3.108: Comparaçāo dos resultados. Exemplo 1.

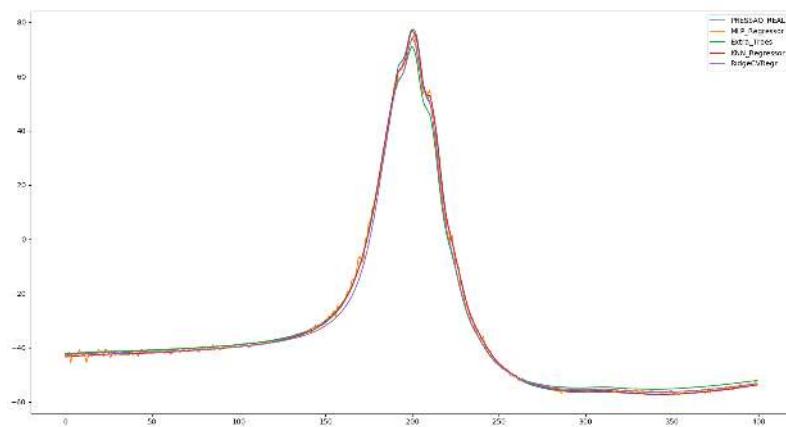


Figura 3.109: Comparação dos resultados. Exemplo 2.

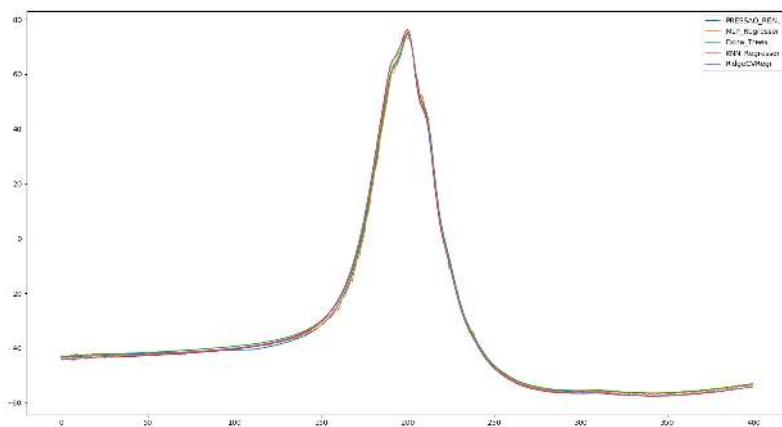


Figura 3.110: Comparação dos resultados. Exemplo 3.

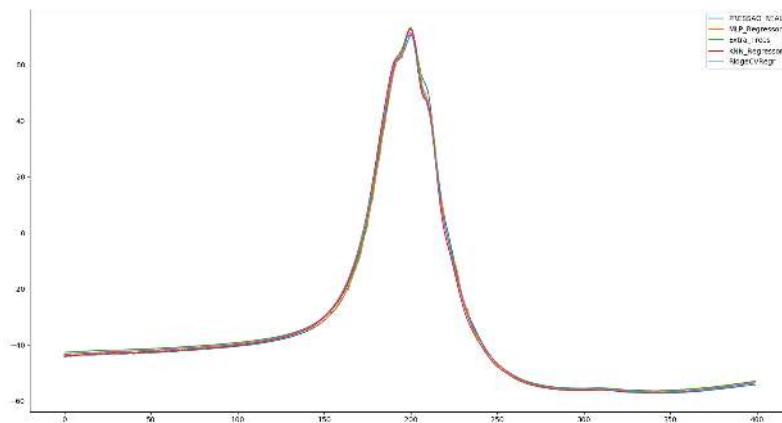


Figura 3.111: Comparação dos resultados. Exemplo 4.

3.8 Ensaios em Campo - Gera Maranhão

Após um longo período em *Stand By*, a usina Gera Maranhão voltou a operar em julho de 2017, e assim, os ensaios em campo puderam ser realizados. A Gera

Maranhão possui um total de 38 grupo geradores Wärtsilä W20V32 de 8.73MW de potência cada, totalizando 331.74MW de capacidade total da planta. Os motores rodam com Óleo Combustível do tipo B1 (OCB1) e consomem cerca 1600 toneladas por dia.

Cada motor possui 20 cilindros, divididos em duas bancadas (A e B). O diâmetro do cilindro é de 320mm, o curso do pistão de 400mm e a biela possui 850mm. A rotação do motor é de 720rpm.



Figura 3.112: Usina Gera Maranhão.



Figura 3.113: Usina Gera Maranhão.

3.8.1 Levantamento da Geometria dos Motores

O levantamento dos dados de geometria do motor da Gera Maranhão é necessário. As informações dos ângulos de combustão de cada cilindro, relativo à uma referência

do virabrequim foram levantadas. Esta etapa é importante para a segmentação dos sinais aquisitados em porções correspondentes a cada ciclo de combustão por cilindro.

Na ausência das informações de *datasheet* dos motores, os ângulos foram levantados empiricamente, através da observação das marcações no volante de inércia. Na tabela 3.24 são apresentados os ângulos de TDC dos cilindros do motor.

Tabela 3.24: Ângulos de TDC dos cilindros.

Cylinders angles from reference A1										
A1	A2	A3	A4	A5	A6	A7	A8	A9	A10	
0	232.5	155	77.5	670	310	465	540	592.5	387.5	
B1	B2	B3	B4	B5	B6	B7	B8	B9	B10	
60	292.5	215	137.5	729.5	370	525	574.5	652	447.5	

3.8.2 Posicionamento do Tacômetro

A tabela 3.24 mostra todos os ângulos de TDC de cada cilindro com referência ao ângulo do cilindro A1. Por isso, a fita reflexiva, usada de referência do tacômetro, é posicionada exatamente no ponto demarcado como sendo o TDC do cilindro A1 no volante de inércia do motor. Este procedimento facilita a sincronização dos dados e posterior divisão dos sinais aquisitados em pedaços correspondentes ao ciclo de combustão de cada cilindro.

A figura 3.114 mostra o posicionamento da fita reflexiva no volante de inércia do motor, enquanto a figura 3.115 exibe o posicionamento do tacômetro para a medição do sinal de rotação.



Figura 3.114: Posicionamento da fita reflexiva.



Figura 3.115: Posicionamento do tacômetro.

3.8.3 Medições

Na usina do Maranhão, foram medidos vários motores, em condições diferentes de carga. Os níveis estabelecidos para a carga dos motores foram: 50%, 75% e 100%.



Figura 3.116: Motor monitorado da Gera Maranhão. DG#01W20V32.

Na tabela 3.25, são apresentados quais motores foram medidos e em que condições de carga.

Tabela 3.25: Motores medidos.

50%	DG#01W20V32	DG#02W20V32	DG#09W20V32	DG#11W20V32
75%	DG#01W20V32	DG#02W20V32		DG#11W20V32
100%	DG#01W20V32	DG#02W20V32	DG#09W20V32	DG#11W20V32
50%		DG#15W20V32	DG#17W20V32	DG#20W20V32
75%		DG#15W20V32	DG#17W20V32	
100%	DG#13W20V32	DG#15W20V32	DG#17W20V32	DG#20W20V32
50%	DG#27W20V32		DG#34W20V32	
75%	DG#27W20V32	DG#29W20V32	DG#34W20V32	
100%	DG#27W20V32	DG#29W20V32	DG#34W20V32	

A seguir vemos alguns exemplos dos sinais medidos de alguns dos motores da Gera Maranhão.

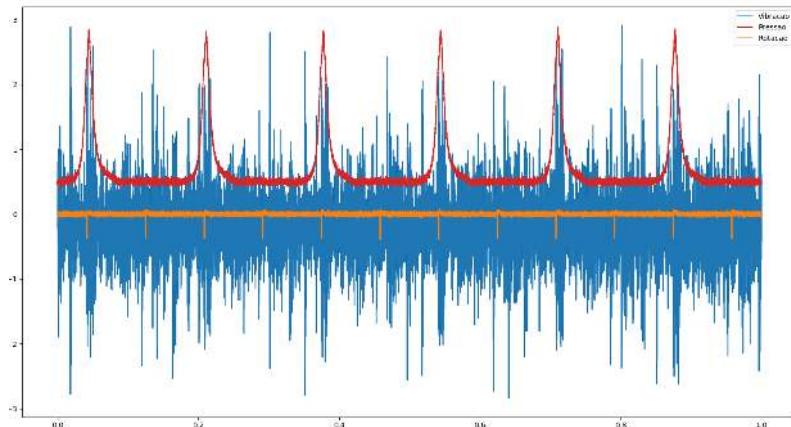


Figura 3.117: Sinal medido do motor DG#02W20V32.

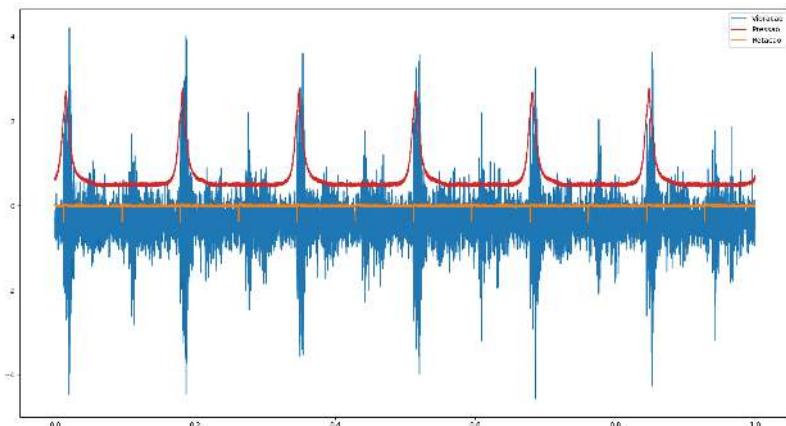


Figura 3.118: Sinal medido do motor DG#09W20V32.

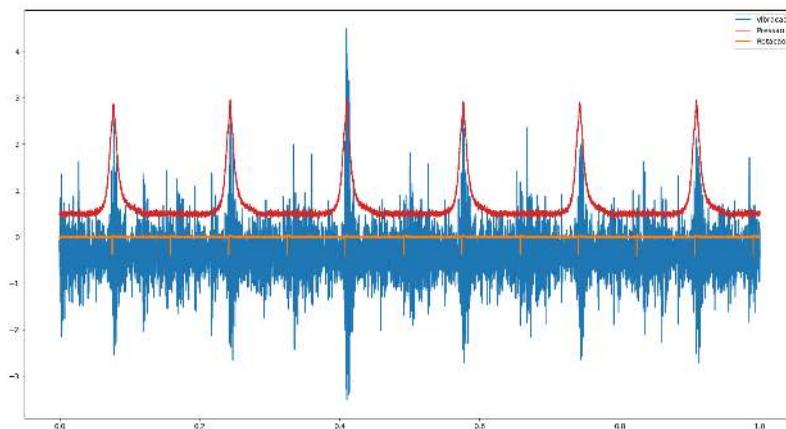


Figura 3.119: Sinal medido do motor DG#11W20V32.

Na figura 3.120 é possível observar o sinal de pressão de todos os cilindros ao longo do tempo.

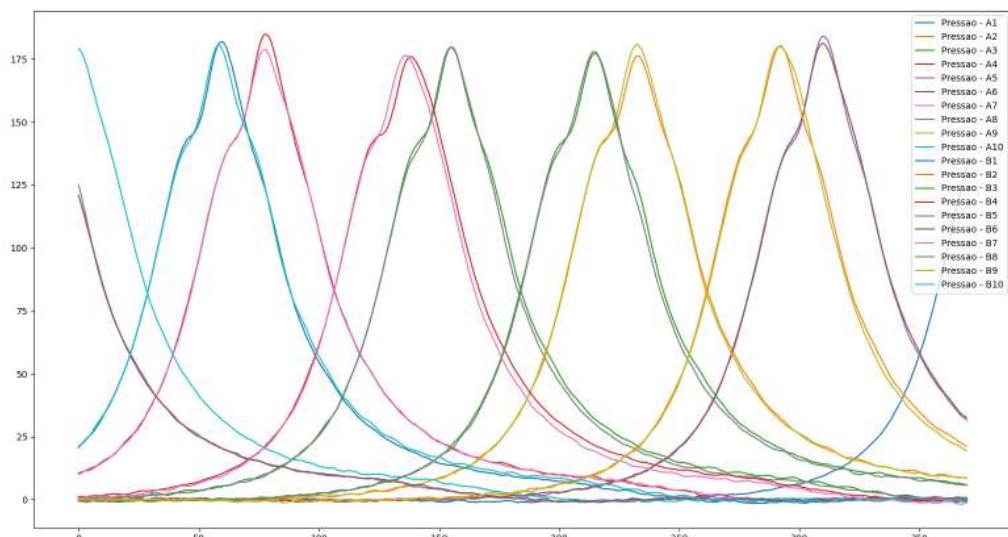


Figura 3.120: Sinais de pressão de todos os cilindros do motor DG#02W20V32.

E nas figuras que seguem, é possível observar os sinais de pressão de alguns motores, sincronizados através do sinal de rotação e dos ângulos de TDC apresentados na tabela 3.24.

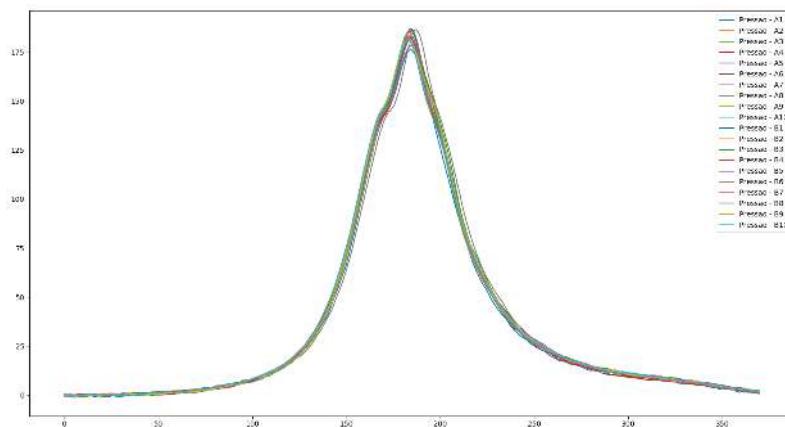


Figura 3.121: Sinais de pressão de todos os cilindros do motor DG#02W20V32, sincronizados.

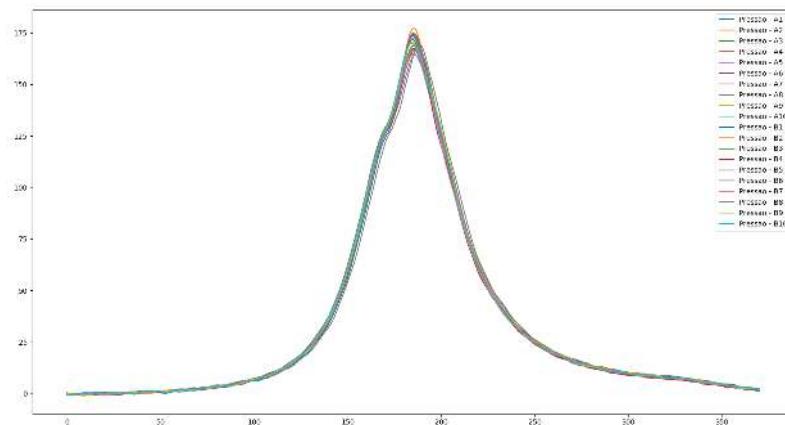


Figura 3.122: Sinais de pressão de todos os cilindros do motor DG#09W20V32, sincronizados.

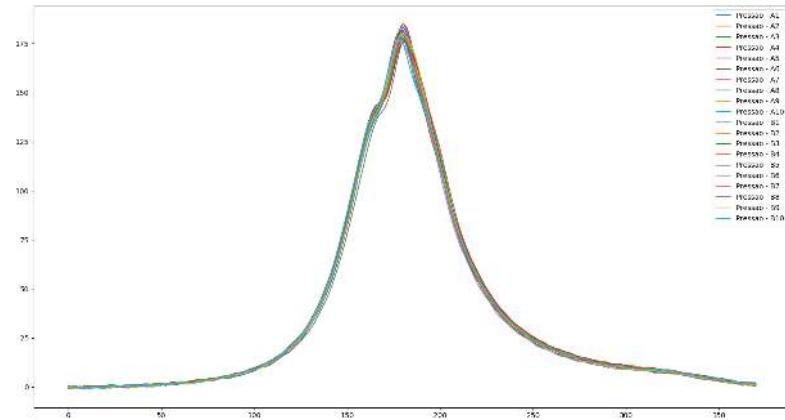


Figura 3.123: Sinais de pressão de todos os cilindros do motor DG#11W20V32, sincronizados.

Nas figuras a seguir, são apresentados os sinais de pressão e vibração nas 3 diferentes condições de carga de um motor de exemplo.

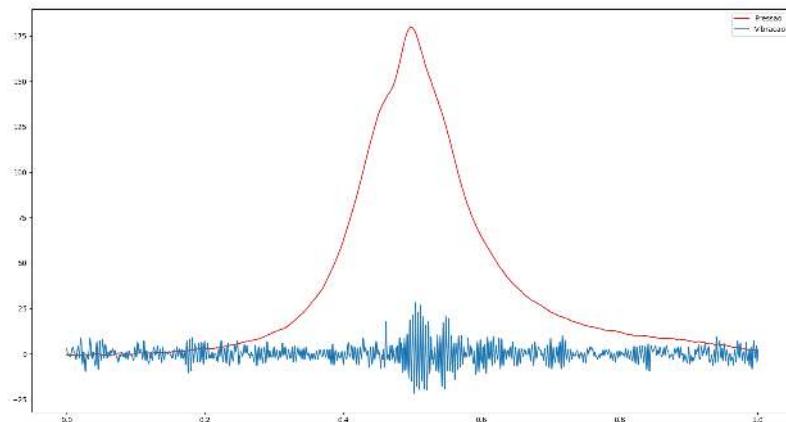


Figura 3.124: Sinais do cilindro A1 do motor DG#11W20V32 a 100% de carga.

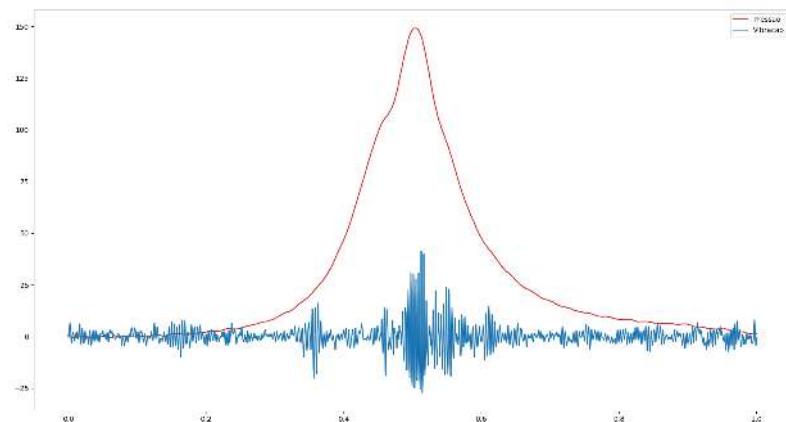


Figura 3.125: Sinais do cilindro A1 do motor DG#11W20V32 a 75% de carga.

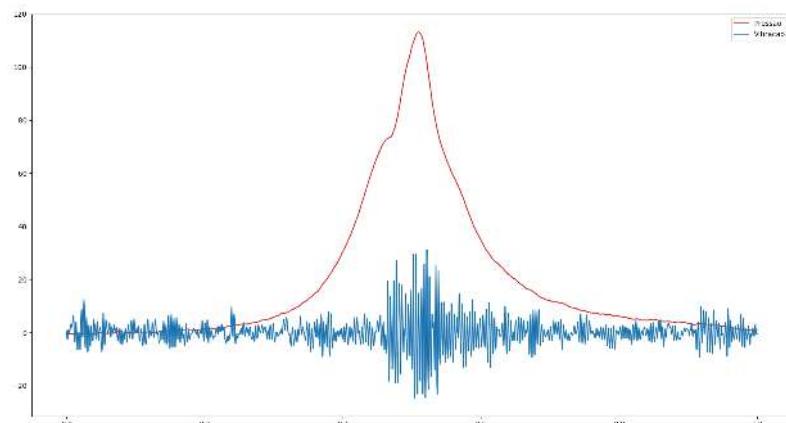


Figura 3.126: Sinais do cilindro A1 do motor DG#11W20V32 a 50% de carga.

3.8.4 Tratamento dos sinais e Modelos Clássicos

Assim como realizado na seção 3.5, os sinais foram tratados e os modelos clássicos foram treinados a partir dos sinais tratados.

Sinal de Pressão

Exemplo do resultado do tratamento dos sinais de pressão na figura 3.129:

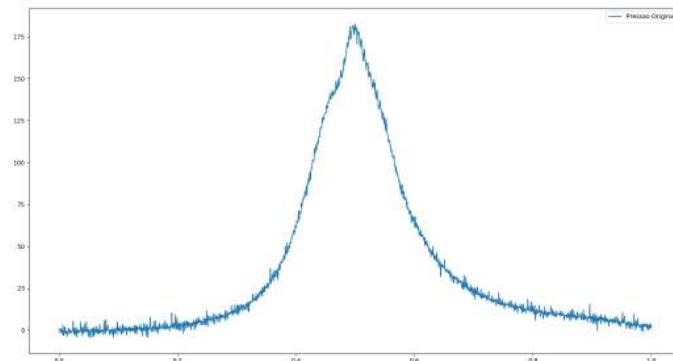


Figura 3.127: Sinal de pressão original de um cilindro.

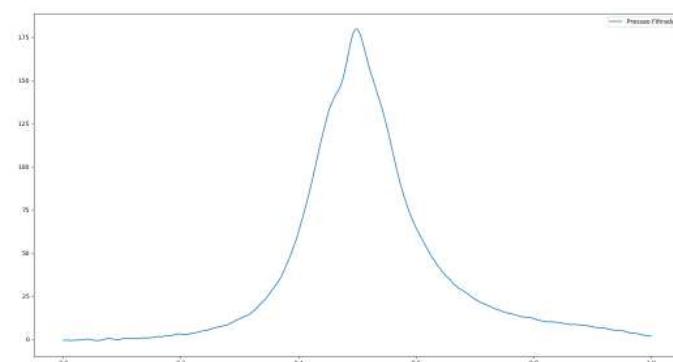


Figura 3.128: Sinal de pressão filtrado de um cilindro.

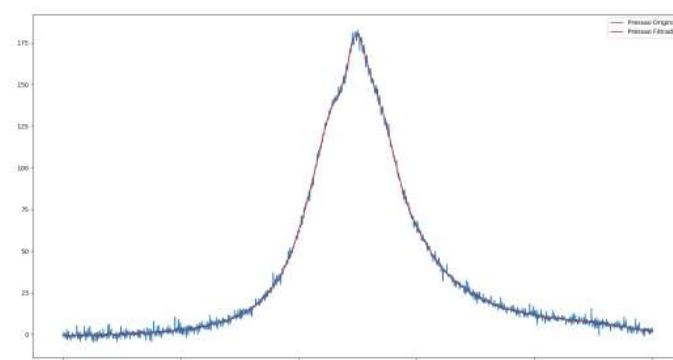


Figura 3.129: Comparaçāo dos sinais anteriores.

Sinal de Vibração

Assim com o sinal de pressão, o sinal de vibração também foi tratado como descrito na seção 3.5. O resultado pode ser visto na figura 3.107 a seguir.

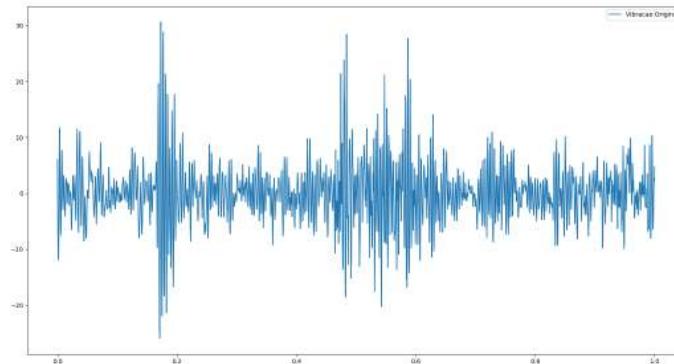


Figura 3.130: Sinal de pressão original de um cilindro.

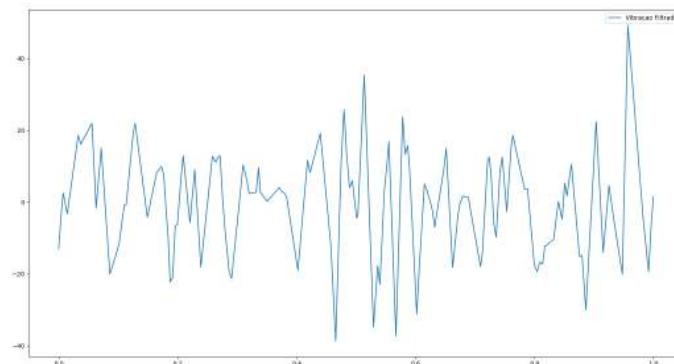


Figura 3.131: Sinal de pressão filtrado de um cilindro.

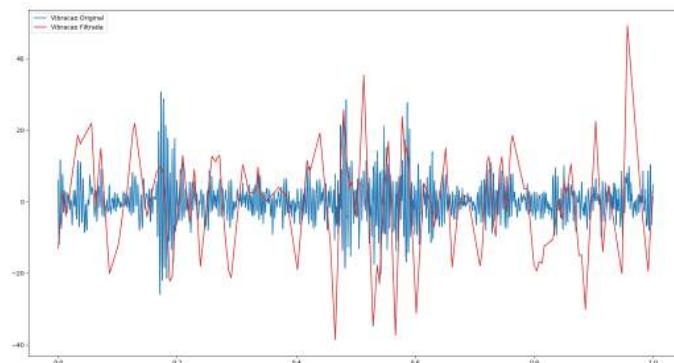


Figura 3.132: Comparaçao dos sinais anteriores.

Treinando os Modelos

Os modelos clássicos treinados nesta etapa foram os mesmos modelos da etapa realizada na unidade de Manaus. São eles:

- Extra trees
- K-nn Regressor
- Ridge Regressor
- Rede Neural MLP

Uma breve explanação de cada um desses algoritmos pode ser visto na seção 3.5.

Nas medições da usina Gera Maranhão, foi possível variar a carga a qual eram submetidos os motores. No entanto, no período em que foram realizados os ensaios, somente 5 motores foram medidos completamente, nas 3 condições de carga propostas: 50%, 75% e 100%. Dessa forma, de maneira semelhante ao que foi feito na etapa anterior, na usina de Manaus, foi utilizada a estratégia de *Leave One Out Cross Validation* – LOOCV. Esta estratégia permite uma análise estatística mais robusta e próxima da aplicação real.

A cada rodada, são utilizados 4 motores para aprendizado do modelo e o motor restante é utilizado para medir a efetividade do modelo treinado. Dessa forma, 5 rodadas foram realizadas de treinamento e teste do modelo, uma para cada motor.

Essa estratégia permite uma análise mais generalizada dos resultados, pois o modelo é aplicado em um motor cujos dados não foram usados para o aprendizado. As medidas de erro utilizadas nestes ensaios foram as mesmas da etapa anterior, e são as seguintes:

- MAE (*mean absolute error*) – Representa a média da diferença absoluta entre o sinal de pressão real e o sinal reconstruído pelo modelo

$$MAE = \frac{\sum_{i=1}^n |p_r - p_e|}{n}$$

- MSE (*mean squared error*) – Representa a média do quadrado da diferença entre o sinal de pressão real e o sinal reconstruído pelo modelo

$$MSE = \frac{\sum_{i=1}^n (p_r - p_e)^2}{n}$$

- R^2 (coeficiente de determinação) – Representa a proporção de variação do sinal de pressão reconstruído com relação ao sinal de pressão real

$$R^2 = 1 - \frac{\sum_{i=1}^n (p_r - \bar{p}_r)^2}{\sum_{i=1}^n (p_r - p_e)^2}$$

Onde p_r é o sinal de pressão real, p_e o sinal de pressão estimado pelo modelo e \bar{p}_r o valor médio do sinal de pressão real.

3.8.5 Resultados

Nas tabelas 3.26, 3.27, 3.28, 3.29 e 3.30 são apresentados os resultados para as 5 rodadas da estratégia de LOOCV. E na tabela 3.31, as medidas de desempenho consolidadas.

Tabela 3.26: Resultados para o motor DG#20W20V32.

	<i>MSE</i>	<i>MAE</i>	<i>R</i> ²
MLP Regressor	111,13	4,105	0,95
Extra Trees	71,335	4,367	0,958
KNN Regressor	20,727	2,453	0,987
RidgeCV	93,376	4,064	0,951
Treino:	[motor34, motor01, motor11, motor17]		
Teste:	[motor20]		

Tabela 3.27: Resultados para o motor DG#34W20V32.

	<i>MSE</i>	<i>MAE</i>	<i>R</i> ²
MLP Regressor	50,454	3,062	0,976
Extra Trees	52,589	3,599	0,966
KNN Regressor	77,411	4,324	0,961
RidgeCV	72,332	3,52	0,966
Train:	[motor20, motor01, motor11, motor17]		
Test:	[motor34]		

Tabela 3.28: Resultados para o motor DG#01W20V32.

	<i>MSE</i>	<i>MAE</i>	<i>R</i> ²
MLP Regressor	133,225	5,525	0,933
Extra Trees	84,993	4,743	0,945
KNN Regressor	98,037	5,273	0,947
RidgeCV	125,22	5,578	0,927
Train:	[motor20, motor34, motor11, motor17]		
Test:	[motor01]		

Tabela 3.29: Resultados para o motor DG#11W20V32.

	<i>MSE</i>	<i>MAE</i>	<i>R</i> ²
MLP Regressor	69,476	4,157	0,965
Extra Trees	34,952	3,191	0,971
KNN Regressor	80,648	4,406	0,959
RidgeCV	85,892	4,88	0,948
Train:	[motor20, motor34, motor01, motor17]		
Test:	[motor11]		

Tabela 3.30: Resultados para o motor DG#17W20V32.

	<i>MSE</i>	<i>MAE</i>	<i>R</i> ²
MLP Regressor	80,697	5,098	0,93
Extra Trees	74,958	4,747	0,935
KNN Regressor	75,741	4,404	0,951
RidgeCV	93,135	4,827	0,936
Train:	[motor20, motor34, motor01, motor11]		
Test:	[motor17]		

Tabela 3.31: Resultados consolidados.

	<i>MSE</i>		<i>MAE</i>		<i>R</i> ²	
	u	d	u	d	u	d
MLP Regressor	89,00	33,10	4,39	0,96	0,95	0,02
Extra Trees	63,77	19,93	4,13	0,70	0,95	0,01
KNN Regressor	70,51	29,21	4,17	1,04	0,95	0,02
RidgeCV	93,99	19,44	4,57	0,80	0,94	0,01

Nas figuras a seguir é possível observar alguns resultados de sinais de pressão reconstruídos em comparação com o sinal real de pressão medido.

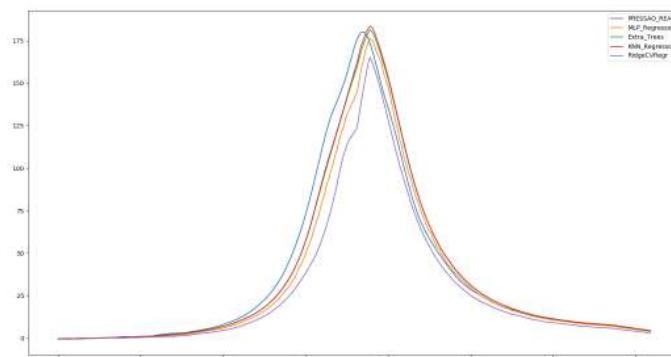


Figura 3.133: Comparaçāo dos sinais de pressāo reconstruídos.

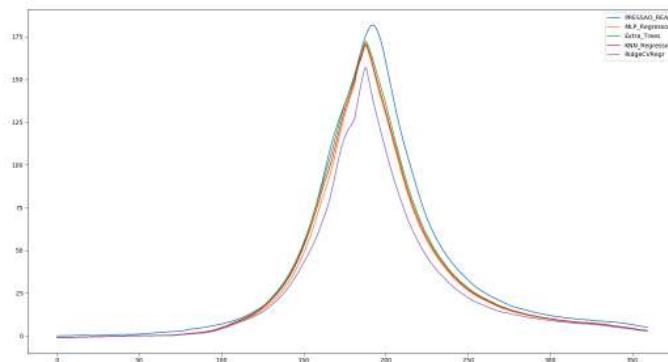


Figura 3.134: Comparação dos sinais de pressão reconstruídos.

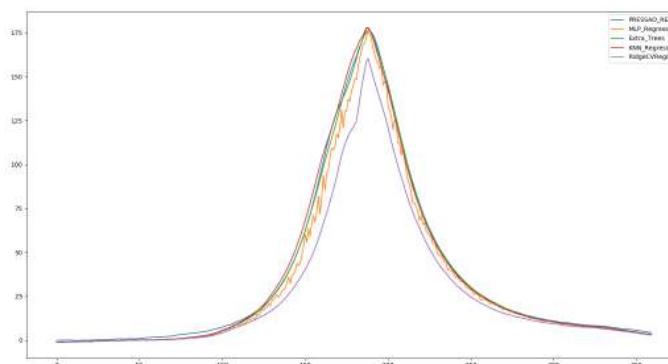


Figura 3.135: Comparação dos sinais de pressão reconstruídos.

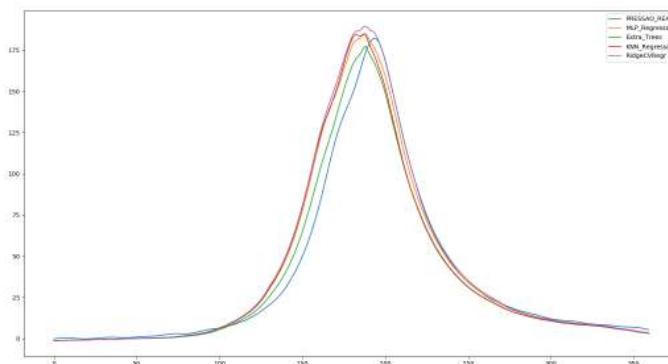


Figura 3.136: Comparação dos sinais de pressão reconstruídos.

3.9 Redes Neurais Convolucionais

Redes neurais convolucionais (*Convolutional Neural Networks - CNN*) são um tipo específico de redes neurais artificiais. Esse tipo de rede neural tem se mostrado bastante eficiente em áreas como reconhecimento de imagens e classificação. As CNNs são usadas com bastante sucesso em identificação facial, reconhecimento de objetos e sinais de trânsito, em aplicações como visão em robôs ou carros autônomos.

Sua estrutura facilita a identificação de regiões relevantes em imagens, através de operações de convolução. Essas operações tomam por base a relevância de um determinado pixel, de acordo com sua vizinhança. Mais recentemente, devido a

essa característica, Redes Neurais Convolucionais têm recebido atenção crescente, como uma ferramenta robusta e eficiente para a extração de características de sinais utilizados para o monitoramento de condição de equipamentos.

Em [17], falhas em redutores são classificadas usando uma CNN que aprende a partir de um conjunto de 256 características pré-determinadas do sinal de vibração. Em [23], é realizada a detecção de falhas em equipamentos rotativos através do sinal de vibração, porém, convertidos no domínio da frequência. Em [22], uma CNN é treinada diretamente com sinais de vibração no domínio do tempo para a detecção de falhas em motores elétricos. Estes trabalhos introduzem na literatura alguns conceitos utilizados neste projeto, detalhados nas seções que seguem.

3.9.1 Estrutura da CNN

Redes neurais convolucionais, especificamente projetadas para extração de requisitos com a finalidade de regressão (reconstrução) de sinais, têm ao menos três estruturas claras para o seu funcionamento. Estas fases correspondem a: Convolução, *Pooling* e a Regressão propriamente dita. Na figura 3.137 a seguir, é possível observar estas fases.

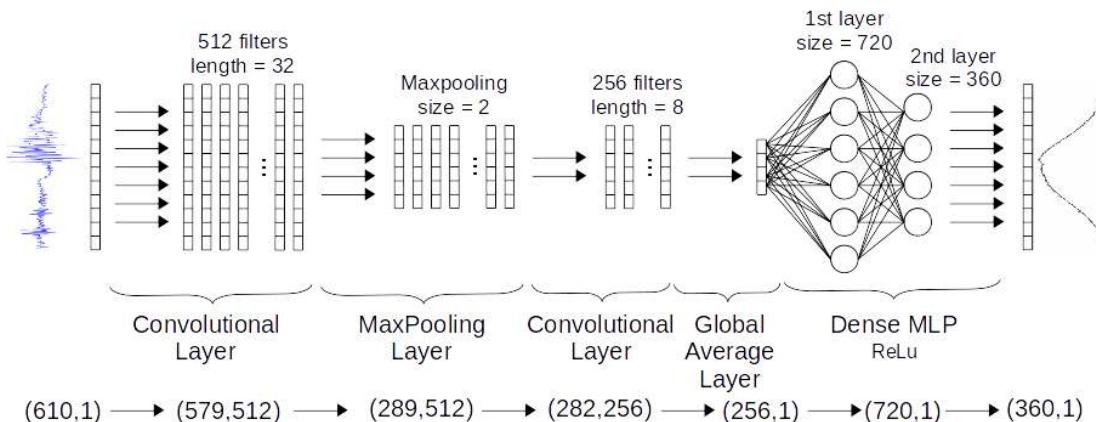


Figura 3.137: Estrutura de uma CNN para regressão.

Na rede neural convolucional proposta para este projeto, são realizadas suas etapas de convolução, intercaladas por duas etapas de *pooling*. No final, uma rede neural MLP, densamente conectada é acoplada a CNN para a realização da reconstrução do sinal de pressão, tomando como entrada as características extraídas pelas fases convolucionais da rede.

3.9.2 Convolução

A camada de convolução consiste em um conjunto de filtros. Cada filtro é relativamente pequeno se comparado ao tamanho total do sinal, mas é aplicado em toda a sua extensão. Por exemplo, dado um sinal de vibração e um filtro unidimensional, de tamanho igual a 3, para cada elemento do sinal original, é computado o produto escalar do filtro com a porção do sinal sob a projeção do filtro, como pode ser visto na figura 3.138 a seguir.

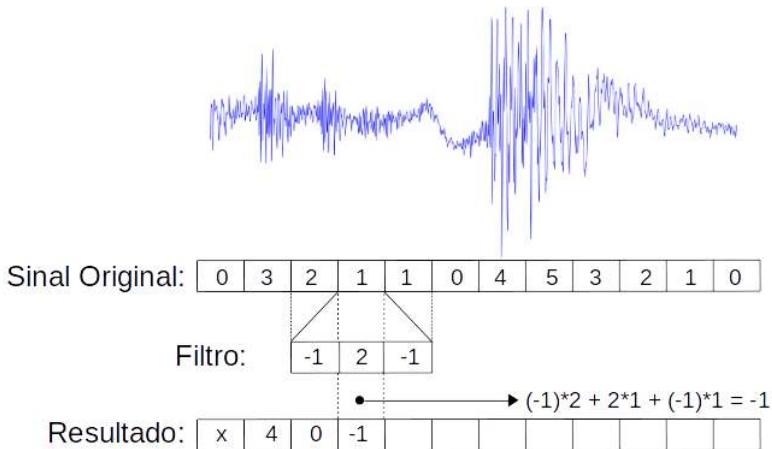


Figura 3.138: Exemplo de uma convolução unidimensional.

Na prática, uma rede neural convolucional aprende os valores desses filtros durante o processo de treinamento da rede. Alguns parâmetros ainda são necessários, como o número e o tamanho dos filtros. Intuitivamente, a rede irá aprender parâmetros para os filtros que são ativados na presença de alguma característica temporal em um sinal unidimensional, como o sinal de vibração.

3.9.3 Pooling

A etapa de *Pooling* reduz a dimensão do *feature map* através da manutenção somente das informações mais relevantes. Os tipos de *pooling* existente são os de máximo, média e soma.

Neste trabalho é utilizado uma etapa de *Max Pooling*, ou seja, a cada n valores, o maior deles é mantido no sinal, onde n é o fator de subamostragem. Na figura 3.137, o tamanho de n é igual a 2. Outras alternativas, seriam tomar a média dos n valores (*Average Pooling*) ou a soma dos valores na janela.

3.9.4 Regressão

A etapa de regressão, ou reconstrução do sinal, é uma rede neural *Multi Layer Perceptron* – MLP, completamente conectada. Neste tipo de rede, cada neurônio em uma camada anterior, se conecta a todos os neurônios da camada seguinte.

A saída das etapas de convolução e subamostragem representam características de alto nível do sinal. O objetivo da camada é reconstruir cada valor o sinal de pressão, baseado nessas características aprendidas na etapa de treinamento. Em outras palavras, a fase de reconstrução do sinal, através de um rede MLP Densa (totalmente conectada), combina de maneira não-linear as características extraídas.

3.9.5 Treinamento

O processo de treinamento da rede pode ser dividido nas seguintes etapas:

- Os filtros e parâmetros/pesos da rede são inicializados com valores aleatórios;

- A rede toma um sinal de vibração como entrada, aplica os filtros e pesos aleatórios e gera um sinal de pressão;
 - Como os pesos foram gerados aleatoriamente, na primeira rodada de treino, a pressão reconstruída também é aleatória.
- Calcula-se o erro de aproximação do sinal de pressão reconstruído com o sinal de pressão esperado;
 - O erro nesta etapa é calculado através do MSE (*mean squared error*) – Representa a média do quadrado da diferença entre o sinal de pressão real e o sinal reconstruído pelo modelo: $MSE = \frac{\sum_{i=1}^n (p_r - p_e)^2}{n}$
- Então é usado o algoritmo de *Backpropagation* para calcular os gradientes do erro com relação a todos os pesos da rede.
 - Os pesos são então ajustados proporcionalmente a sua contribuição ao erro total calculado;
- Repetir os passos de 2 a 4 para todos os exemplos do conjunto de treino;

Esse procedimento de treino é realizado até que se atinja um valor aceitável de erro, ou até um limite de iterações. Esse processo faz com que os pesos sejam otimizados para a reconstrução do sinal de pressão. Se o conjunto de treino for grande e variado o suficiente, a rede será capaz de generalizar a reconstrução do sinal de pressão para novos sinais de vibração.

3.9.6 Resultados

A principal vantagem da utilização de redes neurais convolucionais em relação aos modelos clássicos, é que para a fazer a reconstrução do sinal de pressão, não se faz necessária a etapa de pré-processamento do sinal, como visto nas seções anteriores. Ou seja, para treinarmos a CNN proposta na arquitetura da figura 3.137, entramos diretamente como sinal de vibração medido.

O sinal de vibração é unidimensional e tem uma tamanho de 610 pontos. São aplicados 512 filtros de 32 posições cada. Ou seja, cada sinal de vibração geram 512 novos sinais, com 579 posições (descontados as 32 posições dos extremos do sinal, devido ao processo de convolução). De cada sinal resultante, são selecionados os valores mais significativos, com um fator de 2, gerando 512 novos sinais de 289 posições. Uma nova etapa de convolução é aplicada, com 256 filtros de tamanho igual a 8, gerando 256 sinais de 282 posições. É tirada a média de cada um dos 256 sinais resultantes, que é o vetor de característica final, que alimenta a rede neural MLP para fazer a reconstrução do sinal.

Para comparar os resultados da metodologia proposta, as medições da usina Gera Maranhão foram utilizadas, onde 5 motores foram medidos completamente, nas 3 condições de carga propostas: 50%, 75% e 100%. Assim como nas etapas anteriores, a cada rodada, são utilizados 4 motores para aprendizado do modelo e o motor restante é utilizado para medir a efetividade do modelo treinado. Dessa forma, 5

rodadas foram realizadas de treinamento e teste do modelo, uma para cada motor. As medidas de erro utilizadas nestes ensaios foram as mesmas da etapa anterior, e são as seguintes:

- MAE (*mean absolute error*) – Representa a média da diferença absoluta entre o sinal de pressão real e o sinal reconstruído pelo modelo

$$MAE = \frac{\sum_{i=1}^n |p_r - p_e|}{n}$$

- MSE (*mean squared error*) – Representa a média do quadrado da diferença entre o sinal de pressão real e o sinal reconstruído pelo modelo

$$MSE = \frac{\sum_{i=1}^n (p_r - p_e)^2}{n}$$

- R^2 (coeficiente de determinação) – Representa a proporção de variação do sinal de pressão reconstruído com relação ao sinal de pressão real

$$R^2 = 1 - \frac{\sum_{i=1}^n (p_r - \bar{p}_r)^2}{\sum_{i=1}^n (p_r - p_e)^2}$$

Onde p_r é o sinal de pressão real, p_e o sinal de pressão estimado pelo modelo e \bar{p}_r o valor médio do sinal de pressão real.

A comparação dos resultados do modelos de rede neural convolucional com os modelos clássicos para cada rodada de treino podem ser vistos a seguir.

Tabela 3.32: Resultados para o motor DG#20W20V32.

	MSE	MAE	R2
MLP Regressor	111,13	4,105	0,95
Extra Trees	71,335	4,367	0,958
KNN Regressor	20,727	2,453	0,987
RidgeCV	93,376	4,064	0,951
CNN Regressor	19,015	2,24	0,99
Train: [motor34, motor01, motor11, motor17]			
Test: [motor20]			

Tabela 3.33: Resultados para o motor DG#34W20V32.

	MSE	MAE	R2
MLP Regressor	50,454	3,062	0,976
Extra Trees	52,589	3,599	0,966
KNN Regressor	77,411	4,324	0,961
RidgeCV	72,332	3,52	0,966
CNN Regressor	72,953	3,753	0,967
Train: [motor20, motor01, motor11, motor17]			
Test: [motor34]			

Tabela 3.34: Resultados para o motor DG#01W20V32.

	MSE	MAE	R2
MLP Regressor	133,225	5,525	0,933
Extra Trees	84,993	4,743	0,945
KNN Regressor	98,037	5,273	0,947
RidgeCV	125,22	5,578	0,927
CNN Regressor	68,575	4,161	0,965
Train:	[motor20, motor34, motor11, motor17]		
Test:	[motor01]		

Tabela 3.35: Resultados para o motor DG#11W20V32.

	MSE	MAE	R2
MLP Regressor	69,476	4,157	0,965
Extra Trees	34,952	3,191	0,971
KNN Regressor	80,648	4,406	0,959
RidgeCV	85,892	4,88	0,948
CNN Regressor	42,874	3,293	0,974
Train:	[motor20, motor34, motor01, motor17]		
Test:	[motor11]		

Tabela 3.36: Resultados para o motor DG#17W20V32.

	MSE	MAE	R2
MLP Regressor	80,697	5,098	0,93
Extra Trees	74,958	4,747	0,935
KNN Regressor	75,741	4,404	0,951
RidgeCV	93,135	4,827	0,936
CNN Regressor	104,316	5,715	0,928
Train:	[motor20, motor34, motor01, motor11]		
Test:	[motor17]		

Tabela 3.37: Comparação dos modelos clássicos e de CNN.

	MSE		MAE		R2	
	u	d	u	d	u	d
MLP Regressor	89,00	33,10	4,39	0,96	0,95	0,02
Extra Trees	63,77	19,93	4,13	0,70	0,95	0,01
KNN Regressor	70,51	29,21	4,17	1,04	0,95	0,02
RidgeCV	93,99	19,44	4,57	0,80	0,94	0,01
CNN Regressor	61,55	32,27	3,83	1,27	0,96	0,02

É possível notar que os resultados são ligeiramente melhores quando aplicamos redes neurais convolucionais, além de tornar o processo mais simples e menos dependente dos pré-processamentos propostos nas etapas anteriores.

Na figura 3.139 a seguir, podemos ver uma comparação entre os resultados dos modelos clássicos e o resultado da rede neural convolucional.

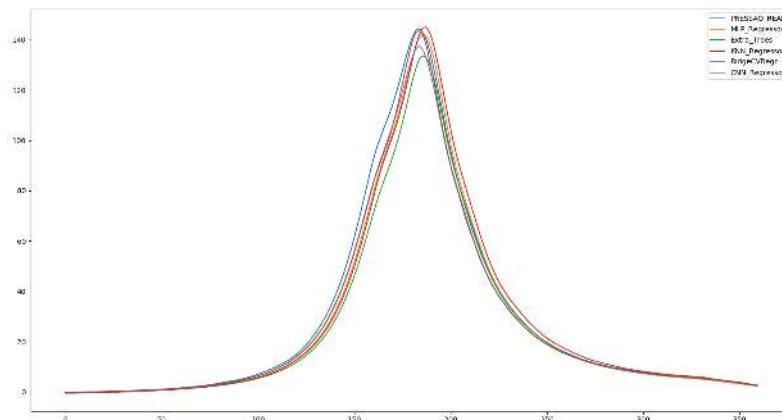


Figura 3.139: Comparação dos modelos clássicos e de CNN.

Na figura 3.140 a seguir, é exibido alguns resultados de reconstrução para sinais com cargas diferentes.

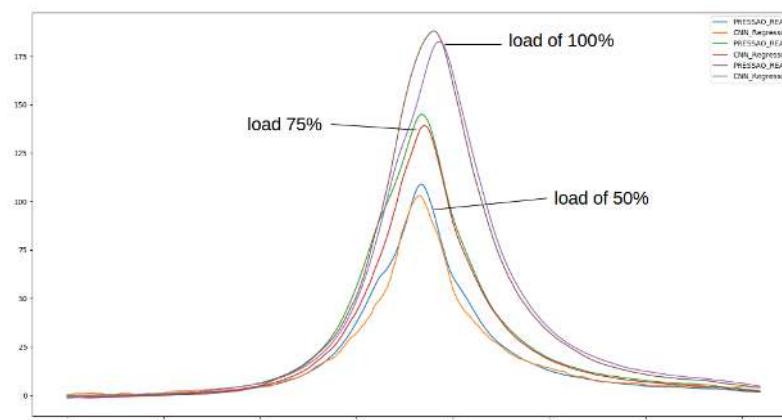


Figura 3.140: Comparação dos resultados da CNN para diferentes cargas.

Capítulo 4

CONCLUSÃO

Neste trabalho foi apresentada uma rede neural convolucional para a reconstrução da pressão interna dos cilindros de motores de combustão de grupo geradores termelétricos, usando somente os dados brutos de vibração e rotação do motor como entrada para o modelo. A aplicação dessas técnicas no problema de reconstrução do sinal de pressão se mostra original na literatura, com vantagens em relação às principais metodologias empregadas até então. Esta abordagem não só simplifica o processo de reconstrução do sinal de pressão, como também o torna mais robusto e menos suscetível a variações das condições operacionais.

Devido aos custos bem inferiores de sensores de vibração em comparação aos transdutores de pressão, além da maior vida útil em operação e aos resultados eficazes e robustos da metodologia proposta neste trabalho, é possível realizar o monitoramento constante de motores de combustão de grupos geradores termelétricos, evitando paradas inesperadas, consumo excessivo de combustível e emissão de poluentes.

O custo de instrumentação utilizando transdutores de pressão, que tem um valor médio de dois mil dólares, para um parque como o da Gera Maranhão, é maior que 1,5 milhão de dólares. O mesmo custo, usando somente acelerômetros de vibração, com um valor dez vezes menor, ficaria em torno de 150 mil dólares. Ao comparar a vida útil, extremamente menor de um transdutor de pressão, devido às altíssimas temperaturas e pressões a que é submetido, o custo de instrumentação se torna inviável com transdutores de pressão, porém plausível através de sensores de vibração e da aplicação das técnicas desenvolvidas neste projeto.

Os ensaios no motor Sulzer de Itajubá, aliado aos ensaios da bancada de simulação de falhas, tornaram robusto o modelo de reconstrução do sinal de pressão. A comparação dos sinais com um equipamento típico de mercado validam os sinais utilizados como entrada no modelo. Os ensaios em campo, em duas unidades com equipamentos distintos, mostrou a aplicabilidade prática dos modelos desenvolvidos em laboratório. Portanto, devido aos recursos empregados nessas etapas, pode-se considerar os resultados do monitoramento de motores de combustão como válidos, robustos e de aplicação prática.

Com a técnica desenvolvida, se o monitoramento contínuo identificar com maior eficiência qualquer desvio de temporização do processo de combustão de grupo geradores, que resulte na diminuição de pelo menos um centésimo de consumo de um

único motor, já permitiria uma economia de mais de 400 quilos de óleo combustível por dia de operação - levando em consideração que o parque consome em média 1600 toneladas de óleo combustível por dia. Essa economia, associada aos custos inferiores de instrumentação e a maior confiabilidade que a manutenção preditiva possibilita à gestão de ativos, tornam os resultados da pesquisa desenvolvida neste projeto muito relevantes à aplicação na usina proponente e nas demais usinas geradoras semelhantes a Gera Maranhão.

Referências Bibliográficas

- [1] Decisiontreeregressor. <http://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeRegressor.html#sklearn.tree.DecisionTreeRegressor>. Accessed: ago-2015.
- [2] Exponential decay. https://en.wikipedia.org/wiki/Exponential_decay. Accessed: ago-2015.
- [3] Extratreeregressor. <http://scikit-learn.org/stable/modules/generated/sklearn.tree.ExtraTreeRegressor.html#sklearn.tree.ExtraTreeRegressor>. Accessed: ago-2015.
- [4] Função de gauss. https://pt.wikipedia.org/wiki/Fun%C3%A7%C3%A3o_de_Gauss. Accessed: ago-2015.
- [5] Kneighborsregressor. <http://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsRegressor.html#sklearn.neighbors.KNeighborsRegressor>. Accessed: ago-2015.
- [6] Linearregression. http://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html#sklearn.linear_model.LinearRegression. Accessed: ago-2015.
- [7] Ridgecv. http://scikit-learn.org/stable/modules/generated/sklearn.linear_model.RidgeCV.html#sklearn.linear_model.RidgeCV. Accessed: ago-2015.
- [8] A Albarbar, Fengshou Gu, and AD Ball. Diesel engine fuel injection monitoring using acoustic measurements and independent component analysis. *Measurement*, 43(10):1376–1386, 2010.
- [9] A Albarbar, Fengshou Gu, AD Ball, and A Starr. Acoustic monitoring of engine fuel injection based on adaptive filtering techniques. *Applied Acoustics*, 71(12):1132–1141, 2010.
- [10] L. Barelli, G. Bidini, C. Buratti, and R. Mariani. Diagnosis of internal combustion engine through vibration and acoustic pressure non-intrusive measurements. *Applied Thermal Engineering*, 29(8):1707 – 1713, 2009.
- [11] L. Barelli, G. Bidini, C. Buratti, and R. Mariani. Diagnosis of internal combustion engine through vibration and acoustic pressure non-intrusive measurements. *Applied Thermal Engineering*, 29(8):1707 – 1713, 2009.

- [12] Katarzyna Bizon, Gaetano Continillo, Ezio Mancaruso, and Bianca Maria Vaglieco. Reconstruction of in-cylinder pressure in a diesel engine from vibration signal using a rbf neural network model. 09 2011.
- [13] Katarzyna Bizon, Gaetano Continillo, Ezio Mancaruso, and Bianca Maria Vaglieco. Application of rbf neural networks for real-time pressure prediction in a diesel engine. 4, 10 2015.
- [14] Andrea Businaro, Nicolò Cavina, Enrico Corti, Giorgio Mancini, Davide Moro, Fabrizio Ponti, and Vittorio Ravaglioli. Accelerometer based methodology for combustion parameters estimation. *Energy Procedia*, 81(Supplement C):950 – 959, 2015. 69th Conference of the Italian Thermal Engineering Association, ATI 2014.
- [15] Gopi O Chandroth, AJC Sharkey, and NE Sharkey. Artificial neural nets and cylinder pressures in diesel engine fault diagnosis. *Proc of INMARC098 Shipping Trends for the Next Millennium*, 1:9–1, 1998.
- [16] Peter Charles, Jyoti K Sinha, Fengshou Gu, Liam Lidstone, and AD Ball. Detecting the crankshaft torsional vibration of diesel engines for combustion related diagnosis. *Journal of Sound and Vibration*, 321(3):1171–1185, 2009.
- [17] ZhiQiang Chen, Chuan Li, and René-Vinicio Sanchez. Gearbox fault identification and classification with convolutional neural networks. 2015:1–10, 10 2015.
- [18] Giancarlo Chiatti, Ornella Chiavola, Erasmo Recco, Agnese Magno, Ezio Mancaruso, and Bianca M. Vaglieco. Accelerometer measurement for mfb evaluation in multi-cylinder diesel engine. *Energy*, 133(Supplement C):843 – 850, 2017.
- [19] Instituto de Tecnologia e Educação Galileo da Amazônia – ITEGAM Companhia Energética Manauara. Desenvolvimento de um software para a avaliação da eficiência da combustão de termoelétricas operando com gás e alternando com diesel. *código ANEEL PD-5480-0001/2010*.
- [20] M. El-Ghamry, J.A. Steel, R.L. Reuben, and T.L. Fog. Indirect measurement of cylinder pressure from diesel engines using acoustic emission. *Mechanical Systems and Signal Processing*, 19(4):751 – 765, 2005.
- [21] Fathi Elamin, Fengshou Gu, and Andrew Ball. Diesel engine injector faults detection using acoustic emissions technique. *Modern Applied Science*, 4(9):3, 2010.
- [22] Turker Ince, Serkan Kiranyaz, Levent Eren, Murat Askar, and Moncef Gabbouj. Real-time motor fault detection by 1d convolutional neural networks. *IEEE Transactions on Industrial Electronics*, 63(11):7067–7075, 2016.
- [23] Olivier Janssens, Viktor Slavkovikj, Bram Vervisch, Kurt Stockman, Mia Locufier, Steven Verstockt, Rik Van de Walle, and Sofie Van Hoecke. Convolutional neural network based fault detection for rotating machinery. *Journal of Sound and Vibration*, 377(Supplement C):331 – 345, 2016.

- [24] Libin Jia, Jeffrey Naber, and Jason Blough. Frequency response function adaptation for reconstruction of combustion signature in a 9-l diesel engine. 229, 01 2015.
- [25] Libin Jia, Jeffrey Naber, Jason Blough, and Seyed Zekavat. Accelerometer-based combustion metrics reconstruction with radial basis function neural network for a 9 l diesel engine. 136:031507, 03 2013.
- [26] Roger Johnsson. Cylinder pressure reconstruction based on complex radial basis function networks from vibration and speed signals. *Mechanical Systems and Signal Processing*, 20(8):1923 – 1940, 2006.
- [27] Roger Johnsson. Cylinder pressure reconstruction based on complex radial basis function networks from vibration and speed signals. *Mechanical Systems and Signal Processing*, 20(8):1923 – 1940, 2006.
- [28] N. B. Jones and Yu-Hua Li. A review of condition monitoring and fault diagnosis for diesel engines. *Tribotest*, 6(3):267–291, 2000.
- [29] NB Jones and Yu-Hua Li. A review of condition monitoring and fault diagnosis for diesel engines. *Tribotest*, 6(3):267–291, 2000.
- [30] Phillip Mendonca, E.L. Bonaldi, Levy Oliveira, Germano Lambert-Torres, Jonas Borges da Silva, Luiz Eduardo Borges da Silva, C.P. Salomon, and Wilson Sant'Ana. Desenvolvimento de sistema preditivo para diagnóstico termomecânico de falhas em motores de combustão interna. *código ANEEL PD-6599-0002/2013*.
- [31] Bert Ritscher. dual-fuel engine with cylinder pressure based control. *MTZ industrial*, 3(2):14–23, 2013.
- [32] Brentech Energia S/A. Nacionalização de produto para monitoramento de grupos geradores. *código ANEEL PD-2934-0010/2012*.
- [33] Central Geradora Termelétrica Fortaleza S/A. Estudo de desenvolvimento de uma ferramenta para monitoramento e diagnóstico térmico de unidades geradoras com motor diesel. *código ANEEL PD-5614-0003/2015*.
- [34] TERMELÉTRICA VIANA S.A. Desenvolvimento de um sistema para monitoramento e diagnóstico de desempenho de unidades termelétricas com motor de combustão interna. *código ANEEL PD-6483-0111/2011*.
- [35] C. A. J. Sharkey, O. G. Chandroth, and E. N. Sharkey. A multi-net system for the fault diagnosis of a diesel engine. *Neural Computing & Applications*, 9(2):152–160, 2000.
- [36] F. Taglialatela, M. Lavorgna, E. Mancaruso, and B.M. Vaglieco. Determination of combustion parameters using engine crankshaft speed. *Mechanical Systems and Signal Processing*, 38(2):628 – 633, 2013.

- [37] REPARAI (REPair over AiR using Artificial Intelligence) Termelétrica Borboleta Energética – Paraíba. Sistema automático de diagnóstico acústico inteligente para auxílio à análise de falhas mecânicas, em motores a combustão interna de geração de energia elétrica. *código ANEEL PD-6471-0002/2012*.
- [38] Zhiqiang Wang. Study on fault diagnosis of fuel injection based on vibration signal analysis of high-pressure fuel injection pipe. *Applied Physics Research*, 1(2):102, 2009.
- [39] E. Weißenborn, T. Bossmeyer, and T. Bertram. Adaptation of a zero-dimensional cylinder pressure model for diesel engines using the crankshaft rotational speed. *Mechanical Systems and Signal Processing*, 25(6):1887 – 1910, 2011. Interdisciplinary Aspects of Vehicle Dynamics.
- [40] Jian-yuan Zhu. Detection of cylinder pressure in diesel engines using cylinder head vibration and time series methods. *Journal of Marine Science and Application*, 6(4):8–12, Dec 2007.

Apêndice A

Artigo: CITENEL

Artigo submetido para o CITENEL 2017. A submissão foi realizada em janeiro de 2017, antes dos ensaios em campo. Sem os resultados obtidos na prática, somente com o desenvolvimento teórico, o artigo acabou não sendo aceito.

Apêndice B

Artigo: CONEM

Resumo estendido do artigo submetido para: X Congresso Nacional de Engenharia Mecânica (CONEM), 20 - 24 de maio de 2018, Salvador, BA, Brasil.

Apêndice C

Artigo: ENCIT

Artigo sendo submetido para: 17th Brazilian Congress of Thermal Sciences and Engineering (ENCIT), 25 - 28 de novembro de 2018, Águas de Lindóia, SP, Brasil

Apêndice D

Artigo: IJCNN

Artigo sendo submetido para: 2018 International Joint Conference on Neural Networks (IJCNN), 8 – 13 de Julho de 2018, Rio de Janeiro, RJ, Brasil

Apêndice E

Artigo: CSBC

Artigo a ser submetido para: XXXVIII Congresso da Sociedade Brasileira de Computação, 22 – 26 julho de 2018, Natal, RN, Brasil

Apêndice F

Artigo: Revista

Artigo sendo submetido para a revista: Mechanical Systems and Signal Processing,
ISSN 0888-3270

Apêndice G

Patente

Texto de pedido de patente sobre o processo desenvolvido.

Apêndice H

Qualificação Doutorado

Formulário do Exame de Qualificação Específico (EQE) da tese de doutorado.